

Nachzeichner KI

Maturarbeit

Ian Wasser, Robin Steiner

Oktober 2022

Betreut durch: Nicolas Ruh

NKSA

Zusammenfassung

ReSketch ist eine künstliche Intelligenz, die versucht Strichbilder, wie zum Beispiel Ziffern oder Buchstaben, auf eine physische Weise nachzuzeichnen. Um die Frage zu beantworten, inwiefern das möglich ist, sind definierende Kriterien des Nachzeichnens festgelegt. So soll die künstliche Intelligenz zum Beispiel nur Bewegungen ausführen können, die auch mit einem Stift möglich wären. Die künstliche Intelligenz erlernt das Nachzeichnen nach diesen Kriterien durch Deep Q-Learning, einem Reinforcement Learning Modell. Das Modell basiert auf der Arbeit hinter Doodle-SDQ [Doodle-SDQ], erfährt aber konzeptuelle Variationen wie die Integration einer Physiksimulation. Die künstliche Intelligenz ist auf das Nachzeichnen von Ziffern trainiert. Ein Test dieser trainierten künstlichen Intelligenz auf Buchstaben und andere Arten von Strichbildern führt zur Antwort auf die Frage, ob eine künstliche Intelligenz das Nachzeichnen im Allgemeinen erlernen kann.

Vorwort

Diese Arbeit ist eine Untersuchung über künstliche Intelligenz. Die Fragestellung der Untersuchung wird mithilfe einer selbst programmierten künstlichen Intelligenz beantwortet.

Wir haben uns für das Thema Künstliche Intelligenz entschieden, weil damit praktische Arbeit mit intellektueller Forschung verbunden werden kann. Das Thema ermöglicht ausgeprägte, praktische Programmierarbeiten, was uns zuspricht. Zusätzlich ermöglicht künstliche Intelligenz einfache Forschung. Mit einfacher Forschung ist dabei nicht der Grad der Komplexität gemeint, sondern die Vielfalt der Möglichkeiten. Es gibt Aspekte und Anwendungen der künstlichen Intelligenz, die für uns zugänglich sind und noch nicht zu weit erforscht sind, um neue Ideen zu finden. Ausserdem benötigt die Forschung an künstlicher Intelligenz nur einen Computer. Experimente und Tests können durch Programmcode ausgeführt werden. Die Auswertung der Experimente findet auf dem selben Computer statt und die Genauigkeit der Ergebnisse stellt ebenfalls kein Problem dar, da der Computer die Zahlen direkt berechnet. Der Computer ist eine optimale Umgebung für eine erste Forschungsarbeit.

Diese Arbeit ist für uns eine erste vertiefte Erfahrung mit dem grossen Gebiet der künstlichen Intelligenz. Wir erhoffen uns durch diese Erfahrung einen erweiterten Horizont, neues Wissen und verbesserte Programmierkenntnisse.

Vielen Dank an unseren Betreuer, Dr. Nicolas Ruh, für die hilfreichen Vorschläge, die ausgeprägte Beratung und das Vertrauen in uns.

Inhaltsverzeichnis

1	Einleitung	1
2	Theoretische Grundlagen	3
2.1	Machine Learning	3
2.1.1	Funktionsweise eines Machine Learning Modelles . .	4
2.1.2	Hyperparameter	5
2.1.3	künstliche neuronale Netze	5
2.2	Reinforcement Learning	7
2.2.1	Aufbau und Funktionsweise	8
2.3	Verwandte Arbeiten und Themen	9
2.3.1	Doodle-SDQ	9
2.4	Git und GitHub	11
2.4.1	Git	11
2.4.2	GitHub	11
3	Methode	13
3.1	Grundprogramm	13
3.1.1	Doodle-SDQ als Basis	14
3.1.2	Präparierung der Daten und Optimierung	15
3.2	Evaluierung der Leistung	15
3.2.1	Erkennbarkeit	16
3.2.2	Prozentuale Übereinstimmung	16
3.2.3	Geschwindigkeit	17
3.3	Variationen	17
3.3.1	Basis Reward-Function	17
3.3.2	Training auf Geschwindigkeit	18
3.3.3	Training auf Erkennbarkeit	18
3.3.4	Physikalische Umgebung	20
3.4	Auswertung	21
3.4.1	Testumgebung	22

4 Resultate	25
4.1 Tabellen	26
4.2 Bildersammlung	27
5 Diskussion	31
5.1 Fragestellung und Unterfragen	31
5.1.1 Beantwortung der Unterfragen	32
5.1.2 Beantwortung der Fragestellung	34
5.2 Fazit und Ausblick	35
5.3 Selbstreflexion	35
5.3.1 Optimierung der KI	36
5.3.2 Analyse der künstlichen Intelligenz	36
5.3.3 Verwendung von Git und GitHub	37
6 Zusammenfassung	39
Literatur	41

Kapitel 1

Einleitung

Der Computer ist ein Werkzeug, das dem Menschen Arbeit abnehmen kann. Um komplizierte Aufgaben zu übernehmen, muss sich der Computer jedoch an menschliches Verhalten, menschliches Urteilsvermögen und menschliche Intelligenz annähern. Mit anderen Worten braucht der Computer, oder das steuernde Computerprogramm eine künstliche Intelligenz. Es ist schwierig, Intelligenz in einem Computerprogramm umzusetzen. Der fähigste und am weitesten verbreitete Ansatz liefert Machine Learning. Diese Arbeit selbst ist eine Untersuchung im Bereich Machine Learning. Spezifischer ist die Arbeit im Bereich Reinforcement Learning, einem Teilgebiet von Machine Learning.

Die Fragestellung der Untersuchung lautet: Kann eine künstliche Intelligenz lernen, Strichbilder nachzuzeichnen, sodass diese durch ein automatisches System richtig erkannt werden können?

Für ein gegebenes Strichbild soll die künstliche Intelligenz (KI) erlernen, ein möglichst gleiches Bild daneben zeichnen können. Die Frage ist, ob die KI das Nachzeichnen genug gut lernen kann, damit die Zeichnung von einem automatischen System richtig erkannt wird. Richtig erkannt heisst in diesem Fall vereinfacht, dass eine zweite KI in der Zeichnung das selbe Motiv wie in der Vorlage erkennt. Wenn das zutrifft, kann die künstliche Intelligenz erfolgreich nachzeichnen. Es existieren allerdings weitere Kriterien, die die Leistung der KI bei der Tätigkeit des Nachzeichnens beurteilen.

Nachzeichnen ist eine menschliche Tätigkeit. Menschen führen beim Zeichnen durch gewisse Handbewegungen einen Stift, wodurch das Nachzeichnen mit physischen Einschränkungen verbunden ist. Der Stift kann sich nicht teleportieren, sondern sich nur mit einer bestimmten Geschwindigkeit fortbewegen. Die KI soll das Nachzeichnen mit ähnlichen physischen Einschränkungen erlernen. Mit anderen Worten soll die KI lernen, einen Stift zu führen. Die physischen Einschränkungen sind dabei jedoch simuliert und im Vergleich zu der echten Welt vereinfacht.

Die KI soll das Nachzeichnen von Strichbildern allgemein erlernen. Strichbilder können Zahlen, Buchstaben, Formen, Symbole und allgemeine Kritzeleien sein. Die KI kann nicht mit allen Arten von Strichbildern trainieren, weil die Vielfalt zu gross ist. Daraus ergibt sich die Frage, wie gut die künstliche Intelligenz Arten von Strichbildern nachzeichnet, die nicht im Training enthalten waren.

Die vorangehenden Überlegungen sind in einer Sammlung an Unterfragen, die in dieser Arbeit beantwortet werden, vertreten. Die Unterfragen lauten:

- Wie kann die Architektur einer KI aussehen, die das Nachzeichnen erlernt?
- Nach welchen Kriterien lässt sich die Leistung der KI in dieser Aufgabe beurteilen?
- Wie lässt sich die Leistung der KI in dieser Aufgabe verbessern?
- Wie ändert sich die Leistung der KI für Strichbilder, die im Training nicht enthalten sind?
- Welche Einflüsse haben physische Einschränkungen auf die Leistung der KI?
- Wie und in wiefern lässt sich die KI mit menschlichem Zeichnen vergleichen?

Kapitel 2

Theoretische Grundlagen

Die theoretischen Grundlagen führen die Konzepte ein, die über die ganze Arbeit hinweg Anwendung finden. Es handelt sich dabei um Zusammenfassungen. Die Theorie wird auf den Teil reduziert, der für ein grundsätzliches Verständnis der Arbeit nötig ist. Weitere Informationen werden in den referenzierten Quellen einsehbar. Auch die verwendeten Fachbegriffe werden in diesem Kapitel eingeführt.

2.1 Machine Learning

Machine Learning ist ein Teilbereich der künstlichen Intelligenz. "Künstliche Intelligenz (KI) bezieht sich im Allgemeinen auf jedes menschenähnliche Verhalten durch eine Maschine oder ein System" [1] Mit Maschinen und Systemen sind in den allermeisten Fällen Computer, beziehungsweise die steuernden Computerprogramme gemeint. Diese Computerprogramme bilden ein Modell von menschlichem Verhalten. Machine Learning Modelle entwickeln (oder erlernen) eine Mustererkennung durch die Analyse von Daten [2]. Mustererkennung bedeutet hier, dass der Algorithmus Zusammenhänge zwischen den analysierten Daten erkennt und auf dieser Basis Vorhersagen treffen kann. Vereinfacht gesagt, versucht ein Machine Learning Modell menschliches Urteilsvermögen zu erlernen [3].

Ein Beispielpproblem für ein Machine Learning Modell ist die Erkennung von handschriftlichen Zahlen. Ein Computerprogramm soll durch den Input eines Bildes mit einer handschriftlichen Zahl eine korrekte Beurteilung treffen, um welche Zahl es sich handelt. Mit anderen Worten soll der Output des Computerprogrammes der Zahl entsprechen, die auf dem Bild der Eingabe zu sehen ist (siehe ??). Jedes Computerprogramm, das dieses Problem löst, fällt in den Bereich der künstlichen Intelligenz. Machine Learning Modelle geben einen Ansatz für die Umsetzung eines solchen Computerprogrammes.

Machine Learning Modelle, die das Beispielpproblem lösen, basieren üblicherweise auf Supervised Learning. Das ist ein Teilbereich von Machine Learning, wobei das Machine Learning Modell aus Rückmeldungen der korrekten Beurteilung, der Zielvariable, als Reaktion auf ihre eigenen Beurteilungen lernt [4]. Die Zielvariable muss dabei im Voraus für jeden Datenpunkt in den analysierten Daten durch einen Menschen festgelegt sein [ML 3.1]. Ausgedrückt durch den Fachbegriff müssen die Daten labeled sein [2.1 labeled]. Weitere Teilbereiche von Machine Learning sind Unsupervised Learning und Reinforcement Learning [5]. Beachte Reinforcement Learning für eine ausgeprägtere Einführung in Reinforcement Learning.

Machine Learning Modelle sind hauptsächlich in der Programmiersprache Python implementiert [6]. Dabei werden häufig Tensorflow und Keras verwendet. Tensorflow ist ein Machine Learning Framework [7]. Das bedeutet, dass Tensorflow fertige Funktionen und Algorithmen bereitstellt, die für Machine Learning Modelle nötig sind. Keras ist ein weiteres Machine Learning Framework, das selbst mit Tensorflow funktioniert.

2.1.1 Funktionsweise eines Machine Learning Modelles

Dieser Abschnitt erklärt die Funktionsweise eines Machine Learning Modelles, basierend auf dem Beispielpproblem aus dem letzten Abschnitt (siehe Machine Learning).

Bei den Daten, die das Machine Learning Modell analysiert handelt es sich in diesem Fall um das MNIST Datenset [8]. Dieses Datenset wurde vom NIST (National Institute of Standards and Technology) in Amerika veröffentlicht und beinhaltet 70'000 Bilder von handschriebenen Zahlen [9]. Jedes Bild hat eine Auflösung von 28×28 Pixeln (siehe [autorefmnist](#)).

Ein Machine Learning Modell durchläuft ein Training gefolgt von einer Testphase [10]. Während dem Training erlernt das Modell die Mustererkennung, um verlässliche Aussagen zu den Daten der Eingabe zu treffen. Die Testphase misst die Genauigkeit des Modelles, also die Wahrscheinlichkeit, mit der das Modell die richtige Lösung zur Eingabe liefert. Nur in den seltensten Fällen erreicht diese Genauigkeit 100%. Das Modell garantiert somit nicht die richtige Lösung. Das Machine Learning Modell erlernt die Mustererkennung während dem Training durch die Analyse von Trainingsdaten aus einem Datenset. Das Modell gibt zu jedem Datenpunkt die Beurteilung, um welche Zahl es sich handelt. Das Datenset ist labeled (siehe Machine Learning). Falls die Beurteilung des Modelles nicht mit der bekannten, korrekten Lösung übereinstimmt, passt sich das Modell automatisch auf eine bestimmte Weise an. Dadurch soll die Beurteilungen für zukünftige Datenpunkte genauer werden. Die Testphase misst die Genauigkeit des Modelles auf Testdaten. Die Testdaten bestehen aus Datenpunkten, die in den Trainingsdaten nicht enthalten sind.

Zusammengefasst kann Ein Machine Learning Modell Daten Beurteilen und sich selbst Anpassen, um die Beurteilungen zu verbessern. Künstliche Neuronale Netze (siehe künstliche neuronale Netze) umfassen diese Funktionalität, und finden daher in Machine Learning Modellen Anwendung.

2.1.2 Hyperparameter

Machine Learning Modelle umfassen verschiedene Hyperparameter. Diese beschreiben unter anderem wie lange das Training läuft oder wie stark sich das Modell nach einer falschen Beurteilung anpasst. Diese Hyperparameter beeinflussen das Lernverhalten des Modelles [11], aber ihr optimaler Wert ist im Voraus nicht bekannt.

Hyperparameter können unter anderem durch den Bayesian Optimization Algorithmus optimiert werden [12][13]. Dieser Algorithmus versucht, den Output einer Black Box Funktion zu maximieren oder zu minimieren [14, S. 15]. Eine Black Box ist ein häufig komplexes System, dessen inneren Vorgänge nicht betrachtet werden [15]. Bei einer Blackbox Funktion ist folglich der Input und der Output bekannt, während die Verarbeitung des Inputs zum Output nicht betrachtet wird (siehe [autorefBlackbox](#)).

Machine Learning Modelle werden häufig als Black Box Funktionen angesehen, da das Training mit hohem rechnerischen Aufwand verbunden ist, wodurch die genauen Vorgänge durch einen aussenstehenden Betrachter nicht oder nur schwer erfassbar sind [16]. Um ein Machine Learning Modell als eine BlackBox Funktion für den Bayesian Optimization Algorithmus zu verwenden, werden die zu optimierenden Hyperparameter als Input und eine Zielvariable als Output definiert. Die Zielvariable des Outputs entspricht dabei einem Wert, der die Leistung des Modelles widerspiegelt und durch den Algorithmus maximiert werden soll. Ein Beispiel für die Zielvariable wäre die Genauigkeit des Machine Learning Modelles (siehe Funktionsweise eines Machine Learning Modelles) Die inneren Vorgänge in der BlackBox Funktion entsprechen in diesem Fall einem Training des Modelles

Der Bayesian Optimization Algorithmus kann bis zu 20 Hyperparameter zuverlässig optimieren [17]. Der Algorithmus führt die Blackbox Funktion für eine bestimmte Anzahl Iterationen mit jeweils verschiedenen Parametern durch. Die Wahl der Parameter basiert dabei auf Bayes' Theorem [14, S. 7]. Diejenigen Parameter, die den höchsten gefundenen Wert der Zielvariable auslösen, werden gespeichert.

2.1.3 künstliche neuronale Netze

Ein neuronales Netz ist, im biologischen Sinne, eine beliebige Anzahl Neuronen, die miteinander Verbunden sind"[18]. Ein Beispiel für ein

neuronales Netz ist das menschliche Gehirn. Künstliche Neuronale Netze modellieren biologische neuronale Netze in der Form von Programmcode [19]. Diese Arbeit behandelt künstliche neuronale Netze, nicht aber biologische. Somit handelt es sich bei jedem erwähnten neuronalen Netz, um ein künstliches neuronales Netz.

Der Grundbaustein eines neuronalen Netzes ist das Neuron. Im Modell stellt das Neuron ein Objekt dar, das eine beliebige Anzahl Inputs, aber nur einen Output hat (siehe *autorefneuron*) [20]. Input und Output sind hierbei rationale Zahlen. Die Ausgabe des Neurons ist im einfachsten Modell, dem Perzeptron Neuron, grundsätzlich entweder 0 oder 1. Die Ausgabe ist 1, wenn die Summe der Eingaben einen vorgegebenen Wert, den *Threshold*, überschreitet. Ansonsten ist die Ausgabe gleich 0. Jede Eingabe hat ein *Gewicht*, das einer rationalen Zahl entspricht. Vor der Addition der Inputs wird jeder Input mit seinem Gewicht multipliziert. Die Grösse des Gewichts bestimmt somit den Einfluss der zugehörigen Eingabe auf die Ausgabe des Neurons. [21][22]

Neuronale Netze in Machine Learning Modellen verwenden kompliziertere Neuronen als das Perzeptron Neuron, wie zum Beispiel das Sigmoid-Neuron. Die Neuronen unterscheiden sich in ihrer Activation Function und somit im Verhalten ihres Outputs [23]. So nimmt der Output im Sigmoid-Neuron beispielsweise auch Werte zwischen 0 und 1 an in einem stetigen Übergang zwischen den beiden Grenzen (siehe *autorefsig* vs *perc*) [24].

Neuronale Netze sind Verbindungen dieser Neuronen. Dabei dient der Output eines Neurons als Input in ein anderes Neuron. Der Output eines Neurons kann gleich für mehrere Neuronen ein Input sein. Die Neuronen sind in *Layers* geordnet (siehe *autoreflayers*). Neuronale Netze haben mindestens eine *Input Layer* und eine *Output Layer* [21][25]. Die Input Layer umfasst die Daten, zu dem das neuronale Netz eine Beurteilung liefern sollte. Im Beispielproblem (siehe Machine Learning) bestünde die Eingabe-Ebene aus 28×28 Neuronen, wobei jedes Neuron die Graustufe (durch einen Wert von 0 bis 255) eines Pixels im Bild beschreibt. Der Input ist in diesem Fall zweidimensional. Die Dimensionen sind allerdings flexibel. Die Output Layer besteht im Beispiel aus 10 Neuronen, wobei jedes Neuron einer Beurteilung entspricht (das fünfte Neuron beschreibt zum Beispiel die Ziffer Fünf als Beurteilung). Dasjenige Neuron mit dem höchsten Output entspricht der Beurteilung des neuronalen Netzes.

Zwischen der Input Layer und der Output Layers kann es weitere *Hidden Layers* geben [26]. Es gibt verschiedene Arten von Hidden Layers, die verschiedene Funktionen haben. Zwei der meist verwendeten Layers sind Fully Connected (Dense) Layers und Convolutional Layers [27]. In Fully Connected Layers dient jedes Neuron als Input für jedes Neuron in der nächsten Layer. In Convolutional Layers trifft das nicht zu. (siehe

autorefconv vs. full)Die Funktion von Convolutional Layers ist es, wichtige Merkmale aus dem Input hervorzuheben [28]. Concatenation Layers [29] sind eine weitere Form von hidden Layers, die zwei verschiedene Layers als Input haben und diese somit verbinden. Machine Learning Modelle werden ab mehr als einer Hidden Layer als Deep Learning Modelle bezeichnet [deep learning].

Ein Machine Learning Modell passt während dem Training (siehe Funktionsweise eines Machine Learning Modelles) einzelne Gewichte im neuronalen Netz in der Hoffnung an, dass die Genauigkeit der Beurteilung mit den angepassten Gewichten grösser ist. Die Genaue Anpassung erfolgt in den meisten Machine Learning Modellen durch den Backpropagation Algorithmus [25][30].

2.2 Reinforcement Learning

Reinforcement Learning bedeutet Lernen durch Interaktion mit einer Umgebung. [31]. Genauer gesagt soll ein Machine Learning Modell durch Rückmeldungen und Beobachtungen aus einer Umgebung ein bestimmtes Verhalten erlernen.

Reinforcement Learning Modelle führen somit die Umgebung ein. Anders als bei Supervised Learning und Unsupervised Learning (siehe Machine Learning) sind die Daten, aus denen das Modell lernen soll, im Voraus nicht bekannt. Reinforcement Learning Modelle trainieren somit nicht auf der Grundlage eines Datensets. Das liegt in der Natur der Umgebung, die häufig zu viele verschiedene Zustände einnehmen kann, als dass diese in einem Datenset gesammelt werden könnten. Ein Machine Learning Modell kann trotzdem aus einer Umgebung lernen, indem es selbst mit dieser interagiert und dadurch Erfahrung sammelt. [32]

Als Beispiel kann die echte Welt als eine Umgebung angesehen werden. Der Mensch wäre in diesem Fall das Reinforcement Learning Modell. Der Mensch lernt die Eigenschaften seiner Umgebung durch Interaktionen mit dieser kennen. Beispielsweise lernt ein Mensch die Schwerkraft durch das Hinfallen kennen. Durch diese Erfahrungen kann der Mensch ein gewisses Verhalten, zum Beispiel das Laufen, erlernen. Reinforcement Learning Modelle imitieren dieses Lernverhalten. So verwendet die Robotik häufig Reinforcement Learning, um einen Roboter laufen zu lassen. Die Umgebung, mit der das Reinforcement Learning Modell lernt, ist dabei häufig nicht echt, sondern simuliert.

2.2.1 Aufbau und Funktionsweise

Dieser Abschnitt umfasst eine genauere Erklärung eines Reinforcement Learning Modelles, in diesem Fall Deep Q-Learning, unter der Verwendung der korrekten Fachbegriffe.

Ein Reinforcement Learning Modell umfasst eine *Umgebung* und einen *Agent*. Der Agent ist dasjenige Element in der Umgebung, welches mit dieser interagiert und daraus lernt [33, S. 53]. Die Umgebung verändert sich in Zeitschritten, genannt *Steps*. In jedem Step führt der Agent eine *Action* aus, die die Umgebung beeinflusst. Die Entscheidung, welche Action der Agent ausführt, basiert auf einer *Observation* [34, S. 2] der Umgebung. Die Observation umfasst alle Daten der Umgebung, die für die Entscheidung des Agents relevant sind. Der Agent trifft seine Entscheidung auf der Basis eines neuronalen Netzes (siehe künstliche neuronale Netze). Der Input in dieses neuronale Netz ist die Observation der Umgebung und der Output beschreibt die Action, die der Agent ausführt. Jedes Neuron des Outputs beschreibt eine spezifische Action des Agents. Der Agent kann somit nur eine feste Anzahl Actions ausführen. Alle Actions zusammen werden *Action-Space* [33, S. 67] genannt. Jede Action im Action-Space besitzt einen *Q-Value*, der dem Output des zugehörigen Neurons entspricht. (siehe autorefschema1) [35] Die schlussendliche Entscheidung, welche Action ausgeführt wird, basiert auf der *Epsilon-Greedy* Strategie [33, S. 34]. Diese Strategie sieht vor, dass die Entscheidung mit einer Wahrscheinlichkeit von ϵ auf eine zufällige Action fällt. Ansonsten fällt die Entscheidung auf diejenige Action mit dem höchsten Q-Value. Der Agent erkundet die Umgebung durch die zufälligen Actions, die er teilweise wählt. Der Agent wählt Actions, die er ansonsten nie wählen würde, und trifft möglicherweise zufällig auf bessere Optionen für zukünftige Steps [36].

Die Umgebung und somit auch der Agent werden durch die Actions des Agenten beeinflusst. Dieser Einfluss wird durch die *Reward-Function* gemessen. Die Reward-Function gibt eine rationale Zahl, den *Reward* aus [33, S. 75]. Umso grösser der Reward, desto positiver ist der Effekt auf die Umgebung und umgekehrt. Ein positiver Einfluss auf die Umgebung durch eine Action ist so definiert, dass der Agent durch die Action das gewünschte Verhalten vorzeigt. Die Reward-Function definiert, welches Verhalten welchen Reward erzielt. Der Q-Value der gewählten Action wird mit dem Reward (und dem maximalen Q-Value aus den nächsten möglichen Actions) addiert. Diese Formel nennt sich Bellman-Gleichung [34, S. 3]. Der neue Q-Value nimmt somit einen kleineren Wert an, wenn der Reward negativ ist, und einen grösseren Wert, wenn der Reward positiv ist. Die Gewichte des neuronalen Netzes werden daraufhin so angepasst, dass der Output für das Neuron, dessen Action ausgeführt wurde, näher am neu berechneten Q-Value ist (siehe autorefschema2). Der schlussendliche Effekt ist, dass

Actions, die einen positiven Reward auslösen, wahrscheinlicher gewählt werden, und umgekehrt Actions, die einen negativen Rewards auslösen, unwahrscheinlicher gewählt werden. Der Agent versucht insgesamt durch seine Actions einen möglichst hohen akkumulierten Reward zu erzielen [33, S. 57]. Der akkumulierte Reward entspricht der Summe der Rewards aus jedem Step.

Das Training läuft in *Episodes* [33, S. 14]. Eine Episode umfasst eine gewisse Anzahl Steps und am Anfang jeder Episode wird die Umgebung in einen Startzustand zurückgesetzt. Die Resultate eines Steps werden in dem *Replay-Buffer* gespeichert. Dazu gehören die Observation der Umgebung, die Action, und der Reward. Der Replay-Buffer enthält Speicherplatz für eine bestimmte Anzahl Steps. Während dem Training werden zufällige Steps aus dem Replay-Buffer gewählt, auf die das neuronale Netz trainiert. Das neuronale Netz trainiert also auf Daten aus der Vergangenheit der Umgebung und des Agents. Diese Strategie nennt sich Experience Replay [34, S. 5]. Ausserdem trainiert das neuronale Netz jeweils mit einem *Batch* an Steps, also mit einer gewissen Anzahl an Steps gleichzeitig. Der Replay-Buffer und der Batch sichern zu, dass das neuronale Netz mit einer grossen Vielfalt an Steps trainiert, was das Lernverhalten stabiler macht als ein chronologisches Training auf einzelne Steps [37].

2.3 Verwandte Arbeiten und Themen

Das Nachzeichnen von Strichbildern hängt allgemein mit dem Zeichnen von Bildern durch einen Computer zusammen. Es gibt verschiedene Ansätze, um einen Computer zeichnen zu lassen. Ein häufiger Ansatz ist *Stroke-Based Rendering* [stroke based rendering]. Stroke-Based Rendering ist das Zeichnen von Bildern durch das Platzieren von Elementen wie Strichen. Beispiele für Arbeiten in diesem Bereich sind Strokenet [38] und “Learning to Paint With Model-based Deep Reinforcement Learning” [39]. Andere Ansätze simulieren die Führung eines Stiftes. (siehe autorefstroke-based vs Stift) Ein Beispiel dafür ist das Programm Doodle-SDQ [40]. Doodle-SDQ beschäftigt sich auch spezifischer mit dem Nachzeichnen von Strichbildern und wird deswegen im nächsten Abschnitt weiter behandelt.

2.3.1 Doodle-SDQ

Doodle-SDQ ist ein Computerprogramm, das durch ein Reinforcement Learning Modell, spezifischer Deep Q-Learning (siehe Aufbau und Funktionsweise), erlernt, Strichbilder aus dem Google QuickDraw Datenset [41] nachzuzeichnen. Nachfolgend sind die Aspekte von Doodle-SDQ beschrieben, die für diese Arbeit relevant sind.

Die QuickDraw Bilder, die das Programm nachzeichnen soll, sind zu einer einheitliche Grösse von 84×84 Pixeln verarbeitet [40, S. 7]. Der Agent kann sich auf einer leeren Zeichenfläche von der selben Grösse bewegen und zeichnen. Die Umgebung umfasst diese Zeichenfläche, den Agent und das abzuzeichnende Bild.

Der Agent kann sich durch eine Action in jedem Step auf einen beliebigen Pixel in einem 11×11 Feld, in dessen Zentrum er ist, bewegen. Der Agent kann ausserdem jede dieser Bewegungen im zeichnenden Zustand oder im nicht zeichnenden Zustand machen. Der Action-Space hat somit insgesamt eine Grösse von $2 \cdot 11 \cdot 11 = 242$ Actions [40, S. 5]. Im zeichnenden Zustand wird ein Strich auf der Zeichenfläche zwischen der alten und der neuen Position des Agenten gezeichnet. Der Agent begeht 100 Steps pro Episode. Eine neue Episdoe entspricht dabei einem neuen Bild, das abgezeichnet werden soll.

Die Obervation der Umgebung, und somit der Input in das neuronale Netz (siehe Aufbau und Funktionsweise), ist in zwei Teile gegliedert: den Global Stream und den Local Stream. Der Global Stream hat eine Form von $28 \times 28 \times 4$. Der Input ist somit dreidimensional. Die Form kann als 4 aufeinandergestapelte Bilder angesehen werden, die jeweils eine Grösse von 28×28 Pixeln haben. Dabei beschreibt eine relle Zahl den Wert von jedem Pixel in einem Bild. Das erste Bild im global Stream ist die Vorlage, die abgezeichnet werden soll. Das zweite Bild ist die Zeichenfläche im aktuellen Zustand. Das dritte Bild beschreibt die Position des Agents durch seine relative Entfernung zu jedem Punkt auf der Zeichenfläche. Das vierte Bild beschreibt, ob der Agent im zeichnenden Zustand ist oder nicht. Wenn alle Pixel dieses letzten Bildes den Wert 1 haben, ist der Agent im zeichnenden Zustand. Wenn umgekehrt alle Pixel den Wert 0 haben, ist der Agent nicht im zeichnenden Zustand. Der Local Stream hat eine Form von $11 \times 11 \times 2$. Er ist somit auch dreidimensional und beschreibt zwei gestapelte Bilder. Das erste Bild umfasst die Vorlage in dem 11×11 Bereich (bezeichnet als Local image patch [40, S. 5]), in dem sich der Agent in einem Schritt bewegen kann. Das zweite Bild beschreibt den selben Bereich von der Zeichenfläche [40, S. 4 ff.]. Der global Stream und der Local Stream werden durch eine Concatenation Layer (siehe künstliche neuronale Netze) zusammengeführt.

Die Reward-Function (siehe Aufbau und Funktionsweise) bezieht sich auf die Differenz der Anzahl der übereinstimmenden Pixel zwischen der Vorlage und Zeichenfläche zwischen zwei Steps [40, S. 6]. Eine grosse Menge an neu übereinstimmenden Pixel entsprechen somit einem höheren Reward als wenige neu übereinsimmdende Pixel. Wenn nach einem Step weniger Pixel übereinstimmen als zuvor, entspricht das einem negativen Reward.

2.4 Git und GitHub

Git und Github sind weit verbreitete Hilfsmittel für Software Entwickler. Git ist ein Programm, während GitHub ein Service ist, der dieses Programm in der Cloud zugänglich macht. GitHub hat zusätzliche Funktionen, die die Zusammenarbeit zwischen mehreren Entwicklern erleichtern. Die genaue Funktion und das Zusammenspiel dieser beiden Hilfsmittel wird nachfolgend erläutert.

2.4.1 Git

Git erkennt Veränderungen im Code eines Projektes und speichert diese Veränderungen in einer neuen Version ab. Die einzelnen Versionen des Projektes bleiben dabei zu jedem Zeitpunkt abrufbar. Dieses Konzept nennt sich Version Control [42]. Das Programm wurde 2005 von Linus Torvald entwickelt [43]. Versionen des Projektes werden manuell durch einen Commit gespeichert. Es wird empfohlen, nur jeweils ein bestimmtes Problem oder eine bestimmte Funktion pro Commit anzugehen [`noauthor 5 nodate`]. Für grössere Funktionen oder Probleme kann ein Branch erstellt werden. Ein Branch ermöglicht eine abgekapselte Entwicklung eines Projektes [44]. Zum Beispiel kann das Projekt in mehreren Branches gleichzeitig und unabhängig von einander entwickelt werden [Git How Branch]. Eine weit verbreitete Arbeitsweise und Branch Struktur mit Git ist Gitflow [45]. Gitflow schlägt grundsätzlich einen Main Branch, einen Develop Branch und verschiedene Feature Branches vor [42]. Professionelle Anwendungen von Gitflow verwenden ausserdem so genannte Release Branches und Hotfix Branches [46]. Im Main Branch sind offizielle Versionen des Projektes gespeichert, Im Develop Branch wird das Projekt als ganzes entwickelt, und in jedem Feature Branch wird eine Funktionalität in das Projektes implementiert (siehe autorefBranch Structure für die genaue Branch Struktur).

2.4.2 GitHub

GitHub wurde 2008 von Chris Wanstrath, PJ Hyett, Scott Chacon und Tom Preston-Werner entwickelt [47]. 2018 wurde das Unternehmen von Microsoft gekauft. GitHub ist ein Service, der Projekte, die mit Git verwaltet werden, in der Cloud speichert. Dadurch kann ein Projekt überall und von beliebig vielen Personen entwickelt werden. GitHub betreibt eine Webseite, über welche der Service verwendet werden kann [47].

GitHub besitzt verschiedene Hilfsmittel, die die Zusammenarbeit von Entwicklern weiter vereinfachen. Beispiele dafür sind Issues und Project Boards. Diese Hilfsmittel ermöglichen Organisation, Strukturierung und Arbeitsteilung. Ein weiteres Hilfsmittel sind Pull Requests. Eine Pull Reqeust wird dann gestellt, wenn die Arbeit an einem Branch fertig ist. Durch Pull

Requests können die Entwickler des Projektes die Funktionalität eines Branches überprüfen. Wenn ein Branch nicht die gewünschte Aufgabe erfüllt, kann die Pull Request abgelehnt werden. Erst wenn eine Pull Request angenommen wird, kann der Branch wieder in den Main Branch zurückgeführt werden [48].

Kapitel 3

Methode

Die Methode dieser Untersuchung besteht darin, die in der Fragestellung beschriebene künstliche Intelligenz (KI) zu entwickeln und dessen Leistung auszuwerten. Die Diskussion dieser Resultate führt schlussendlich zu einer Antwort auf die Fragestellung. Die Entwicklung der KI besteht aus zwei Teilen. Der eine Teil umfasst die Definition der Kriterien, nach denen die Leistung der KI evaluiert wird (siehe Evaluierung der Leistung). Der andere Teil umfasst die Entwicklung der KI (siehe Grundprogramm), zusammen mit verschiedenen Variationen (siehe Variationen). Die Variationen haben jeweils einen unterschiedlichen Fokus auf die definierten Kriterien. Die Auswertung (siehe Auswertung) bezieht sich ebenfalls auf die definierten Kriterien. Die Leistung der KI wird dabei in einer Testumgebung für das Zeichnen von verschiedenen Arten von Strichbildern erfasst.

3.1 Grundprogramm

Die KI ist abhängig von den Kriterien, die dessen Leistung definieren (siehe Evaluierung der Leistung). Mit anderen Worten trainiert die KI auf diese Kriterien. Das Ziel des Grundprogrammes ist, die allgemeine Trainingsumgebung für die KI bereitzustellen. Dieses Grundprogramm ist unabhängig von einem spezifischen Kriterium und kann stattdessen auf ein ausgewähltes Kriterium trainiert werden. Reinforcement Learning Modelle mit einer undefinierten Reward Function (siehe Aufbau und Funktionsweise) stellen diese Eigenschaften bereit. Eine Reward function, basierend auf einem spezifischen Kriterium, ermöglicht das Training auf dieses Kriterium. Das Grundprogramm ist in Python unter der Verwendung des Keras Frameworks implementiert (siehe Machine Learning).

3.1.1 Doodle-SDQ als Basis

Das Reinforcement Learning Modell des Grundprogrammes basiert auf Doodle-SDQ. (siehe Doodle-SDQ) Von Doodle-SDQ ist das neuronale Netz, bezogen auf die Form des Inputs, des Outputs und den Hidden Layers, zu grossem Teil übernommen. Die relevanten Anpassungen zwischen Doodle-SDQ und dem Grundprogramm dieser Arbeit sind nachfolgend erläutert.

Bei der Umgebung handelt es sich, wie bei Doodle-SDQ, um eine Zeichenfläche, worauf sich der Agent frei bewegen kann. Die Ziffern, die während dem Training nachgezeichnet werden sollen, stammen aus dem MNIST Datenset (siehe Machine Learning) und haben somit eine Grösse von 28×28 Pixeln. Die Fläche, worauf sich der Agent bewegen kann, hat somit auch eine Grösse von 28×28 Pixeln. Der global Stream (siehe Doodle-SDQ) des Inputs in das Neuronale Netz ändert sich bis auf die neue Grösse der Bilder nicht. Die Pixel der Bilder, wie auch die Zeichenfläche, nehmen den Wert von einem Bit an. Eine Null repräsentiert einen schwarzen (nicht gezeichneten) Pixel an dieser Stelle im Bild und eine Eins einen weissen (gezeichneten) Pixel. Die genaue Architektur des neuronalen Netzes ist im Schema autorefarchitecture angegeben. Jeder Block in der Abbildung repräsentiert Eine Layer des neuronalen Netzes, wobei die Form des Inputs und die Form des Outputs von jeder Layer angegeben ist.

Der Local Stream, also das nahe Umfeld um den Agent schrumpft von 11×11 Pixel auf 7×7 Pixel. Somit schrumpft gleichzeitig der Action-Space (siehe Aufbau und Funktionsweise) des Agenten von $2 \cdot 11 \cdot 11 = 242$ Actions auf $2 \cdot 7 \cdot 7 = 98$ Actions. Das bedeutet für den Agent, dass er sich pro Step um maximal drei Pixel von seiner Position wegbewegen kann. Diese Bewegung kann der Agent entweder zeichnend oder nicht zeichnend ausführen (siehe autorefzeich vs nicht zeich).

Falls der Agent die Action zeichnend ausführt, zieht das Programm einen Strich zwischen der alten und der neuen Position. Mit anderen Worten werden alle Pixel der Zeichenfläche zwischen den beiden Positionen weiss. Der Strich hat eine festgelegte Breite von 3 Pixeln. Am Anfang jeder Episode, also bei jeder neuen Ziffer, die gezeichnet werden soll, startet der Agent in einer zufälligen Position im nicht zeichnenden Zustand. Am Anfang jeder Episode ist die Zeichenfläche leer, also vollkommen Schwarz.

Actions des Agents, die ihn über die vorgegebene Zeichenfläche hinaus positionieren würden, sind nicht zulässig. Diese Actions können vom Agent nicht gewählt werden und ihr optimaler Q-Value (siehe autorefzeich vs nicht zeich) ist in jedem Fall 0. Das hat zur Folge, dass nach dem Training die allermeisten unzulässigen Actions einen Q-Value nahe oder gleich 0 haben. Das senkt die Wahrscheinlichkeit, dass der Agent versucht, eine unzulässige Action auszuführen.

3.1.2 Präparierung der Daten und Optimierung

Die Trainingsdaten bestehen aus 36'000 Bildern von handgeschriebenen Ziffern aus dem MNIST Datenset (siehe Machine Learning). Die restlichen Bilder des MNIST Datensets machen die Testdaten aus. Die Bilder im Datenset sind als Bitmap dargestellt, wobei jedes Element (jeder Pixel) einen Wert zwischen 0 und 255 annimmt. Die Zahl repräsentiert eine Graustufe, wobei 0 Schwarz ist und 255 Weiss. Diese Graustufen werden entfernt. Jeder Pixel mit einem Wert über 0 übernimmt den Wert 1, wodurch die Bilder nur noch aus Einsen und Nullen bestehen. Dabei ist 0 Schwarz und 1 Weiss (siehe `autorefnorm` vs. `nogray`). So stimmen die Bilder mit den Zeichnungen, die der Agent produzieren kann, überein.

Das Grundprogramm trainiert mit 4000 Bildern, von denen jede Ziffer 400 Bilder ausmacht. Die restlichen Bilder in den Trainingsdaten sind für mögliche Erweiterungen aufgehoben. Der Agent zeichnet jedes der 4000 Bilder ein Mal und trainiert somit für 4000 Episodes. Der Agent macht 64 Steps pro Episode. Er kann sich also pro Zeichnung 64 Mal bewegen. Das neuronale Netz passt sich in jedem vierten Step an, mit einem Batch von 64 zufällig ausgewählten Steps aus dem Replay Buffer.

Die Hyperparameter des Grundprogrammes, wie auch der Variationen (siehe Variationen) sind durch den Bayesian Optimization Algorithmus optimiert (siehe Hyperparameter). Die Implementierung des Algorithmus in Python stammt von [fernando'bayesian'2022]. Der Algorithmus ändert sich für verschiedene Variationen der KI nicht und ist somit Teil des Grundprogrammes, wobei er zu der optimalen Leistung der KI beiträgt.

Mit jeder Iteration des Bayesian Optimization Algorithmus trainiert das Reinforcement Learning Modell für eine vom Algorithmus selbst bestimmte Anzahl Episodes. Die Zielvariable, die durch den Bayesian Optimization Algorithmus maximiert werden soll, wird am Ende jeder Iteration des Trainings in der Testumgebung berechnet (siehe Testumgebung). Auf welchem Kriterium die Zielvariable basiert, ist frei wählbar.

3.2 Evaluierung der Leistung

In diesem Unterkapitel sind die Kriterien definiert, die die Leistung der künstlichen Intelligenz evaluieren. Mit anderen Worten beschreiben die Kriterien, wie gut die KI nachzeichnet. Für eine präzise und objektive Evaluierung sind alle Kriterien durch einen Zahlenwert definiert. Dieser Zahlenwert geht direkt aus Berechnungen vom Computerprogramm hervor. Die Kriterien und ihre jeweilige Berechnung sind nachfolgend beschrieben.

3.2.1 Erkennbarkeit

Das Kriterium der Erkennbarkeit beschreibt, ob in der Vorlage das gleiche Motiv wie in der Zeichnung der künstlichen Intelligenz erkannt wird. Wenn Beispielsweise in beiden Fällen eine Fünf erkannt wird, hat das Kriterium den Wert 1. Wird in der Vorlage eine Fünf erkannt, aber in der Zeichnung eine Vier, hat das Kriterium den Wert 0

Welches Motiv in der Zeichnung erkannt wird, ist durch eine zweite künstliche Intelligenz bestimmt (siehe Funktionsweise eines Machine Learning Modelles). Diese zweite KI beurteilt ein Motiv nur als erkannt, wenn das zugehörige Neuron im Output des neuronalen Netzen einen Wert von über 0.75 hat. Das entspricht mit einer hohen Wahrscheinlichkeit der korrekten Beurteilung.

Um die verschiedenen Arten von Strichbildern, die die KI zeichnen soll, zu erkennen, existieren vortrainierte Machine Learning Modelle. Die in dieser Arbeit implementierten vortrainierten Modelle sind in der Tabelle ... ersichtlich. Diese Modelle sind mit den selben Daten trainiert, die in der Testumgebung (siehe Testumgebung) als Vorlage zum Abzeichnen dienen.

Tabelle: Art — Entwickler — Trainiert mit — Genauigkeit Zahlen Buchstaben Strichbilder von Objekten

Dieses Kriterium ist in der Fragestellung (siehe Einleitung) angedeutet. Die Antwort auf die Frage fällt positiv aus, wenn die KI dieses Kriterium der Erkennbarkeit konsequent erfüllt. Neben der Erkennbarkeit existieren weitere Kriterien, die andere Aspekte der Leistung der künstlichen Intelligenz betreffen.

3.2.2 Prozentuale Übereinstimmung

Dieses Kriterium ist durch die prozentuale Übereinstimmung der weissen (gezeichneten) Pixel zwischen der Vorlage und der Zeichnung der künstlichen Intelligenz definiert. Der Wert K dieses Kriteriums zu einem bestimmten Step t berechnet sich aus folgender Formel:

$$K(t) = \frac{G(t)}{G_{\max}}$$

G_{\max} entspricht der Anzahl aller weissen Pixeln in der Vorlage. $G(t)$ entspricht der Anzahl der weissen Pixel, die zwischen der Vorlage und der Zeichenfläche übereinstimmen. Wenn der gleiche Pixel (am gleichen Ort) in der Vorlage und in der Zeichenfläche weiss ist, erhöht sich diese Anzahl um Eins. Wenn in der Zeichenfläche ein weisser Pixel gezeichnet ist, der in der Vorlage schwarz ist, sinkt die Anzahl um Eins. $G(t)$ und somit auch $K(t)$ können dadurch auch negative Werte annehmen. Der maximale Wert von

$K(t)$ ist 1, was einer Genauigkeit von 100% entspricht (siehe autorefüber Pixel).

3.2.3 Geschwindigkeit

Dieses Kriterium beschreibt, wie schnell die Zeichnung der KI fertig ist. Der Wert dieses Kriteriums entspricht der Anzahl Steps bis zur Fertigstellung der Zeichnung. Eine kleinere Anzahl Steps entspricht einer schnelleren Fertigstellung der Zeichnung und somit einer besseren Leistung nach diesem Kriterium.

Eine Zeichnung gilt als fertig, wenn die prozentuale Übereinstimmung (siehe Prozentuale Übereinstimmung) mindestens 70% beträgt und die Zahl der Definition entsprechend erkannt wird (siehe Erkennbarkeit). Wenn die Zeichnung bis zum Ende der Episode die Bedingungen einer fertigen Zeichnung nicht erfüllt, hat dieses Kriterium den Wert 64. Das entspricht der maximalen Anzahl Steps, die von der KI pro Zeichnung begangen werden.

3.3 Variationen

Dieses Kapitel beschreibt verschiedene Variationen ausgehend vom Grundprogramm (siehe Grundprogramm). Bei einigen dieser Variationen handelt es sich um konkrete Implementierungen der definierten Kriterien in die Reward Function (siehe Aufbau und Funktionsweise). Die Reward Function kann dabei auch auf mehreren Kriterien basieren. Der Unterschied zwischen den Variationen liegt im Fokus auf die Kriterien. Einige Variationen sind untereinander kombinierbar. Andere Variationen führen Strukturelle Änderungen an der KI ein, die über die Reward Function hinaus gehen. Das Ziel der strukturellen Änderungen ist eine grundsätzliche Verbesserung, oder zumindest eine Anpassung des Verhaltens und der Leistung der künstlichen Intelligenz.

3.3.1 Basis Reward-Function

Die Basis Reward Function ist die einfachste Erweiterung des Grundprogrammes (siehe Grundprogramm) zu einer funktionierenden künstlichen Intelligenz. Diese Reward Function implementiert das Kriterium der prozentualen Übereinstimmung (siehe Prozentuale Übereinstimmung). Der Reward für eine Action berechnet sich aus der Differenz zwischen der prozentualen Übereinstimmung vor dem Ausführen der Action, und der prozentualen Übereinstimmung nach dem Ausführen der Action (also $K(t-1)$ und $K(t)$). Somit wird der Reward R zum Step t durch folgende Formel berechnet.

$$R(t) = K(t) - K(t-1)$$

Der Reward eines Steps entspricht somit nicht der gesamten prozentualen Übereinstimmung zu diesem Step. Stattdessen entspricht der Reward der Veränderung der prozentualen Übereinstimmung, ausgelöst durch die Action zu diesem Step. Der addierte Reward aller Steps entspricht dem absoluten Wert der prozentualen Übereinstimmung.

3.3.2 Training auf Geschwindigkeit

Der numerische Wert für die Zeit bis zur Fertigstellung der Zeichnung (siehe Geschwindigkeit) kann in die Reward-Function integriert werden. Dadurch trainiert die künstliche Intelligenz auf eine minimale Zeit bis zur Fertigstellung. Die Variation verwendet die grundsätzlich die Basis Reward-Function (siehe Basis Reward-Function). Die Anpassung davon sieht folgendermassen aus: Am Ende jeder Zeichnung wird der Reward jedes Steps mit einem Faktor f multipliziert. Dieser Faktor berechnet sich aus folgender Formel:

$$f = 2 - \frac{S}{S_{\max}}$$

S_{\max} entspricht der Anzahl Steps, die der Agent pro Zeichnung (Episode) begeht (siehe Präparierung der Daten und Optimierung). S entspricht der Anzahl Steps bis zur Fertigstellung der Zeichnung. Der Faktor nimmt einen Wert zwischen 1 und 2 an. Ein grösserer Faktor f entspricht einer schnellen Fertigstellung und deswegen einem hohen Reward. Wenn der Agent die Zeichnung bis zum Ende einer Episode nicht fertigstellen, ist $f = 1$ (siehe Geschwindigkeit). In diesem Fall unterscheidet sich die Reward-Function nicht von der Basis Reward-Function. Wenn die Zeichnung früher fertiggestellt wird, zeichnet der Agent trotzdem S_{\max} Steps. Das verhindert eine ungleichmässige Verteilung zwischen verschiedenen Episodes im Replay-Buffer (siehe Aufbau und Funktionsweise). In diesem Fall wird S nur in dem Step gespeichert, in dem die Zeichnung zum ersten Mal die Bedingung einer Fertigstellung erfüllt.

Der Fokus des Trainings auf eine maximale Geschwindigkeit erfährt einen weiteren anstieg, durch eine Anpassung der Bedingung für eine fertige Zeichnung während dem Training. Die minimale prozentuale Übereinstimmung einer fertigen Zeichnung ist als 75% definiert. Zu Beginn des Trainings wird dieser Wert auf 25% herabgesetzt, und über das Training hinweg linear bis auf 75% erhöht. Dadurch löst die Reward Function bei einer unfertigen Zeichnung bereits positive Rewards für die Geschwindigkeit aus.

3.3.3 Training auf Erkennbarkeit

Das Kriterium der Erkennbarkeit kann, anders als die anderen Kriterien, nur teilweise in die Reward Function integriert werden. Das Kriterium

strebt eine Erkennbarkeit, unabhängig von der Art der Strichbilder, an (siehe Erkennbarkeit). Die künstliche Intelligenz trainiert allerdings nur auf das Nachzeichnen von Ziffern. Aus diesem Grund trainiert diese Variation nur auf die Erkennbarkeit von Ziffern, und lässt die anderen Arten von Strichbildern ausser vor.

Die Reward-Function (siehe Aufbau und Funktionsweise) dieser Variation beinhaltet eine zweite KI, die handgeschriebene Ziffern erkennt (siehe Unterabschnitt 3.2.1). Diese zweite KI beurteilt in jedem Step, welche Ziffern sie in der Vorlage und in der aktuellen Zeichnung erkennt. Wenn die erkannte Zahl in der Vorlage und der Zeichnung gleich ist, erhält der Agent einen Reward von 0.1. In diesem Zustand funktioniert die Reward-Function allerdings nicht. Der Agent kann den akkumulierten Reward nicht maximieren. Zwei Ansätze gehen auf dieses Problem ein. Beide Ansätze sind Teil dieser Variation.

Der erste Ansatz schlägt vor, die zweite KI erst ab einer gewissen prozentualen Übereinstimmung (siehe Prozentuale Übereinstimmung) einzusetzen. In diesem Fall löst die korrekte Erkennung erst ab einer prozentualen Übereinstimmung von 20% einen positiven Reward aus. Diese zusätzliche Bedingung ist notwendig, weil die Beurteilungen der zweiten KI teilweise für einen menschlichen Betrachter fragwürdig sind. Zum Beispiel schätzt die zweite KI eine leere Zeichenfläche mit einer hohen Wahrscheinlichkeit als eine Eins (siehe autorefnist rec) ein. Das ist ein Problem, weil dadurch der Agent einen positiven Reward für eine leere Zeichenfläche erhält. Das stört das weitere Lernverhalten, weil es die Wahrscheinlichkeit erhöht, dass die KI nicht mehr zeichnet.

Der zweite Ansatz implementiert neben der Reward-Function der Erkennbarkeit erneut die Basis Reward-Function (siehe Basis Reward-Function). Die Relevanz der beiden Reward-Functions ändert sich allerdings über das Training hinweg. Die Rewards werden in jedem Step mit einem bestimmten Faktor multipliziert. Zu Beginn des Trainings ist der Faktor für den Reward der Basis Reward-Function $f_b = 1$ und der Faktor für den Reward basierend auf der Erkennbarkeit $f_e = 0$. Vom Start ausgehend sinkt f_b linear und f_e steigt linear. Ab einem gewissen Punkt bleiben beide Faktoren stehen (siehe autorefdecrementor graph). Blieben die Faktoren ab diesem Punkt nicht konstant, würde die Variation, gestützt auf Beobachtungen, an Stabilität der Leistung verlieren.

Das Zusammenspiel der beiden Reward-Functions hat den Vorteil, dass die künstliche Intelligenz zu Beginn des Trainings durch die Basis Reward-Function für kleine Erfolge positive Rewards erzielt. Die Reward-Function der Erkennbarkeit ermöglicht das nicht, da sie erst für eine korrekte Erkennung einen Reward auslöst. Eine korrekte Erkennung ist für eine untrainierte KI schwer zu erreichen. Deswegen muss die KI durch die Basis Reward-

Function gewissermassen vortrainiert werden, um schlussendlich von der Reward-Function der Erkennbarkeit zu profitieren

3.3.4 Physikalische Umgebung

Diese Variation spezialisiert sich auf kein Kriterium. Stattdessen verändert sich die Umgebung, in der sich der Agent bewegt (siehe Aufbau und Funktionsweise). Auch der Input und der Output des neuronalen Netzes sind angepasst. Durch diese Veränderungen unterscheidet sich die Variation vom Grundprogramm. Sie bleibt allerdings mit den anderen Variationen (siehe Training auf Erkennbarkeit und Training auf Geschwindigkeit) kompatibel, Da diese ausschliesslich die Reward-Function anpassen.

Die Variation ergänzt die Umgebung durch physikalische Simulationen. Diese physikalische Umgebung definiert die physischen Rahmenbedingungen des Zeichnens neu, mit dem Ziel, diese näher an die Realität zu bringen (siehe Beantwortung der Unterfragen).

Der Agent hat neu eine Geschwindigkeit, die durch einen Vektor \vec{v} dargestellt ist. Die Geschwindigkeit beschreibt, um wie viele Pixel und in welche Richtung sich der Agent pro Step bewegt. Die folgende Formel beschreibt, wie sich die Position des Agenten vom Step t bis zum nächsten Step $t + 1$ ändert:

$$\vec{p}(t + 1) = \vec{p}(t) + \vec{v}(t)$$

$\vec{p}(t)$ beschreibt die Position des Agents als einen Ortsvektor auf der Zeichenfläche zum Step t und $\vec{v}(t)$ beschreibt die Geschwindigkeit des Agenten zum Step t . Die Position rundet in jedem Step auf ganze Zahlen. Das kommt daher, dass die Geschwindigkeit auch Dezimalzahlen annehmen kann, aber die Position nur durch ganze Zahlen dargestellt ist.

Zur Geschwindigkeit des Agent wird in jedem Step ein Beschleunigungsvektor addiert. Jede Action, die der Agent wählen kann, entspricht einem anderen Beschleunigungsvektor. Der Action-Space (siehe Aufbau und Funktionsweise) besteht neu aus 42 Actions. 21 der 42 Actions entsprechen Beschleunigungsvektoren im zeichnenden Zustand. Die anderen 21 Actions entsprechen den selben Vektoren im nicht zeichnenden Zustand. Die 21 verschiedenen Beschleunigungsvektoren haben folgende Form: Ein Vektor entspricht dem Nullvektor. Dieser verändert die Geschwindigkeit des Agents nicht. 8 Vektoren sind um den Agent herum mit einer Länge von 0.9 Pixeln in gleichmässigem Abstand von einander angeordnet. Zusammen bilden diese Vektoren einen Kreis um den Agent. Die restlichen 12 Vektoren sind in einem grösseren Kreis gleichmässig angeordnet. Die Vektoren haben dabei eine Länge von 1.8 Pixeln (siehe autorefactionspace). Mit dem gewählten Beschleunigungsvektor $\vec{a}(t)$ berechnet sich die Geschwindigkeit

im nächsten Step $t + 1$ aus dem aktuellen Step t durch folgende Formel:

$$\vec{v}(t + 1) = \vec{v}(t) + \vec{a}(t)$$

Der Betrag der Geschwindigkeit $\vec{v}(t + 1)$ des Agents wird, unabhängig von der gewählten Action, in jedem Step um 0.2 Pixel verringert. Das simuliert eine Reibungskraft, die auf den Agent einwirkt.

Die Veränderung in der Umgebung erfordert weitere Anpassungen im neuronalen Netz (siehe künstliche neuronale Netze). Ohne diese Anpassungen kann die KI den akkumulierten Reward nicht maximieren. Das Problem ist, dass die aktuelle Geschwindigkeit des Agents kein Teil der Observation (siehe Aufbau und Funktionsweise) ist. Der Agent berücksichtigt deswegen seine Geschwindigkeit nicht in seinen Entscheidungen. Die Lösung dieses Problems bietet eine Verschiebung des Local image patch (siehe Doodle-SDQ). Im Grundprogramm entspricht der Mittelpunkt des Local image patches genau der Position des Agents. Neu befindet sich der Mittelpunkt dort, wo sich der Agent laut seiner aktuellen Geschwindigkeit im nächsten Schritt befinden wird. Durch diese Verschiebung des Local image Patches erhält der Agent Informationen über seine Geschwindigkeit, ohne dessen numerischen Wert zu kennen. Wie im Grundprogramm gibt der Local image patch den gesamten Bereich an, in dem sich der Agent im nächsten Schritt befinden kann. Die tatsächliche neue Position des Agents wird durch die Action seiner Wahl bestimmt. Die Grösse des Local image patches schrumpft von 7×7 Pixeln auf 5×5 Pixel, da alle möglichen Positionen des Agents nach einem Step auf einem 5×5 Feld Platz haben (siehe autoreflocal patch).

Ein weiteres Problem ist, dass der Agent sich durch seine Geschwindigkeit aus den vorgegebenen Grenzen der Zeichenfläche begeben kann. Im Grundprogramm (siehe Doodle-SDQ als Basis) kann der Agent Actions, die ihn in eine unzulässige Position bewegen würden, nicht auswählen. Wenn allerdings in der physikalischen Umgebung die Geschwindigkeit des Agents zu hoch ist, kann dieser keine Actions mehr wählen, die ihn innerhalb der Grenzen der Zeichenflächen hielten. Wenn der Agent durch zu hohe Geschwindigkeit über die Grenze hinausgeht, wird seine Geschwindigkeit auf den Nullvektor zurückgesetzt und die Reward Function löst einen negativen Reward von -0.05 aus. Der negative Reward soll die Häufigkeit dieser Vorfälle vermindern

3.4 Auswertung

Die Auswertung der Daten über die Leistung der künstlichen Intelligenz liefert das Resultat der Methode. Die Auswertung berechnet den Zahlenwert der definierten Kriterien (siehe Evaluierung der Leistung) für verschiedene Variationen der KI.

Die Variationen werden auf ihre Leistung für drei verschiedene Datensets überprüft. Die drei Datensets beinhalten verschiedene Arten von handgemachten Strichbildern. (siehe Unterabschnitt 3.2.1) Das erste Datenset, MNIST, beinhaltet Ziffern, die in den Trainingsdaten nicht vorkommen. Das zweite Datenset, EMNIST Letters, beinhaltet die 26 Kleinbuchstaben des Alphabets. Das dritte Datenset, QuickDraw, beinhaltet Zeichnungen von insgesamt 345 verschiedenen Motiven. Die KI wird allerdings nur auf das Nachzeichnen von zehn Motiven überprüft. Die zehn Motive sind: 'Amboss', 'Apfel', 'Besen', 'Eimer', 'Bulldozer', 'Uhr', 'Wolke', 'Computer', 'Auge' und 'Blume' (siehe [autorefDataset images](#)). Die Bilder in den drei Datensets sind gleich verarbeitet wie die Trainingsdaten (siehe Präparierung der Daten und Optimierung).

Die Variationen (siehe Variationen) der KI umfassen zwei Umgebungen und drei Reward-Functions Aufbau und Funktionsweise. Für jede Variation ist zur Vereinfachung eine Abkürzung definiert.

- Grundprogramm Umgebung: Grund
- Physikalische Umgebung: Physik
- Training auf Erkennbarkeit: Basis
- Training auf Geschwindigkeit: Speed
- Training auf Erkennbarkeit (von MNIST Ziffern): MNIST

Die folgenden Kombinationen an Variationen der künstlichen Intelligenz werden ausgewertet. Diese Kombinationen stellen einzelne Versionen der KI dar

- Grund-Basis
- Grund-MNIST
- Grund-Speed
- Grund-MNIST-Speed
- Physik-Basis
- Physik-MNIST
- Physik-Speed
- Physik-MNIST-Speed

3.4.1 Testumgebung

Die Leistungen der verschiedenen Variationen der künstlichen Intelligenz werden in einer Testumgebung (siehe Funktionsweise eines Machine Learning Modelles) ausgewertet. zwischen der Trainingsumgebung und der Testumgebung sind drei relevante Unterschiede erkennbar. Erstens trainiert die KI in der Testumgebung nicht. Die Testumgebung übernimmt eine trainierte Version der KI und verändert diese während dem Test nicht. Zweitens wählt der Agent in keinem Fall mehr eine zufällige Action. Stattdessen wählt er immer die Action mit dem höchsten Q-Value

(gleichbedeutend mit $\varepsilon = 0$) (siehe Aufbau und Funktionsweise). Der Dritte Unterschied liegt in den Strichbildern, die für die künstliche Intelligenz als Vorlage dienen. Im Test zeichnet das Computerprogramm 2000 Bilder aus einem der drei zur Verfügung stehenden Datensets (siehe ??).

Am Ende jeder Episode (das heisst jeder Zeichnung), wird der Zahlenwert für die verschiedenen Kriterien (siehe Evaluierung der Leistung) nach ihrer Definition ausgewertet und gespeichert. Die KI zeichnet auch in der Testumgebung für 64 Steps. Wenn eine Zeichnung der Definition entsprechend früher fertig ist (siehe Geschwindigkeit), wird die Anzahl Steps zu diesem Zeitpunkt als Wert des Kriteriums der Geschwindigkeit gespeichert und die KI zeichnet weiter. Der Durchschnitt aller gespeicherten Werte eines Kriteriums entspricht der Leistung der getesteten Variation in diesem Kriterium. Das Kriterium der Erkennbarkeit (siehe Erkennbarkeit) verwendet zur Auswertung je nach dem verwendeten Datenset im Test, dasjenige vortrainierte Modell, das auf dem selben Datenset trainiert ist. Da das Kriterium der Erkennbarkeit jeweils den Wert 0 oder 1 hat, ergibt der Durchschnitt aus allen Werten dieses Kriteriums eine prozentuale Angabe (in Dezimalform) darüber, in wie vielen Fällen das richtige Motiv erkannt wird.

Kapitel 4

Resultate

Die Resultate bestehen aus drei Tabellen. Jede Tabelle beschreibt die Leistung der acht Versionen (siehe Variationen), bezogen auf die drei definierten Kriterien (siehe Evaluierung der Leistung). Die Daten in den Tabellen stammen aus den Tests der KI (siehe Auswertung). Der Unterschied in den Tabellen liegt im Datenset, mit denen die Versionen der KI jeweils getestet sind. Eine Sammlung von gezeichneten Strichbildern ergänzt die Resultate. Die Strichbilder sind dabei jeweils in Paaren angeordnet. Das linke Bild im Paar zeigt die Vorlage aus dem Datenset und das rechte Bild zeigt die nachgezeichnete Variante von der KI. Die Zeichnungen, die in der Sammlung vertreten sind, sind zufällig ausgewählt aus dem Test der jeweiligen Version der KI. Die Bilder haben einen Farbverlauf, der den zeitliche Verlauf des Zeichnens dargestellt. Die Helligkeit eines Striches ist proportional zu dem Step, in dem dieser gezeichnet wurde. Das bedeutet, dass dunklere Striche früher gezeichnet werden als hellere Striche. Bewegungen des Agents, in denen dieser nicht zeichnet, sind in den Bildern nicht erkennbar.

4.1 Tabellen

Tabelle 4.1: Testen auf MNIST Datenset — 2000 Tests

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
Grund-Basis	86.5	86.6	24.5
Grund-MNIST	66.8	64.3	51.2
Grund-Speed	86.2	86.6	25.5
Grund-MNIST-Speed	61.4	55.1	56.8
Physik-Basis	56.4	46.4	62.5
Physik-MNIST	38.4	35.7	63.9
Physik-Speed	63.0	58.2	61.2
Physik-MNIST-Speed	29.2	27.3	63.7

Tabelle 4.2: Testen auf EMNIST Datenset — 2000 Tests

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
Grund-Basis	86.8	74.5	38.2
Grund-MNIST	65.2	45.0	57.4
Grund-Speed	87.8	77.0	37.7
Grund-MNIST-Speed	62.2	40.0	60.9
Physik-Basis	57.6	32.4	63.5
Physik-MNIST	43.3	23.6	63.9
Physik-Speed	56.3	35.0	63.6
Physik-MNIST-Speed	30.2	13.9	64.0

Tabelle 4.3: Testen auf QuickDraw-Datenset — 2000 Tests

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
Grund-Basis	79.1	80.5	39.1
Grund-MNIST	57.3	62.5	59.9
Grund-Speed	79.5	82.2	40.0
Grund-MNIST-Speed	54.9	58.9	62.5
Physik-Basis	48.1	55.7	63.8
Physik-MNIST	30.5	38.9	64.0
Physik-Speed	50.0	58.3	63.6
Physik-MNIST-Speed	22.4	31.1	64.0

4.2 Bildersammlung

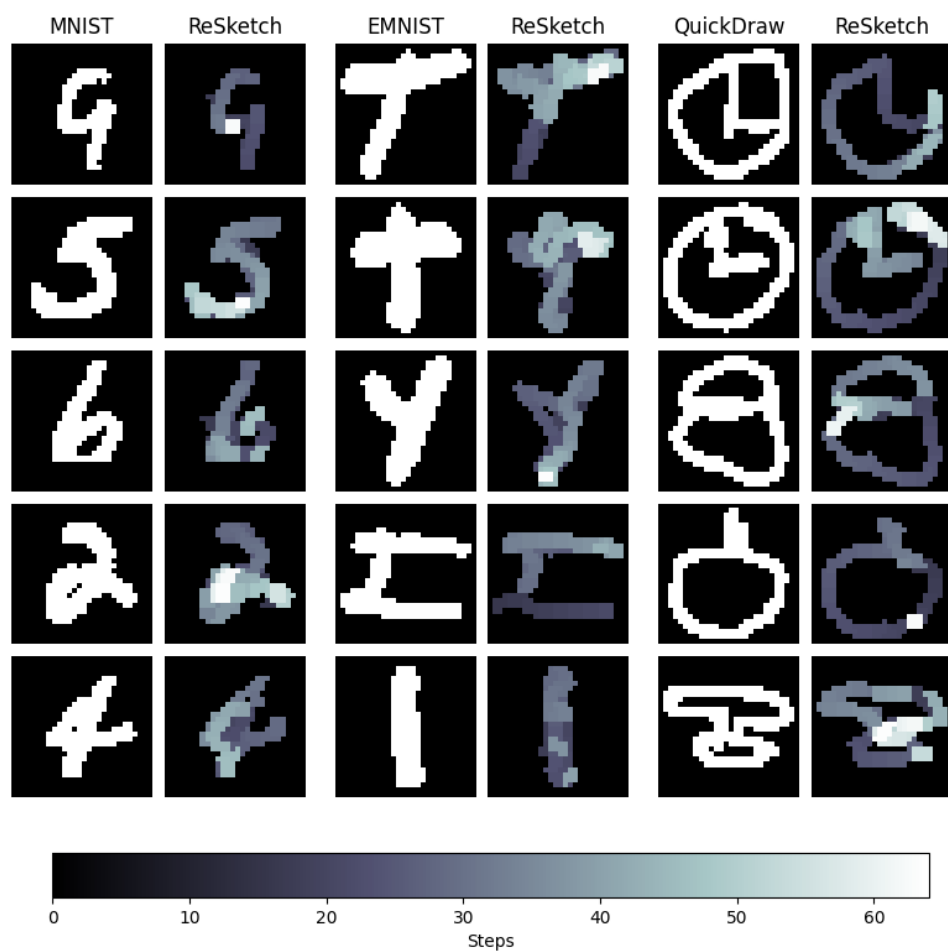


Abbildung 4.1: Grund-Basis

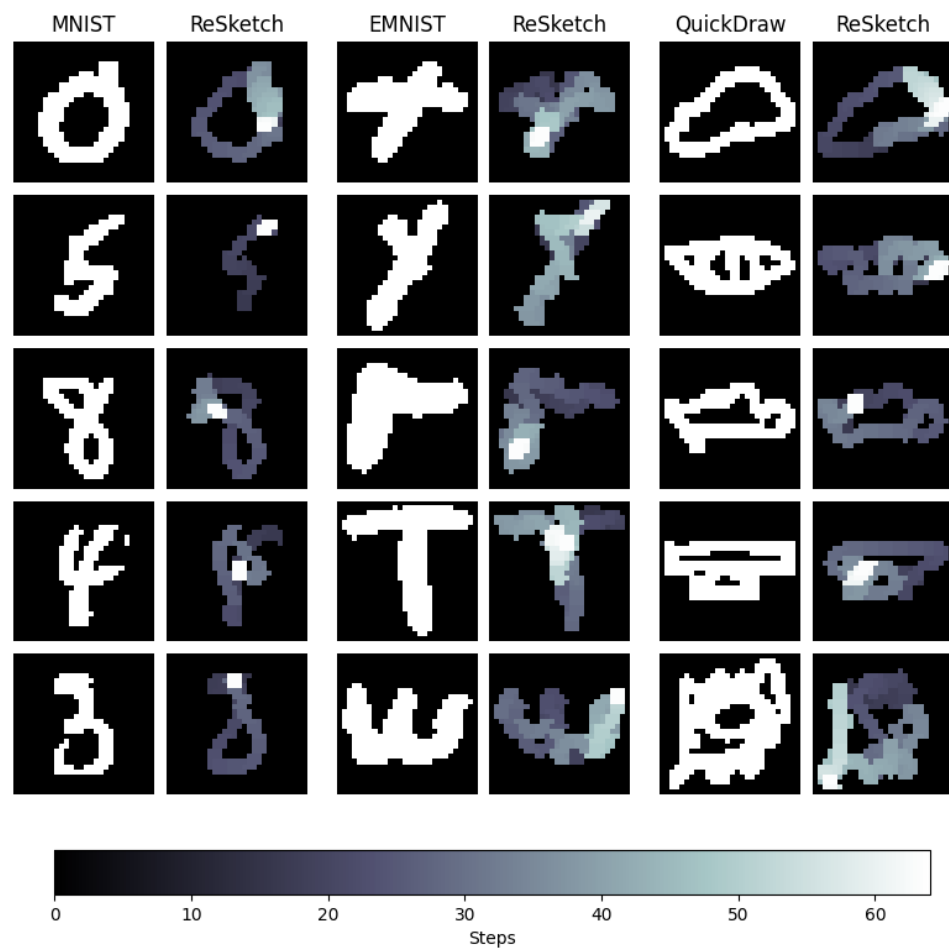


Abbildung 4.2: Grund-MNIST




Abbildung 4.3: Physik-Basis




Abbildung 4.4: Physik-Speed

Kapitel 5

Diskussion

Die Diskussion analysiert die Resultate der Methode (siehe Methode), um daraus eine Antwort auf die Fragestellung zu bilden. Zu diesem Zweck werden einige allgemeine Feststellungen getroffen und die Unterfragen beantworten (siehe 5.1 Fragestellung und Unterfragen). Im zweiten Teil der Diskussion folgt ein Fazit, ein Ausblick (siehe Fazit und Ausblick), und eine Selbstreflexion (siehe Selbstreflexion). Dabei verschiebt sich der Fokus von der Fragestellung weg und auf eine allgemeinere Betrachtung der Arbeit.

5.1 Fragestellung und Unterfragen

Die Fragestellung und die Unterfragen decken nicht alle Erkenntnisse aus den Resultaten ab. Einige allgemeine Feststellungen geben Einblick, wie die Resultate (siehe Resultate) zu verstehen sind.

Die Grund-Basis Version und die Grund-Speed Version (siehe Auswertung) erreichen in allen Kriterien für alle Datensets die beste Leistung. Die Resultate zwischen den Versionen sind dabei fast ununterscheidbar. Vor allem im Kriterium der Geschwindigkeit (siehe Geschwindigkeit) zeigt die Speed Variation keine Verbesserung. Unter den Versionen, die auf der physikalischen Umgebung basieren, erreichen Ebenfalls die Physik-Basis und die Physik-Speed Versionen die beste Leistung. Die Grund-MNIST Version und die Physik-MNIST Version sind in allen Kriterien schlechter als die Basis und Speed Versionen. Auch im Kriterium der Erkennbarkeit (siehe Erkennbarkeit) bringt die Variation keinen Vorteil. Die Physik-MNIST-Speed Version erbringt die schlechteste Leistung. Eine Erklärung dafür ist, dass diese Version eine Kombination von allen Variationen (siehe Variationen) ist und somit von der besten Version, der Grund-Basis Version am stärksten abweicht.

Die Bildersammlung (siehe Bildersammlung) zeigt, dass die KI in vielen

Fällen präzise der Linie folgt und selten willkürliche Sprünge begeht. Das ist interessant, weil der KI nie explizit mitgeteilt wird, wie genau sie zeichnen sollte.

5.1.1 Beantwortung der Unterfragen

Insgesamt sechs Unterfragen werden beantwortet (siehe Einleitung). Diese Unterfragen weiten die Fragestellung aus und tragen zu der schlussendlichen Antwort auf die Fragestellung bei. Die Antworten beruhen auf den Resultaten, aber auch auf Erkenntnissen aus der Methode (siehe Methode) selbst.

Wie kann die Architektur einer KI aussehen, die das Nachzeichnen erlernt?

Unter der Annahme, dass die KI dieser Arbeit das Nachzeichnen erlernt, (siehe Beantwortung der Fragestellung), kann die Architektur genau so aussehen, wie sie in dieser Arbeit beschrieben ist (siehe Doodle-SDQ als Basis).

Wie lässt sich die Leistung der KI in dieser Aufgabe beurteilen?

Die Leistung der KI lässt sich durch die definierten Kriterien (siehe Evaluierung der Leistung) beurteilen. Das Kriterium Die Übereinstimmung ist ein objektiver und Absoluter Wert, und somit das Aussagekräftigste Kriterium. Ausserdem ist der maximale Wert des Kriteriums, unabhängig vom gezeichneten Bild, gleich 1. Dadurch ist das Kriterium geeignet für Vergleiche zwischen Versionen der KI.

die Kriterien der Erkennbarkeit und der Geschwindigkeit sind an subjektive Annahmen gebunden. Zum Beispiel wird für das Kriterium der Geschwindigkeit ein subjektiver Punkt der Fertigstellung definiert (siehe Geschwindigkeit). Dadurch sinkt ihre Aussagekraft. Allerdings verändern sich die Annahmen nicht und die Kriterien sind in jedem Fall durch einen Zahlenwert repräsentiert. Somit eignen sich auch diese Kriterien für Vergleiche zwischen Versionen der KI. Aus der Annahme heraus, dass für Menschen beim Nachzeichnen Erkennbarkeit wichtiger als absolute Genauigkeit ist, ergibt sich das Kriterium der Erkennbarkeit als besonders wichtiges. Aus diesem Grund ist das Kriterium in der Fragestellung (siehe Beantwortung der Fragestellung) vermerkt.

Wie lässt sich die Leistung der KI verbessern?

Bezogen auf die definierten Kriterien erreicht die Grundversion Werte, die durch die implementierten Variationen nicht oder nur marginal verbessert werden. Die Variationen der KI sind somit insgesamt ein gescheiterter Versuch der Verbesserung der Leistung. Die Grundversion erfuhr allerdings in dessen Entwicklung signifikante Verbesserungen. Die grössten

Verbesserungen stammen aus der Optimierung der Hyperparameter durch den Bayesian Optimization Algorithmus (siehe Präparierung der Daten und Optimierung). Zum Beispiel hat die Grösse des Replay Buffers einen erheblichen Effekt auf die Leistung.

Welche Einflüsse haben Physiksimulationen auf die Leistung der KI?

Bezogen auf die definierten Kriterien verschlechtert sich die Leistung der KI. Alle Versionen, die auf der Grundumgebung basieren, erzielen höhere Werte als die gleichen Versionen basierend auf der physikalischen Umgebung (siehe Physikalische Umgebung). Die physikalische Umgebung hat zum Ziel, die Bewegungen der KI realistischer zu gestalten. In diesem Bereich kann der Einfluss nicht objektiv bestimmt werden. Aus Beobachtungen der Bilder, welche in der physikalischen Umgebung gezeichnet sind (siehe Bildersammlung), gehen ebenfalls keine Erkenntnisse in diesem Bereich hervor. Die Bilder unterscheiden sich kaum von denjenigen aus der Grundumgebung.

Wie ändert sich die Leistung der KI bei Strichbildern, die sich von den Trainingsdaten unterscheiden

In allen acht Versionen bleibt die Leistung der KI zwischen den drei Datensets (siehe ??) vergleichbar. Die Tabellen ... und ... Zeigen die Leistung der Grund-Basis Version und der Physik-Basis Version in den drei definierten Kriterien, getestet auf die drei Datensets. Der Wert der Übereinstimmung zwischen dem MNIST Datenset und dem EMNIST Datenset ist beinahe identisch. Für beide Versionen ist der Wert der Übereinstimmung für das QuickDraw Datenset niedriger. Insgesamt ist die KI in diesem Kriterium jedoch kaum beeinflusst durch die Wahl des Datensets. Die Analyse der anderen zwei Kriterien führt zu einer ähnlichen Schlussfolgerung. Interessant ist, dass vor allem die Grund-Basis Version eine viel höhere Geschwindigkeit im Zeichnen von MNIST Zahlen hat, als im Zeichnen von EMNIST Buchstaben. Obwohl die Formen zu grossem Teil ähnlich sind, scheint die KI durch das spezifische Training auf MNIST Ziffern eine höhere Geschwindigkeit zu entwickeln.

Inwiefern lässt sich das Zeichnen der KI mit menschlichem Zeichnen vergleichen?

Die Antwort auf diese Frage leitet sich nicht aus den objektiven Resultaten ab, sondern basiert auf subjektiven Beobachtungen. Die Bewegungen in der Physik-Version der künstlichen Intelligenz basieren grundsätzlich auf den selben Gesetzen wie die Bewegungen in der echten Welt. Allerdings sind die Bewegungen stark vereinfacht im Vergleich zu menschlichen Bewegungen. Ausserdem ist für die künstliche Intelligenz der Druck des Stiftes nicht veränderbar. Zumindest Konzeptuell aber nähert die künstliche Intelligenz

menschliches Zeichnen, bezogen auf die physischen Einschränkungen, an. Einige menschliche Gewohnheiten sind bei der künstlichen Intelligenz allerdings nicht beobachtbar. Zum Beispiel beginnt die künstliche Intelligenz beim Zeichnen von Ziffern an zufälligen Orten, während Menschen in der Regel für jede Ziffer an der selben Stelle ansetzen einer Ziffer immer an der selben Stelle

5.1.2 Beantwortung der Fragestellung

Die Fragestellung lautet: in wiefern kann eine künstliche Intelligenz lernen, Strichbilder auf eine physische Weise nachzuzeichnen, sodass diese durch ein automatisches System erkannt werden? (siehe Einleitung) Diese Frage hat mehrere Aspekte, die teilweise bereits durch die Unterfragen (siehe Beantwortung der Unterfragen) erfasst werden. Für die schlussendliche Antwort folgt eine genauere Ausführung der Aspekte.

Die KI zeichnet durch Physiksimulationen und durch allgemeine Einschränkungen der Bewegungsfreiheit auf eine annähernd physische Weise. Das Zeichnen ist nur annähernd physisch, da alle Bewegungen simuliert und in keiner physischen Umgebung umgesetzt sind. Ausserdem sind die Simulationen nicht vollkommen realitätsgetreu (siehe 5.1.1 Welche Einflüsse haben Physiksimulationen auf die Leistung der KI?)

Die künstliche Intelligenz erlernt das Nachzeichnen bezogen auf die Kriterien, nach denen es definiert ist, erfolgreich. Dafür sprechen die Werte der besten Versionen für das Nachzeichnen von Ziffern, die teilweise an den Höchstwert grenzen (siehe Fragestellung und Unterfragen). Die hohen Werte im Kriterium der Erkennbarkeit bestätigen ausserdem, dass die Zeichnungen der KI in den meisten Fällen von einem automatischen System erkannt werden.

Laut der Fragestellung soll die KI das Nachzeichnen von Strichbildern erlernen. Damit ist implizit das Nachzeichnen von allen möglichen Arten von Strichbildern gemeint. Die Leistung der KI kann nicht auf alle möglichen Strichbilder überprüft werden, aber der Test mit drei verschiedenen Datensets ergibt vielversprechende Resultate (siehe Tabellen). Die KI erlernt erfolgreich das Nachzeichnen von Ziffern, Kleinbuchstaben und zehn zufälligen Motiven aus dem QuickDraw Datenset. Durch die Vielfalt im QuickDraw Datenset kann die Annahme getroffen werden, dass die KI zumindest einen grossen Teil an Strichbildern nachzeichnen kann.

Die zusammenfassende Antwort auf die Frage lautet somit: Eine künstliche Intelligenz kann das Nachzeichnen von Strichbildern auf annähernd physische Weise in dem Sinne lernen, dass die fertige Zeichnung von einem automatischen System grösstenteils erkannt wird, Die Übereinstimmung

zwischen der Vorlage und der Zeichnung gross ist und die Zeichnung nicht viel Zeit in Anspruch nimmt.

Diese Antwort bezieht sich auf die genau Frage, wie sie in der Einleitung steht. Der nächste Abschnitt beurteilt die Frage durch die Erkenntnisse aus dieser Arbeit und geht auf mögliche Erweiterungen ein.

5.2 Fazit und Ausblick

Die Resultate erlauben eine positive Antwort auf die Fragestellung. Diese Antwort setzt allerdings einige Annahmen voraus, die weiter diskutiert werden können. Die grösste Annahme bezieht sich auf die Definition des Nachzeichnens. Diese Arbeit definiert Nachzeichnen durch drei Kriterien und durch physische Rahmenbedingungen. Die Kriterien sind für eine künstliche Intelligenz sinnvoll gewählt (siehe Wie lässt sich die Leistung der KI in dieser Aufgabe beurteilen?), Allerdings wären auch andere Kriterien möglich. Nachzeichnen ist eine menschliche Tätigkeit. Dieser Menschliche Aspekt ist in den definierten Kriterien nicht enthalten.

Die physischen Rahmenbedingungen unterscheiden sich von denjenigen, die ein Mensch erfährt. Das kommt daher, dass die physischen Rahmenbedingungen für die KI lediglich simuliert sind. Das verunmöglicht eine umfassende Antwort auf die Frage, ob die künstliche Intelligenz auf eine physische Weise zeichnet. Dieses Problem könnte mit einem Roboter gelöst werden, der die künstliche Intelligenz in eine reale, physische Umgebung überführt. Der Roboter könnte somit verschiedenste Strichbilder auf einem echten Stück Papier, und somit zwangsläufig auf physische Weise nachzeichnen. Aktuell sind die Bewegungen der künstlichen Intelligenz in gewissen Belangen eingeschränkt. So ist beispielsweise die Druckstärke nicht variierbar. Ausserdem zeichnet die künstliche Intelligenz vorwiegend kleine Strichbilder. Experimente mit grösseren Konstrukten, wie ganze Wörter, wären eine mögliche Erweiterung.

Alles in allem sind eine Vielzahl an denkbaren Fragen und Ideen möglich, die auf ReSketch, der künstlichen Intelligenz hinter dieser Arbeit, basieren.

5.3 Selbstreflexion

Die Selbstreflexion gibt genauere Einblicke in die Vorgehensweise hinter dieser Arbeit. Diese Dokumentation ist grundsätzlich eine Zusammenfassung der wichtigsten Ereignisse. Viele Aspekte, wie auch die Arbeitsweise bleiben verschwiegen. Die selbstreflexion geht näher auf drei wichtige Aspekte ein, die in der zusammengefassten Dokumentation nicht genug betont sind.

Die Dokumentation ist mit Latex und spezifischer der ETH Thesis Formatvorlage [ETH template] formatiert. Ein Grossteil der Abbildungen stammt von den Autoren und ist in Adobe Illustrator [adobe ill] oder der Python Library Matplotlib [matplotlib] erstellt

5.3.1 Optimierung der KI

Insgesamt sind acht Versionen der KI präsentiert. Im Verlaufe des Projektes gab es viele weitere Versuche, die Leistung der künstlichen Intelligenz zu verbessern. Diese Versuche führten allerdings häufig dazu, dass die KI den akkumulierten Reward (siehe Aufbau und Funktionsweise) nicht mehr maximieren konnte. In der Dokumentation sind deswegen nur diejenigen Versuche vermerkt, die tatsächlich funktionieren. Das Problem hinter den versuchten Variation liegt darin, dass die Ursache hinter ihrem Scheitern oder ihrem Erfolg häufig nicht erkennbar ist. Das macht die Optimierung der künstlichen Intelligenz allgemein schwierig.

Die Strategie hinter der Optimierung besteht in den meisten Fällen aus wiederholtem Ausprobieren mit Anpassungen zwischen jedem Versuch. Hilfsmittel, wie der Baysian Optimization Algorithmus (siehe Hyperparameter), vereinfachen diese Aufgabe massgeblich. Tatsächlich ermöglichte der Baysian Optimization Algorithmus eine Verbesserung der KI von ungefähr 40 – 50% mehr im Kriterium der Übereinstimmung (siehe Prozentuale Übereinstimmung). Diese Strategie der Optimierung ist für einen Computer sehr ressourcenintensiv. In den längsten Optimierungsarbeiten liefen die beiden Computer, auf denen die Arbeit verrichtet wurde, zusammen länger als 48 Stunden.

5.3.2 Analyse der künstlichen Intelligenz

Eine Analyse der künstlichen Intelligenz ist notwendig, um die Fragestellung und die Unterfragen zu beantworten. Aber auch während der Entwicklung der KI ist eine stetige Analyse nötig, um diese zu verstehen und zu verbessern.

Die Analyse besteht hauptsächlich darin, die Leistung der künstlichen Intelligenz zu beurteilen. Das geschieht mittels den Kriterien, die für diesen Zweck definiert sind (siehe Evaluierung der Leistung). Die Kriterien sind dabei so definiert, dass sie für jede mögliche Variation identisch bleiben. Der durchschnittliche akkumulierte Reward ist beispielsweise absichtlich kein Kriterium. Der akkumulierte Reward ist abhängig von der Reward-Function (siehe Aufbau und Funktionsweise) und unterscheidet sich somit zwischen Variationen. Dieser ist somit nicht für einen Vergleich zwischen Variationen geeignet.

Einzelne Variationen vergleichbar zu halten, ist ein allgemeines Ziel der Analyse. Deswegen basieren alle Variationen auf der gleichen Architektur

der KI. Die Funktionalität des Grundprogrammes (siehe Grundprogramm) ist gründlich getestet. Zum Beispiel sind die Testdaten darauf überprüft, dass sie keine Datenpunkte aus den Trainingsdaten beinhalten. Diese Tests eliminieren mögliche Fehlerquellen falls die künstliche Intelligenz unerwartetes Verhalten aufzeigt.

Eine weitere Form von Analyse stammt aus der Sammlung von Daten über das Lernverhalten der KI. So wird aus jedem Training ein Graph erstellt, der die durchschnittliche Leistung der KI in jeder Episode erfasst (siehe autoreflernkurve). Die Leistung ist dabei durch den akkumulierten Reward in jeder Episode repräsentiert. Wie erwähnt können Versionen der KI nicht anhand ihres akkumulierten Rewards verglichen werden. Der akkumulierte Reward zeigt allerdings für einzelne Versionen am präzisesten, in wiefern diese ihren Reward maximieren können.

5.3.3 Verwendung von Git und GitHub

Die Verwendung von Git und Github (siehe Git und GitHub) erleichtert die Arbeit an einem Projekt von diesem Ausmass sehr. Die Programme ermöglichen einfache Zusammenarbeit am Programmcode und an der Dokumentation. GitHub dient dabei zusätzlich als Hilfsmittel zur Organisation durch die integrierte Funktion der Project Boards. Diese Funktion hätte allerdings zu grösserem Ausmass Verwendung finden können.

Die Funktion der Branches und Commits von Git werden durch die Arbeit hindurch konsequent verwendet. Dabei wird die Giflow Arbeitsweise, abgesehen von den Release Branches und den Hotfix Branches, angewendet (siehe Git) Neben den Feature Branches werden ausserdem Dokumentation Branches eingeführt, in denen jeweils ein Kapitel der Dokumentation verfasst wird. Für die Zusammenführungen der wichtigsten Branches wird das Prinzip der Pull Request (siehe GitHub) angewendet. Die Pull Request muss für jeden Branch von beiden Autoren akzeptiert werden.

Ein weiterer Vorteil von Git und Github ist die Zugänglichkeit des Projektes. Das gesamte Projekt ist unter folgendem Link einsehbar: <https://github.com/LarsZauberer/Nachzeichner-KI>. Im Projektordner sind vortrainierte Variationen der künstlichen Intelligenz enthalten. Das Projekt auf GitHub erfährt möglicherweise Erweiterungen, die in dieser Arbeit nicht mehr erfasst sind.

Kapitel 6

Zusammenfassung

Diese Untersuchung beantwortet die Frage, inwiefern eine künstliche Intelligenz Strichbilder auf eine physische Weise nachzeichnen kann, sodass diese durch ein automatisches System erkannt werden. Mit Strichbildern sind in diesem Fall Ziffern aus dem MNIST Datenset, Buchstaben aus dem EMNIST Datenset und weitere Motive aus dem QuickDraw Datenset gemeint.

Zur Beantwortung der Fragestellung wird der Begriff des Nachzeichnes definiert. Dazu gehören die Rahmenbedingungen, nach denen eine Tätigkeit als Nachzeichnen gilt, und die Kriterien, die die Leistung im Nachzeichnen beurteilen. Zu den Rahmenbedingungen gehören unter anderem die physischen Einschränkungen und die ausführbaren Aktionen der KI. Um die Leistung der KI im Nachzeichnen zu bewerten, sind drei Kriterien definiert: Die Übereinstimmung der Pixel, die Erkennbarkeit der Zeichnung und die Geschwindigkeit des Zeichnens. Die Erkennbarkeit der Zeichnung wird durch eine zweite künstliche Intelligenz ermittelt.

Das Ziel ist es, eine künstliche Intelligenz zu entwickeln, welche die gesetzten Rahmenbedingungen erfüllt und eine möglichst gute Leistung nach den definierten Kriterien erzielt. Bei der Grundsätzlichen Architektur des KI handelt es sich um ein Deep Q-Learning Modell, das auf der Arbeit hinter 'Doodle-SDQ' basiert.

Für die Rahmenbedingungen gibt es zwei Ansätze: eine Grundversion und eine physikalische Version. In der Grundversion kann sich die KI schrittweise um eine begrenzte Anzahl Pixel auf einer Zeichenfläche fortbewegen. Ausserdem startet die KI auf einer zufälligen Position auf der Zeichenfläche. Die physikalische Version ist von simulierter Physik begleitet. So kann die KI durch Beschleunigungen ihre aktuelle Geschwindigkeit anpassen und sich so fortbewegen, während diese durch simulierte Reibung kontinuierlich abgebremst wird.

Für die KI existieren weitere Variationen, die dessen Leistung nach einem bestimmten Kriterium verbessern sollen. So existiert ein spezifisches Training auf eine verbesserte Erkennbarkeit und Geschwindigkeit der KI. Durch Kombinationen der Variationen und der Rahmenbedingungen existieren schlussendlich acht Versionen der künstlichen Intelligenz.

Die acht Versionen der künstlichen Intelligenz sind alle auf das Nachzeichnen von Ziffern trainiert. Ein Experiment bestimmt, ob diese Versionen das Nachzeichnen allgemein erlernen. Die Leistung der Versionen wird auf das Nachzeichnen von Strichbildern aus dem Quickdraw und dem EMNIST Datenset gemessen. Wenn die Leistung für diese Strichbilder vergleichbar bleibt mit der Leistung für die Trainingsdaten, ermöglicht das eine positive Antwort für die Fragestellung.

Einge Versionen der künstlichen Intelligenz zeigen hierbei vielversprechende Ergebnisse. Die Grundversion, ohne weitere Variationen, zeichnet in 91% der Fälle eine erkennbare Ziffer, in 70% der Fälle einen erkennbaren Buchstaben, und in 72% der Fälle ein erkennbares Motiv aus dem QuickDraw Datenset.

Literatur

- [1] *What is Artificial Intelligence (AI)? — Glossary*. URL: <https://www.hpe.com/ch/de/what-is/artificial-intelligence.html> (besucht am 21.06.2022).
- [2] *What is Machine Learning? — Glossary*. URL: <https://www.hpe.com/ch/de/what-is/machine-learning.html> (besucht am 21.06.2022).
- [3] Norman W. Spaulding. “Is Human Judgment Necessary? Artificial Intelligence, Algorithmic Governance, and the Law”. In: *The Oxford Handbook of Ethics of AI*. Hrsg. von Markus D. Dubber, Frank Pasquale und Sunit Das. Oxford University Press, 9. Juli 2020, S. 0. ISBN: 978-0-19-006739-7. DOI: [10.1093/oxfordhb/9780190067397.013.25](https://doi.org/10.1093/oxfordhb/9780190067397.013.25). URL: <https://doi.org/10.1093/oxfordhb/9780190067397.013.25> (besucht am 16.09.2022).
- [4] *Was ist Supervised Learning (Überwachtes Lernen)?* datasolut GmbH. URL: <https://datasolut.com/wiki/supervised-learning/> (besucht am 16.09.2022).
- [5] Surbhi Arora. *Supervised vs Unsupervised vs Reinforcement*. AITUDE. 29. Jan. 2020. URL: <https://www.aitude.com/supervised-vs-unsupervised-vs-reinforcement/> (besucht am 25.06.2022).
- [6] Sadie Bennett. *Why machine learning is primarily written in Python*. IBM Developer. 10. Juni 2019. URL: <https://developer.ibm.com/blogs/why-machine-learning-is-primarily-written-in-python/> (besucht am 02.10.2022).
- [7] *TensorFlow*. URL: <https://www.tensorflow.org/> (besucht am 02.10.2022).
- [8] *MNIST handwritten digit database*, Yann LeCun, Corinna Cortes and Chris Burges. URL: <http://yann.lecun.com/exdb/mnist/> (besucht am 16.09.2022).

- [9] "The EMNIST Dataset". In: *NIST* (4. Apr. 2017). Last Modified: 2019-03-28T09:45-04:00. URL: <https://www.nist.gov/itl/products-and-services/emnist-dataset> (besucht am 16.09.2022).
- [10] *Training and Test Sets: Splitting Data — Machine Learning*. Google Developers. URL: <https://developers.google.com/machine-learning/crash-course/training-and-test-sets/splitting-data> (besucht am 16.09.2022).
- [11] Kizito Nyuytiyumbiy. *Parameters and Hyperparameters in Machine Learning and Deep Learning*. Medium. 28. März 2022. URL: <https://towardsdatascience.com/parameters-and-hyperparameters-aa609601a9ac> (besucht am 16.09.2022).
- [12] Apoorv Agnihotri und Nipun Batra. "Exploring Bayesian Optimization". In: *Distill* 5.5 (5. Mai 2020), e26. ISSN: 2476-0757. DOI: [10.23915/distill.00026](https://doi.org/10.23915/distill.00026). URL: <https://distill.pub/2020/bayesian-optimization> (besucht am 02.10.2022).
- [13] paretos. *Bayesian Optimization (Bayes Opt): Easy explanation of popular hyperparameter tuning method*. 25. Jan. 2021. URL: <https://www.youtube.com/watch?v=M-NTkxfd7-8> (besucht am 22.09.2022).
- [14] Roman Garnett. *Bayesian Optimization Book*. Bayesian Optimization Book. URL: <https://bayesoptbook.com/> (besucht am 02.10.2022).
- [15] *Black Box (Systemtheorie)*. In: *Wikipedia*. Page Version ID: 215860839. 24. Sep. 2021. URL: [https://de.wikipedia.org/w/index.php?title=Black_Box_\(Systemtheorie\)&oldid=215860839](https://de.wikipedia.org/w/index.php?title=Black_Box_(Systemtheorie)&oldid=215860839) (besucht am 02.10.2022).
- [16] Bruce Robbins. *MACHINE LEARNING: How Black is This Beautiful Black Box*. Medium. 14. Juli 2017. URL: <https://towardsdatascience.com/machine-learning-how-black-is-this-black-box-f11e4031fdf> (besucht am 02.10.2022).
- [17] Riccardo Moriconi, Marc P. Deisenroth und K. S. Sesh Kumar. *High-dimensional Bayesian optimization using low-dimensional feature spaces*. 25. Sep. 2020. DOI: [10.48550/arXiv.1902.10675](https://doi.org/10.48550/arXiv.1902.10675). arXiv: [1902.10675\[cs, stat\]](https://arxiv.org/abs/1902.10675). URL: <http://arxiv.org/abs/1902.10675> (besucht am 02.10.2022).
- [18] *Neuronales Netz*. In: *Wikipedia*. Page Version ID: 210963657. 15. Apr. 2021. URL: https://de.wikipedia.org/w/index.php?title=Neuronales_Netz&oldid=210963657 (besucht am 16.09.2022).
- [19] *Artificial Neural Network Tutorial - Javatpoint*. www.javatpoint.com. URL: <https://www.javatpoint.com/artificial-neural-network> (besucht am 16.09.2022).

- [20] Rukshan Pramoditha. *The Concept of Artificial Neurons (Perceptrons) in Neural Networks*. Medium. 29. Dez. 2021. URL: <https://towardsdatascience.com/the-concept-of-artificial-neurons-perceptrons-in-neural-networks-fab22249cbfc> (besucht am 01.10.2022).
- [21] Michael A. Nielsen. "Neural Networks and Deep Learning". In: (2015). Publisher: Determination Press. URL: <http://neuralnetworksanddeeplearning.com> (besucht am 22.04.2022).
- [22] Simplilearn. *What is Perceptron: A Beginners Guide for Perceptron [Updated]*. Simplilearn.com. 26. Mai 2021. URL: <https://www.simplilearn.com/tutorials/deep-learning-tutorial/perceptron> (besucht am 16.09.2022).
- [23] Pragati Baheti. *Activation Functions in Neural Networks [12 Types & Use Cases]*. 19. Juli 2022. URL: <https://www.v7labs.com/blog/neural-networks-activation-functions,%20https://www.v7labs.com/blog/neural-networks-activation-functions> (besucht am 16.09.2022).
- [24] Niranjan Kumar. *Sigmoid Neuron — Deep Neural Networks*. Medium. 18. Dez. 2019. URL: <https://towardsdatascience.com/sigmoid-neuron-deep-neural-networks-a4cd35b629d7> (besucht am 16.09.2022).
- [25] Gavril Ognjanovski. *Everything you need to know about Neural Networks and Backpropagation — Machine Learning Made Easy...* Medium. 7. Juni 2020. URL: <https://towardsdatascience.com/everything-you-need-to-know-about-neural-networks-and-backpropagation-machine-learning-made-easy-e5285bc2be3a> (besucht am 16.09.2022).
- [26] Farhad Malik. *What Are Hidden Layers?* FinTechExplained. 20. Mai 2019. URL: <https://medium.com/fintechexplained/what-are-hidden-layers-4f54f7328263> (besucht am 16.09.2022).
- [27] Diego Unzueta. *Convolutional Layers vs Fully Connected Layers*. Medium. 15. März 2022. URL: <https://towardsdatascience.com/convolutional-layers-vs-fully-connected-layers-364f05ab460b> (besucht am 16.09.2022).
- [28] Adit Deshpande. *A Beginner's Guide To Understanding Convolutional Neural Networks Part 2*. URL: <https://adeshpande3.github.io/A-Beginner's-Guide-To-Understanding-Convolutional-Neural-Networks-Part-2/> (besucht am 28.04.2022).

- [29] Kavinda Jayawardana. *Concatenating Multiple Activation Functions and Multiple Poling Layers for Deep Neural Networks*. Medium. 3. Jan. 2021. URL: <https://towardsdatascience.com/concatenating-multiple-activation-functions-and-multiple-poling-layers-for-deep-neural-networks-d48a4b273d30> (besucht am 16.09.2022).
- [30] David E. Rumelhart, Geoffrey E. Hinton und Ronald J. Williams. *Learning representations by back-propagating errors*. URL: https://www.uro.umontreal.ca/~vincentp/ift3395/lectures/backprop_old.pdf (besucht am 16.09.2022).
- [31] Błażej Osipiński und Konrad Budek. *What is reinforcement learning? The complete guide*. deepsense.ai. Section: Deep learning. 5. Juli 2018. URL: <https://deepsense.ai/what-is-reinforcement-learning-the-complete-guide/> (besucht am 16.09.2022).
- [32] Piyush Verma und Stelios Diamantidis. *What is Reinforcement Learning? – Overview of How it Works — Synopsys*. 27. Apr. 2021. URL: <https://www.synopsys.com/ai/what-is-reinforcement-learning.html> (besucht am 16.09.2022).
- [33] Richard S Sutton und Andrew G Barto. "Reinforcement Learning: An Introduction". In: *MIT Press* (2014), S. 352.
- [34] Volodymyr Mnih u.a. "Playing Atari with Deep Reinforcement Learning". In: (), S. 9.
- [35] Mike Wang. *Deep Q-Learning Tutorial: minDQN*. Medium. 3. Okt. 2021. URL: <https://towardsdatascience.com/deep-q-learning-tutorial-mindqn-2a4c855abffc> (besucht am 15.04.2022).
- [36] Rajendra Koppula. *Exploration vs. Exploitation in Reinforcement Learning*. URL: <https://www.manifold.ai/exploration-vs-exploitation-in-reinforcement-learning> (besucht am 02.10.2022).
- [37] Wouter van Heeswijk PhD. *How To Model Experience Replay, Batch Learning and Target Networks*. Medium. 30. Aug. 2021. URL: <https://towardsdatascience.com/how-to-model-experience-replay-batch-learning-and-target-networks-c1350db93172> (besucht am 16.09.2022).
- [38] Ningyuan Zheng, Yifan Jiang und Dingjiang Huang. "StrokeNet: A Neural Painting Environment". In: *International Conference on Learning Representations*. 27. Sep. 2018. URL: <https://openreview.net/forum?id=HJxwDiActX> (besucht am 31.03.2022).

-
- [39] Zhewei Huang, Shuchang Zhou und Wen Heng. “Learning to Paint With Model-Based Deep Reinforcement Learning”. In: *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, Okt. 2019, S. 8708–8717. ISBN: 978-1-72814-803-8. DOI: [10.1109/ICCV.2019.00880](https://doi.org/10.1109/ICCV.2019.00880). URL: <https://ieeexplore.ieee.org/document/9010329/> (besucht am 31.03.2022).
- [40] Tao Zhou u. a. “Learning to Doodle with Deep Q Networks and Demonstrated Strokes”. In: *arXiv:1810.05977 [cs]* (14. Okt. 2018). arXiv: [1810.05977](https://arxiv.org/abs/1810.05977). URL: <http://arxiv.org/abs/1810.05977> (besucht am 31.03.2022).
- [41] *The Quick, Draw! Dataset*. original-date: 2017-05-09T18:28:32Z. 6. Okt. 2022. URL: <https://github.com/googlecreativelab/quickdraw-dataset> (besucht am 07.10.2022).
- [42] Atlassian. *Git-flow-Workflow — Atlassian Git Tutorial*. Atlassian. URL: <https://www.atlassian.com/de/git/tutorials/comparing-workflows/gitflow-workflow> (besucht am 07.10.2022).
- [43] *Git*. In: *Wikipedia*. Page Version ID: 1062380476. 28. Dez. 2021. URL: <https://en.wikipedia.org/w/index.php?title=Git&oldid=1062380476> (besucht am 30.12.2021).
- [44] Guillermo Brachetta. *What are Git Branches? & How They Work*. Code Institute Global. 3. März 2022. URL: <https://codeinstitute.net/global/blog/git-branches/> (besucht am 01.10.2022).
- [45] *What is Git Flow — How to use Git Flow — Learn Git*. Section: Git. 17. Juni 2022. URL: <https://www.gitkraken.com/learn/git/git-flow> (besucht am 07.10.2022).
- [46] Cameron McKenzie. *Gitflow release branch process from start to finish example*. 24. Feb. 2021. URL: <https://www.theserverside.com/blog/Coffee-Talk-Java-News-Stories-and-Opinions/Gitflow-release-branch-process-start-finish> (besucht am 07.10.2022).
- [47] *GitHub*. In: *Wikipedia*. Page Version ID: 218104003. 11. Dez. 2021. URL: <https://de.wikipedia.org/w/index.php?title=GitHub&oldid=218104003> (besucht am 01.01.2022).
- [48] Atlassian. *Pull Requests — Atlassian Git Tutorial*. Atlassian. URL: <https://www.atlassian.com/de/git/tutorials/making-a-pull-request> (besucht am 01.10.2022).

Abbildungsverzeichnis

4.1	Grund-Basis	27
4.2	Grund-MNIST	28
4.3	Physik-Basis	29
4.4	Physik-Speed	30

Tabellenverzeichnis

4.1	Testen auf MNIST Datenset — 2000 Tests	26
4.2	Testen auf EMNIST Datenset — 2000 Tests	26
4.3	Testen auf QuickDraw-Datenset — 2000 Tests	26

Umgang mit Plagiaten

Was gilt als Plagiat?

Unter einem Plagiat ist die ganze oder teilweise Übernahme eines fremden Werks ohne Angabe der Quelle und des Urhebers bzw. der Urheberin zu verstehen. Das Plagiat ist eine Verletzung des Urheberrechts. Kürzere Passagen eines fremden Werkes dürfen zitiert werden. Dies setzt aber eine Kennzeichnung des Zitats und eine Angabe der Quelle voraus. Folgende Handlungen stellen ein Plagiat im weiteren Sinne dar:

- a) Die Verfasserin bzw. der Verfasser reicht ein Werk, das von einer anderen Person auf Auftrag erstellt wurde, unter ihrem bzw. seinem Namen ein.
- b) Die Verfasserin bzw. der Verfasser reicht ein fremdes Werk unter ihrem bzw. seinem Namen ein.
- c) Die Verfasserin bzw. der Verfasser übernimmt Textteile oder Aussagen von fremden Quellen, ohne die Herkunft mit einem Beleg kenntlich zu machen. Dazu gehört namentlich auch das Verwenden von Textteilen aus dem Internet ohne Quellenangabe und das Übersetzen fremdsprachiger Texte oder Teile von fremdsprachigen Texten ohne Quellenangabe.
- d) Die Verfasserin bzw. der Verfasser übernimmt Textteile oder Aussagen von fremden Quellen und nimmt leichte Textanpassungen und -umstellungen vor (Paraphrasieren), ohne die Herkunft mit einem Beleg kenntlich zu machen.

Unredlichkeiten und ihre Folgen

Beim Aufdecken von Unredlichkeiten wird je nach Ausmass unterschiedlich vorgegangen:

- Wenige vergessene Zitierangaben, fehlerhaftes Anwenden der Grundregeln des Zitierens und Ähnliches wird mit entsprechenden Punktabzügen bei der Bewertung der Arbeit sanktioniert.
- Die im Sinne von c) und d) als Plagiat identifizierten Textteile oder Aussagen werden - mit der entsprechenden Konsequenz für die Bewertung der Arbeit - nicht korrigiert. Zudem können disziplinarische Massnahmen ergriffen werden.
- Übersteigen die im Sinne von c) und d) identifizierten Textteile oder Aussagen 50% des Umfangs einer Arbeit, wird die Arbeit mit der Note 1 bewertet und hat zwingend eine disziplinarische Massnahme zur Folge. Bei den Abschlussarbeiten entfällt die mündliche Präsentation.
- Ein Plagiat im Sinne von a) und b) wird mit der Note 1 bewertet und hat zwingend eine disziplinarische Massnahme zur Folge. Bei den Abschlussarbeiten entfällt die mündliche Präsentation.

Antiplagiatserklärung

Ich erkläre hiermit, dass diese Arbeit nicht abgeschrieben, kopiert, übersetzt oder über das Internet heruntergeladen wurde, die Inhalte dieser Arbeit, auch nicht in Teilen, aus anderen Quellen übernommen worden sind, ohne dass diese korrekt ausgewiesen wurden, der Quellennachweis korrekt angebracht und vollständig aufgeführt ist und die dargestellten Daten und Resultate selber erhoben und korrekt wiedergegeben wurden.

Datum: 05.10.2022

Name: Ian Wasser Abt.: G19E Unterschrift: Ian Wasser

Name: Robin Steiner Abt.: G19E Unterschrift: RSteiner

Name: _____ Abt.: _____ Unterschrift: _____

Name: _____ Abt.: _____ Unterschrift: _____