

ReSketch AI

Maturarbeit

Ian Wasser, Robin Steiner

11. Oktober 2022

Betreut durch: Nicolas Ruh
Zweitbeurteilung: Dieter Koch

NKSA G19E

Abstract

ReSketch ist eine künstliche Intelligenz, die versucht, Strichbilder auf eine physische Weise nachzuzeichnen. Strichbilder sind in diesem Fall beispielsweise Ziffern oder Buchstaben. Um die Frage zu beantworten, inwiefern das möglich ist, sind definierende Kriterien des Nachzeichnens festgelegt. So soll die künstliche Intelligenz zum Beispiel nur Bewegungen ausführen können, die auch mit einem Stift möglich wären. Die künstliche Intelligenz erlernt das Nachzeichnen nach diesen Kriterien durch Deep Q-Learning, einem Reinforcement Learning Modell. Das Modell basiert auf der Arbeit hinter Doodle-SDQ (Zhou et al., 2018), erfährt aber konzeptuelle Variationen, wie die Integration einer Physiksimulation. Die künstliche Intelligenz ist auf das Nachzeichnen von Ziffern trainiert. Ein Test dieser trainierten künstlichen Intelligenz auf Buchstaben und andere Arten von Strichbildern führt zur Antwort auf die Frage, ob eine künstliche Intelligenz das Nachzeichnen im Allgemeinen erlernen kann.

Vorwort

Diese Arbeit ist eine Untersuchung im Bereich der künstlichen Intelligenz. Die Fragestellung der Untersuchung wird mithilfe einer selbst programmierten künstlichen Intelligenz beantwortet.

Wir haben uns für das Thema künstliche Intelligenz entschieden, weil damit praktische Arbeit mit intellektueller Forschung verbunden werden kann. Das Thema ermöglicht ausgeprägte, praktische Programmierarbeiten, was uns zuspricht. Zusätzlich ermöglicht künstliche Intelligenz einfache Forschung. Mit einfacher Forschung ist dabei nicht der Grad der Komplexität gemeint, sondern die Vielfalt der Möglichkeiten. Es gibt Aspekte und Anwendungen der künstlichen Intelligenz, die für Schüler zugänglich sind und noch nicht zu weit erforscht sind, um neue Ideen zu finden. Ausserdem benötigt die Forschung an künstlicher Intelligenz nur einen Computer. Experimente und Tests können durch Programmcode ausgeführt werden. Die Auswertung der Experimente findet auf demselben Computer statt und die Genauigkeit der Ergebnisse stellt ebenfalls kein Problem dar, da der Computer die Zahlen direkt berechnet. Der Computer ist eine optimale Umgebung für eine erste Forschungsarbeit.

Diese Arbeit ist für uns eine erste vertiefte Erfahrung mit dem Gebiet der künstlichen Intelligenz. Wir erhoffen uns durch diese Erfahrung einen erweiterten Horizont, neues Wissen und verbesserte Programmierkenntnisse.

Vielen Dank an unseren Betreuer, Dr. Nicolas Ruh, für die hilfreichen Vorschläge, die ausgeprägte Beratung und das Vertrauen in uns. Vielen Dank auch an Dieter Koch für die Zweitbeurteilung und an Günther Wasser für das Korrekturlesen dieser Arbeit.

Inhaltsverzeichnis

1	Einleitung	1
2	Theoretische Grundlagen	3
2.1	Machine Learning	3
2.1.1	Funktionsweise eines Machine Learning Modelles . .	4
2.1.2	Künstliche neuronale Netze	5
2.1.3	Hyperparameter	10
2.2	Reinforcement Learning	11
2.2.1	Funktionsweise von Reinforcement Learning	12
2.3	Verwandte Arbeiten und Themen	14
2.3.1	Doodle-SDQ	14
3	Methode	17
3.1	Grundprogramm	17
3.1.1	Doodle-SDQ als Basis	17
3.1.2	Präparierung der Daten und Optimierung	20
3.2	Evaluation der Leistung	21
3.2.1	Erkennbarkeit	21
3.2.2	Prozentuale Übereinstimmung	21
3.2.3	Geschwindigkeit	22
3.3	Variationen	22
3.3.1	Basis Reward-Function	23
3.3.2	Training auf Geschwindigkeit	23
3.3.3	Training auf Erkennbarkeit	24
3.3.4	Physikalische Umgebung	26
3.4	Auswertung	29
3.4.1	Testumgebung	30
4	Resultate	31
4.1	Tabellen	32

4.2	Bildersammlung	33
5	Diskussion	37
5.1	Fragestellung und Unterfragen	37
5.1.1	Beantwortung der Unterfragen	38
5.1.2	Beantwortung der Fragestellung	40
5.2	Fazit und Ausblick	41
5.3	Selbstreflexion	42
5.3.1	Optimierung der KI	42
5.3.2	Analyse der KI	43
5.3.3	Verwendung von Git und GitHub	44
6	Zusammenfassung	47
	Literatur	49

Kapitel 1

Einleitung

Der Computer ist ein Werkzeug, das dem Menschen Arbeit abnehmen kann. Um komplizierte Aufgaben zu übernehmen, muss sich der Computer jedoch an menschliches Verhalten, menschliches Urteilsvermögen und an menschliche Intelligenz annähern. Somit benötigt der Computer oder das steuernde Computerprogramm eine künstliche Intelligenz. Die Entwicklung eines intelligenten Computerprogrammes birgt verschiedene Herausforderung. Der fähigste und am weitesten verbreitete Ansatz an diese Herausforderungen liefert Machine Learning. Diese Arbeit ist eine Untersuchung Im Bereich Machine Learning. Spezifischer befindet sich die Arbeit im Bereich Reinforcement Learning, einem Teilgebiet von Machine Learning.

Die Fragestellung der Untersuchung lautet: Inwiefern kann eine künstliche Intelligenz lernen, Strichbilder auf eine physische Weise nachzuzeichnen, sodass diese durch ein automatisches System richtig erkannt werden?

Für ein gegebenes Strichbild soll die künstliche Intelligenz (KI) erlernen, ein möglichst gleiches Bild daneben zeichnen zu können. Die Frage ist, ob die KI das Nachzeichnen genug gut lernen kann, damit die Zeichnung von einem automatischen System richtig erkannt wird. Richtig erkannt heisst grundsätzlich, dass eine zweite KI (ein automatisches System) in der Zeichnung dasselbe Motiv wie in der Vorlage erkennt. Wenn das zutrifft, kann die künstliche Intelligenz erfolgreich nachzeichnen. Es existieren allerdings weitere Kriterien, die die Leistung der KI bei der Tätigkeit des Nachzeichnens beurteilen.

Nachzeichnen ist eine menschliche Tätigkeit. Menschen führen beim Zeichnen durch gewisse Handbewegungen einen Stift, wodurch das Nachzeichnen mit physischen Einschränkungen verbunden ist. Der Stift teleportiert sich nicht, sondern bewegt sich mit einer limitierten Geschwindigkeit. Die KI soll das Nachzeichnen mit ähnlichen physischen

Einschränkungen erlernen. Das heisst, die KI soll lernen, einen Stift zu führen. Die physischen Einschränkungen sind für die KI jedoch simuliert und im Vergleich zu der echten Welt vereinfacht.

Die KI soll das Nachzeichnen von Strichbildern allgemein erlernen. Strichbilder können Ziffern, Buchstaben, Formen, Symbole und allgemeine Kritzeleien sein. Die KI soll diese verschiedenen Motive vergleichbar gut nachzeichnen

Mit den vorangehenden Ausführungen sowie durch die Weiterführung der Arbeit werden folgende Unterfragen behandelt:

- Wie kann die Architektur einer KI aussehen, die das Nachzeichnen erlernt?
- Wie lässt sich die Leistung der KI in ihrer Aufgabe beurteilen?
- Wie lässt sich die Leistung der KI in ihrer Aufgabe verbessern?
- Wie ändert sich die Leistung der KI für Strichbilder, die im Training nicht enthalten sind?
- Wie und inwiefern lässt sich das Verhalten der KI mit menschlichem Zeichnen vergleichen?
- Kann die KI Zahlen ohne Vorlage nachzeichnen?

Kapitel 2

Theoretische Grundlagen

Dieses Kapitel führt die Konzepte ein, die über die ganze Arbeit hinweg Anwendung finden. Auch die verwendeten Fachbegriffe werden in diesem Kapitel eingeführt. Es handelt sich dabei um Zusammenfassungen. Die Theorie wird auf den Teil reduziert, der für ein grundsätzliches Verständnis der Arbeit nötig ist. Weitere Informationen sind in den referenzierten Quellen einsehbar.

2.1 Machine Learning

Machine Learning ist ein Teilbereich der künstlichen Intelligenz. “Künstliche Intelligenz (KI) bezieht sich im Allgemeinen auf jedes menschenähnliche Verhalten durch eine Maschine oder ein System” („What is Artificial Intelligence (AI)?“, n.d.) Mit Maschinen und Systemen sind in den allermeisten Fällen Computer, beziehungsweise die steuernden Computerprogramme gemeint. Diese Computerprogramme bilden ein Modell von menschlichem Verhalten. Machine Learning Modelle entwickeln (oder erlernen) eine Mustererkennung durch die Analyse von Daten („What is Machine Learning?“, n.d.). Mustererkennung bedeutet hier, dass der Algorithmus Zusammenhänge zwischen den analysierten Daten erkennt und auf dieser Basis Vorhersagen treffen kann. Vereinfacht gesagt, versucht ein Machine Learning Modell menschliches Urteilsvermögen zu erlernen (Spaulding, 2020).

Ein Beispielproblem für ein Machine Learning Modell ist die Erkennung von handgeschriebenen Ziffern. Ein Computerprogramm soll durch den Input eines Bildes mit einer handgeschriebenen Ziffer eine korrekte Beurteilung treffen, um welche Ziffer es sich handelt. Das heisst, der Output des Computerprogramms soll der Ziffer entsprechen, die auf dem Bild des Inputs zu sehen ist (siehe Abbildung 2.1). Jedes Computerprogramm, das dieses Problem löst, fällt in den Bereich der künstlichen Intelligenz. Machine

Learning Modelle geben einen Ansatz für die Umsetzung eines solchen Computerprogramms.



Abbildung 2.1: Erkennung von handgeschriebenen Zahlen durch ein Machine Learning Modell. (eigene Abbildung)

Machine Learning Modelle, die das Beispielproblem lösen, basieren üblicherweise auf Supervised Learning. Das ist ein Teilbereich von Machine Learning, wobei das Machine Learning Modell aus Rückmeldungen der korrekten Beurteilung, der Zielvariable, als Reaktion auf ihre eigenen Beurteilungen lernt (Laurenz Wuttke, 2021). Die Zielvariable muss dabei im Voraus für jeden Datenpunkt in den analysierten Daten durch einen Menschen festgelegt sein (Trahasch et al., 2020). Das heißt, ausgedrückt durch den Fachbegriff, dass die Daten labeled sein müssen (Luis G. Serrano, 2021). Weitere Teilbereiche von Machine Learning sind Unsupervised Learning und Reinforcement Learning (Arora, 2020). Siehe Abschnitt 2.2 für eine tiefgreifendere Einführung in Reinforcement Learning.

Machine Learning Modelle sind hauptsächlich in der Programmiersprache Python implementiert (Sadie Bennett, 2019). Tensorflow und Keras sind bekannte Machine Learning Frameworks für Python. Als Framework stellen diese beiden Hilfsmittel fertige Funktionen und Algorithmen bereit, die für die Entwicklung von Machine Learning Modellen nötig sind („TensorFlow“, 2015)(„Keras: the Python deep learning API“, 2015).

2.1.1 Funktionsweise eines Machine Learning Modelles

Dieser Abschnitt erklärt die Funktionsweise eines Machine Learning Modells, basierend auf dem Beispielproblem aus dem letzten Abschnitt (siehe 2.1 Machine Learning).

Bei den Daten, die das Machine Learning Modell analysiert, handelt es sich in diesem Fall um das MNIST Datenset (Yann LeCun et al., n.d.). Dieses Datenset wurde 1998 vom NIST (National Institute of Standards and Technology) in den USA veröffentlicht und beinhaltet 70'000 Bilder von

handgeschriebenen Ziffern (Yann LeCun, n. d.). Jedes Bild hat eine Auflösung von 28×28 Pixeln (siehe Abbildung 2.2 für Beispiele).



Abbildung 2.2: Beispiele aus dem MNIST Datenset. (Eigene Abbildung)

Ein Machine Learning Modell durchläuft ein Training gefolgt von einer Testphase („Training and Test Sets“, n. d.). Während dem Training erlernt das Modell die Mustererkennung, um verlässliche Aussagen zu den Daten des Inputs zu treffen. Die Testphase misst die Genauigkeit des Modells, also die Wahrscheinlichkeit, mit der das Modell die richtige Lösung zu dem Input liefert. Nur in den seltensten Fällen erreicht diese Genauigkeit 100%. Das Modell garantiert somit nicht die richtige Lösung. Das Machine Learning Modell erlernt die Mustererkennung während dem Training durch die Analyse von Trainingsdaten aus einem Datenset. Das Modell gibt zu jedem Datenpunkt die Beurteilung, um welche Zahl es sich handelt. Das Datenset ist labeled (siehe 2.1 Machine Learning). Falls die Beurteilung des Modells nicht mit der bekannten korrekten Lösung übereinstimmt, passt sich das Modell auf automatisierte Weise an. Dadurch soll die Beurteilungen für zukünftige Datenpunkte genauer werden. Die Testphase misst die Genauigkeit des Modells auf Testdaten. Die Testdaten bestehen aus Datenpunkten, die in den Trainingsdaten nicht enthalten sind.

Zusammengefasst kann ein Machine Learning Modell Daten beurteilen und sich selbst anpassen, um die Beurteilungen zu verbessern. Diese Eigenschaften sind in künstlichen neuronalen Netzen (siehe 2.1.2 Künstliche neuronale Netze) vorhanden, wodurch diese in Machine Learning Modellen Anwendung finden.

2.1.2 Künstliche neuronale Netze

Ein neuronales Netz ist, im biologischen Sinne, „eine beliebige Anzahl Neuronen, die miteinander Verbunden sind“ („Neuronales Netz“, 2021). Ein Beispiel für ein neuronales Netz ist das menschliche Gehirn. Künstliche

2. THEORETISCHE GRUNDLAGEN

neuronale Netze modellieren biologische neuronale Netze in der Form von Programmcode („Artificial Neural Network Tutorial - Javatpoint“, n. d.). Diese Arbeit behandelt künstliche neuronale Netze, nicht aber biologische. Somit handelt es sich bei jedem erwähnten neuronalen Netz, um ein künstliches neuronales Netz.

Der Grundbaustein eines neuronalen Netzes ist das Neuron. Im Modell stellt das Neuron ein Objekt dar, das eine beliebige Anzahl Inputs, aber nur einen Output hat (siehe Abbildung 2.3) (Pramoditha, 2021). Input und Output sind hierbei rationale Zahlen. Der Output des Neurons ist im einfachsten Modell, dem Perzeptron Neuron, grundsätzlich entweder 0 oder 1. Der Output ist 1, wenn die Summe der Inputs einen vorgegebenen Wert, den *Threshold*, überschreitet. Ansonsten ist der Output gleich 0. Jeder Input hat ein *Gewicht*, das einer rationalen Zahl entspricht. Vor der Addition der Inputs wird jeder Input mit seinem Gewicht multipliziert. Die Grösse des Gewichtes bestimmt somit den Einfluss des zugehörigen Inputs auf den Output des Neurons. (Nielsen, 2015)(Simplilearn, 2021)



Abbildung 2.3: Perzeptron Neuron. (eigene Abbildung)

Neuronale Netze in Machine Learning Modellen verwenden kompliziertere Neuronen als das Perzeptron Neuron, wie zum Beispiel das Sigmoid Neuron. Die Neuronen unterscheiden sich in ihrer *Activation Function* und somit im Verhalten ihres Outputs (Pragati Baheti, 2022). So nimmt der Output im Sigmoid Neuron beispielsweise auch Werte zwischen 0 und 1 an, in einem stetigen Übergang zwischen den beiden Grenzen (siehe Abbildung 2.4) (Kumar, 2019).

Softmax und *ReLU* (rectified linear unit) sind weitere Activation Functions.

ReLU ist die am weitesten verbreitete Activation Function in Deep Learning und wird häufig für *Hidden Layers* verwendet (source...). Softmax wird im Vergleich meistens für die Activation Function des *Output Layers* verwendet. Diese Begriffe werden im nächsten Abschnitt genauer erläutert. Softmax bestimmt die Ausgabe aus dem Output Layer so, dass die Werte von allen Neuronen sich zu Eins addieren. Softmax konvertiert somit die Ausgabe aus einem neuronalen Netz in eine Wahrscheinlichkeitsverteilung. Softmax kann mit einem Parameter, genannt Temperatur, kombiniert werden. Dieser Parameter beeinflusst die Standardabweichung der Wahrscheinlichkeitsverteilung. Mit steigender Temperatur wird die Verteilung dabei uniformer und mit sinkender Temperatur nimmt die Differenz zwischen den einzelnen Werten zu.

2. THEORETISCHE GRUNDLAGEN



Abbildung 2.4: Vergleich des Outputs eines Perzeptron Neurons und eines Sigmoid Neurons. (eigene Abbildung)

Neuronale Netze sind Verbindungen von Neuronen. Dabei dient der Output eines Neurons als Input für andere Neuronen. Der Output eines Neurons kann gleich für mehrere Neuronen ein Input sein. Die Neuronen sind in *Layers* geordnet (siehe autoreflayers). Neuronale Netze haben mindestens einen *Input Layer* und einen *Output Layer* (Nielsen, 2015)(Ognjanovski, 2020). Der Input Layer umfasst die Daten, welche das neuronale Netz beurteilen soll. Im Beispielproblem (siehe 2.1 Machine Learning) bestände der Input Layer aus 28×28 Neuronen, wobei jedes Neuron die Graustufe (durch einen Wert von 0 bis 255) eines Pixels im Bild beschreibt. Der Input ist in diesem Fall zweidimensional. Die Dimensionen sind allerdings flexibel. Der Output Layer besteht im Beispiel aus 10 Neuronen, wobei jedes Neuron einer Beurteilung entspricht (das zweite Neuron beschreibt zum Beispiel die Ziffer Zwei als Beurteilung). Dasjenige Neuron mit dem höchsten Output entspricht der Beurteilung des neuronalen Netzes. (siehe Abbildung 2.5).




Abbildung 2.5: Neuronales Netz mit beschrifteten Layers. (eigene Abbildung)

Zwischen dem Input Layer und dem Output Layer kann es weitere *Hidden Layers* geben (Malik, 2019). Unterschiedliche Arten von Hidden Layers mit unterschiedlichen Funktionen existieren. Zwei der meist verwendeten Layers sind Fully Connected (Dense) Layers und Convolutional Layers (Unzueta, 2022). In Fully Connected Layers dient der Output von jedem Neuron als Input für jedes Neuron in der nächsten Layer. In Convolutional Layers trifft das nicht zu (siehe Abbildung 2.6). Die Funktion von Convolutional Layers umfasst, wichtige Merkmale aus dem Input hervorzuheben (Deshpande, n. d.). Concatenation Layers (Jayawardana, 2021) sind eine weitere Form von Hidden Layers, die zwei verschiedene Layers als Input haben und diese verbindet. Machine Learning Modelle werden ab mehr als einer Hidden Layer als Deep Learning Modelle bezeichnet (Jan-Dirk Kranz, 2019).

Ein Machine Learning Modell passt während dem Training (siehe 2.1.1 Funktionsweise eines Machine Learning Modelles) einzelne Gewichte im neuronalen Netz an, in der Hoffnung, dass die Genauigkeit der Beurteilung mit den angepassten Gewichten grösser ist. Die genaue Anpassung erfolgt in den meisten Machine Learning Modellen durch den Backpropagation Algorithmus (Ognjanovski, 2020)(David E. Rumelhart et al., n. d.).




Abbildung 2.6: Vergleich zwischen Convolutional Layers (links) und Fully Connected Layers (rechts). (Unzueta, 2022)

2.1.3 Hyperparameter

Machine Learning Modelle umfassen verschiedene Hyperparameter. Diese beschreiben unter anderem, wie lange das Training läuft oder wie stark sich das Modell nach einer falschen Beurteilung anpasst. Hyperparameter beeinflussen das Lernverhalten des Modells (Nyuytiymbiy, 2022), aber ihr optimaler Wert ist im Voraus nicht bekannt.

Hyperparameter können unter anderem durch den Bayesian Optimization Algorithmus optimiert werden (Agnihotri & Batra, 2020)(paretos, 2021). Dieser Algorithmus versucht, den Output einer Black Box Funktion zu maximieren oder zu minimieren (Garnett, n. d., S. 15). Eine Black Box ist ein häufig komplexes System, dessen inneren Vorgänge nicht betrachtet werden („Black Box (Systemtheorie)“, 2021). Bei einer Black Box Funktion ist folglich der Input und der Output bekannt, während die Verarbeitung des Inputs zum Output nicht betrachtet wird (siehe Abbildung 2.7).




Abbildung 2.7: Prinzip einer Black Box Funktion. („Black Box (Systemtheorie)“, 2021)

Machine Learning Modelle werden häufig als Black Box Funktionen angesehen, da die genauen Vorgänge des rechnerisch aufwendigen Trainings durch einen aussenstehenden Betrachter nicht oder nur schwer erfassbar

sind. (Robbins, 2017). Um ein Machine Learning Modell als eine Black Box Funktion für den Bayesian Optimization Algorithmus zu verwenden, werden die zu optimierenden Hyperparameter als Input und eine Zielvariable als Output definiert. Die Zielvariable des Outputs entspricht dabei einem Wert, der die Leistung des Modells widerspiegelt und durch den Algorithmus maximiert werden soll. Ein Beispiel für die Zielvariable wäre die Genauigkeit des Machine Learning Modells (siehe 2.1.1 Funktionsweise eines Machine Learning Modelles). Die inneren, nicht betrachteten Vorgänge in der Black Box Funktion entsprechen in diesem Fall dem Training des Modells.

Der Bayesian Optimization Algorithmus kann bis zu 20 Hyperparameter zuverlässig optimieren (Moriconi et al., 2020). Der Algorithmus führt die Black Box Funktion für eine bestimmte Anzahl Iterationen mit jeweils verschiedenen Parametern durch. Die Wahl der Parameter basiert dabei auf Bayes' Theorem (Garnett, n. d., S. 7). Diejenigen Parameter, die den höchsten gefundenen Wert der Zielvariable auslösen, werden gespeichert.

2.2 Reinforcement Learning

Reinforcement Learning bedeutet zusammengefasst: Lernen durch Interaktion mit einer Umgebung. (Osiński & Budek, 2018). Genauer gesagt soll ein Machine Learning Modell durch Rückmeldungen aus einer Umgebung ein bestimmtes Verhalten erlernen.

Reinforcement Learning Modelle führen somit die Umgebung ein. Anders als bei Supervised Learning und Unsupervised Learning (siehe 2.1 Machine Learning) sind die Daten, aus denen das Modell lernen soll, im Voraus nicht bekannt. Reinforcement Learning Modelle trainieren somit nicht oder nicht nur auf den Daten aus einem Datenset. Das liegt in der Natur der Umgebung, die häufig zu viele verschiedene Zustände einnehmen kann, als dass diese in einem Datenset gesammelt werden könnten. Ein Machine Learning Modell lernt aus einer Umgebung, indem es durch Beurteilungen (siehe 2.1.1 Funktionsweise eines Machine Learning Modelles) mit dieser interagiert und dadurch Erfahrungen sammelt. (Piyush Verma & Stelios Diamantidis, 2021)

Als Beispiel kann die echte Welt als eine Umgebung angesehen werden. Der Mensch wäre in diesem Fall das Reinforcement Learning Modell. Der Mensch lernt die Eigenschaften seiner Umgebung durch Interaktionen mit dieser kennen. Beispielsweise lernt ein Mensch die Schwerkraft durch das Hinfallen kennen. Durch diese Erfahrungen kann der Mensch ein gewisses Verhalten, zum Beispiel das Laufen, erlernen. Reinforcement Learning Modelle imitieren dieses Lernverhalten. So verwendet die Robotik häufig Reinforcement Learning, um einen Roboter das Laufen erlernen zu lassen.

Die Umgebung, mit der das Reinforcement Learning Modell lernt, ist dabei häufig nicht echt, sondern simuliert.

2.2.1 Funktionsweise von Reinforcement Learning

Dieser Abschnitt umfasst eine genauere Erklärung eines Reinforcement Learning Modells, in diesem Fall Deep Q-Learning (Mnih et al., 2013), unter der Verwendung der korrekten Fachbegriffe.

Ein Reinforcement Learning Modell umfasst eine *Umgebung* und einen *Agent*. Der Agent ist dasjenige Element in der Umgebung, welches mit dieser interagiert und daraus lernt (Sutton & Barto, 2014, S. 53). Die Umgebung verändert sich in Zeitschritten, genannt *Steps*. In jedem Step führt der Agent eine *Action* aus, welche die Umgebung beeinflusst. Die Entscheidung, welche Action der Agent wählt, basiert auf einer *Observation* der Umgebung (Mnih et al., 2013, S. 2). Die Observation umfasst alle Daten der Umgebung, die für die Entscheidung relevant sind. Sein Entscheidungsprozess findet durch ein neuronales Netz statt (siehe 2.1.2 Künstliche neuronale Netze). Der Input in dieses neuronale Netz ist die Observation der Umgebung und der Output beschreibt die Action, die der Agent ausführt. Jedes Neuron des Outputs beschreibt eine spezifische Action des Agents. Der Agent kann somit nur eine feste Anzahl Actions ausführen. Alle Actions zusammen werden *Action-Space* (Sutton & Barto, 2014, S. 67) genannt. Jede Action im Action-Space besitzt einen *Q-Value*, der dem Output des zugehörigen Neurons entspricht (siehe Abbildung 2.8) (Wang, 2021).

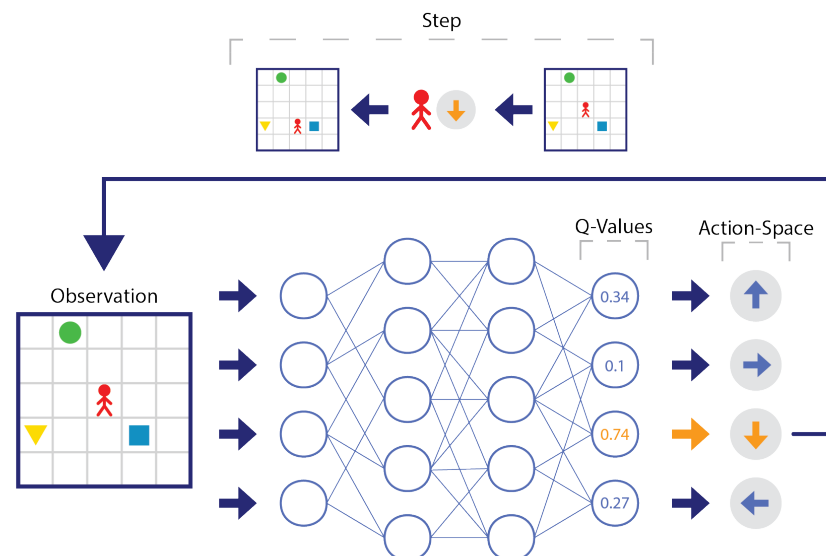


Abbildung 2.8: Funktionsweise eines Reinforcement Learning Modells. (eigene Abbildung)

Die schlussendliche Entscheidung der auszuführenden Aktion wird durch eine *Policy* bestimmt. Softmax und Epsilon Greedy sind 2 Beispiele für eine Policy (Sutton & Barto, 2014, S. 34). Die Epsilon-Greedy Strategie sieht vor, dass die Entscheidung mit einer Wahrscheinlichkeit von ϵ (Epsilon) auf eine zufällige Action fällt.

Ansonsten fällt die Entscheidung auf diejenige Action mit dem höchsten Q-Value. Durch die zufälligen Actions erkundet der Agent die Umgebung, in der Hoffnung, auf bessere Optionen für zukünftige Entscheidungen zu stossen. (Rajendra Koppula, n. d.).

Die Softmax Policy wählt Aktionen auf Basis einer Wahrscheinlichkeitsverteilung. Jede Aktion wird also mit einer gewissen Wahrscheinlichkeit ausgeführt. Die Wahrscheinlichkeitsverteilung berechnet sich aus der Softmax Activation Function von dem Output Layer des neuronalen Netzes.

Die Umgebung wird durch die Actions des Agents beeinflusst. Dieser Einfluss wird durch die *Reward-Function* gemessen. Die Reward-Function gibt eine rationale Zahl, den *Reward* aus (Sutton & Barto, 2014, S. 75). Umso grösser der Reward, desto positiver ist der Effekt einer Action auf die Umgebung und umgekehrt. Ein positiver Einfluss auf die Umgebung durch eine Action ist so definiert, dass der Agent durch die Action das gewünschte Verhalten vorzeigt. Die Reward-Function definiert, welches Verhalten welchen Reward erzielt. Der Q-Value der gewählten Action wird mit dem Reward (und dem maximalen Q-Value aus den nächsten möglichen Actions) addiert. Diese Formel nennt sich Bellman-Gleichung (Mnih et al., 2013, S. 3). Der neue Q-Value hat somit einen kleineren Wert, wenn der Reward negativ ist, und einen grösseren Wert, wenn der Reward positiv ist. Das neuronale Netz wird daraufhin so trainiert, dass der Output für das Neuron, dessen Action ausgeführt wurde, näher am neu berechneten, besseren Q-Value ist (siehe Abbildung 2.9). Der schlussendliche Effekt ist, dass Actions, die einen positiven Reward auslösen, wahrscheinlicher gewählt werden, und umgekehrt Actions, die einen negativen Rewards auslösen, unwahrscheinlicher gewählt werden. Der Agent versucht insgesamt durch seine Actions einen möglichst hohen akkumulierten Reward zu erzielen (Sutton & Barto, 2014, S. 57). Der akkumulierte Reward entspricht der Summe der Rewards aus jedem Step (in einer Episode. Beachte den nächsten Abschnitt).

Das Training läuft in *Episodes* (Sutton & Barto, 2014, S. 14). Eine Episode umfasst eine gewisse Anzahl Steps und am Anfang jeder Episode wird die Umgebung in einen Ausgangszustand zurückgesetzt. Die Resultate der Steps werden in dem *Replay-Buffer* gespeichert. Dazu gehören die Observations der Umgebung, die jeweiligen Actions und der jeweilige Rewards. Der Replay-Buffer enthält Speicherplatz für eine bestimmte Anzahl Steps. Während

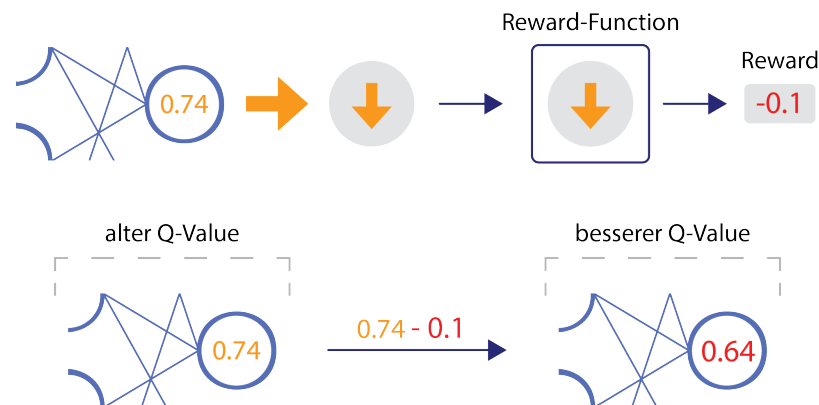


Abbildung 2.9: Funktionsweise einer Reward-Function. (eigene Abbildung)

dem Training werden zufällige Steps aus dem Replay-Buffer gewählt, auf die das neuronale Netz trainiert. Das neuronale Netz trainiert also auf Daten aus der Vergangenheit der Umgebung. Diese Strategie nennt sich Experience Replay (Mnih et al., 2013, S. 5). Ausserdem trainiert das neuronale Netz jeweils mit einem *Batch* an Steps, also mit einer gewissen Anzahl an Steps gleichzeitig. Der Replay-Buffer und der Batch sichern zu, dass das neuronale Netz mit einer grossen Vielfalt an Steps trainiert. Das bewirkt ein stabileres Lernverhalten als ein chronologisches Training auf einzelne Steps. (van Heeswijk, 2021).

2.3 Verwandte Arbeiten und Themen

Das Nachzeichnen von Strichbildern ist ein Teilbereich von der Tätigkeit des Zeichnens allgemein. Es gibt verschiedene Ansätze, um einen Computer zeichnen zu lassen. Ein häufiger Ansatz ist *Stroke-Based Rendering*. Stroke-Based Rendering beschreibt das Zeichnen von Bildern durch das Platzieren von Elementen wie Strichen (Aaron Hertzmann, 2002). Beispiele für Arbeiten in diesem Bereich sind Strokenet (Zheng et al., 2018) und "Learning to Paint With Model-based Deep Reinforcement Learning" (Huang et al., 2019). Andere Ansätze simulieren die Führung eines Stiftes. (siehe Abbildung 2.10). Ein Beispiel dafür ist Doodle-SDQ (Zhou et al., 2018).

2.3.1 Doodle-SDQ

Doodle-SDQ ist ein Computerprogramm, das unter anderem durch Reinforcement Learning und spezifischer durch Deep Q-Learning (siehe 2.2.1 Funktionsweise von Reinforcement Learning) erlernt, Strichbilder aus dem Google QuickDraw Datenset („Quick, Draw! Image Recognition“, 2022) nachzuzeichnen. Nachfolgend sind diejenigen Aspekte von Doodle-SDQ beschrieben, die für diese Arbeit relevant sind.




Abbildung 2.10: Vergleich zwischen Stroke-Based Rendering und dem Führen eines Stiftes. (eigene Abbildung)

Die QuickDraw Bilder, die Doodle-SDQ nachzeichnen soll, sind zu einer einheitliche Grösse von 84×84 Pixeln verarbeitet (Zhou et al., 2018, S. 7). Der Agent kann sich auf einer leeren Zeichenfläche von derselben Grösse bewegen und zeichnen. Die Umgebung umfasst diese Zeichenfläche, den Agent und das abzuzeichnende Bild.

Der Agent kann sich durch eine Action pro Step auf einem beliebigen Pixel in einem 11×11 Feld, in dessen Zentrum er ist, bewegen. Der Agent kann ausserdem jede dieser Bewegungen im zeichnenden Zustand oder im nicht zeichnenden Zustand ausführen. Der Action-Space hat somit insgesamt eine Grösse von $2 \cdot 11 \cdot 11 = 242$ Actions (Zhou et al., 2018, S. 5). Im zeichnenden Zustand wird ein Strich auf der Zeichenfläche zwischen der alten und der neuen Position des Agents gezeichnet. Der Agent begeht 100 Steps pro Episode. Eine neue Episode entspricht dabei einem neuen Bild, das abgezeichnet werden soll.

Die Observation der Umgebung und somit der Input in das neuronale Netz (siehe 2.2.1 Funktionsweise von Reinforcement Learning) ist in zwei Teile gegliedert: der Global Stream und der Local Stream (Zhou et al., 2018, S. 4). Der Global Stream hat eine Form von $28 \times 28 \times 4$. Der Input ist somit dreidimensional. Die Form kann als 4 aufeinandergestapelte Bilder angesehen werden, die jeweils eine Grösse von 28×28 Pixeln haben. Dabei beschreibt eine rationale Zahl den Wert von jedem Pixel in einem Bild. Das erste Bild im Global Stream ist die Vorlage, die abgezeichnet werden soll. Das zweite Bild ist die Zeichenfläche im aktuellen Zustand. Das dritte Bild beschreibt die Position des Agents durch seine relative Entfernung zu jedem Punkt auf der Zeichenfläche. Das vierte Bild beschreibt, ob der Agent im zeichnenden Zustand ist oder nicht. Wenn alle Pixel dieses letzten Bildes den Wert 1 haben, ist der Agent im zeichnenden Zustand. Wenn alle Pixel den Wert 0 haben,

ist der Agent nicht im zeichnenden Zustand. Der Local Stream hat eine Form von $11 \times 11 \times 2$. Er ist somit auch dreidimensional und beschreibt zwei gestapelte Bilder. Das erste Bild umfasst die Vorlage in dem 11×11 Bereich (bezeichnet als Local image Patch (Zhou et al., 2018, S. 5)), in dem sich der Agent in einem Step bewegen kann. Das zweite Bild beschreibt denselben Bereich von der Zeichenfläche (Zhou et al., 2018, S. 4 ff.). Der Global Stream und der Local Stream werden durch eine Concatenation Layer (siehe 2.1.2 Künstliche neuronale Netze) zusammengeführt.

Kapitel 3

Methode

Die Methode dieser Untersuchung besteht darin, die in der Fragestellung beschriebene künstliche Intelligenz (KI) zu entwickeln und dessen Leistung auszuwerten. Die Diskussion dieser Resultate führt schlussendlich zu einer Antwort auf die Fragestellung. Die Entwicklung der KI besteht aus zwei Teilen. Der eine Teil umfasst die Definition der Kriterien, nach denen die Leistung der KI evaluiert wird (siehe 3.2 Evaluation der Leistung). Der andere Teil umfasst die Entwicklung der KI (siehe 3.1 Grundprogramm), zusammen mit verschiedenen Variationen davon (siehe 3.3 Variationen). Die Variationen haben jeweils einen unterschiedlichen Fokus auf die definierten Kriterien. Die Auswertung (siehe 3.4 Auswertung) der Leistung der KI bezieht sich ebenfalls auf die definierten Kriterien.

3.1 Grundprogramm

Die KI ist abhängig von den Kriterien, die dessen Leistung definieren (siehe 3.2 Evaluation der Leistung). Mit anderen Worten trainiert die KI auf diese Kriterien. Das Ziel des Grundprogramms ist, die allgemeine Trainingsumgebung für die KI bereitzustellen. Dieses Grundprogramm ist unabhängig von einem spezifischen Kriterium und ermöglicht das Training auf ein beliebiges Kriterium. Reinforcement Learning Modelle mit einer undefinierten Reward-Function (siehe 2.2.1 Funktionsweise von Reinforcement Learning) umfassen diese Eigenschaften. Das Grundprogramm ist in Python unter der Verwendung des Keras Frameworks implementiert (siehe 2.1 Machine Learning).

3.1.1 Doodle-SDQ als Basis

Das Reinforcement Learning Modell des Grundprogramms basiert auf Doodle-SDQ (siehe 2.3.1 Doodle-SDQ). Von Doodle-SDQ ist das neuronale Netz, bezogen auf die Form des Inputs, des Outputs und den Hidden

3. METHODE

Layers, grösstenteils übernommen. Die relevanten Anpassungen zwischen Doodle-SDQ und dem Grundprogramm dieser Arbeit sind nachfolgend erläutert.

Bei der Umgebung handelt es sich, wie bei Doodle-SDQ, um eine Zeichenfläche, worauf sich der Agent bewegt. Das Grundprogramm wird auf das Nachzeichnen von Ziffern trainiert. Die Ziffern stammen aus dem MNIST Datenset (siehe 2.1 Machine Learning) und haben somit eine Grösse von 28×28 Pixeln. Die Fläche, worauf sich der Agent bewegen kann, hat folglich auch eine Grösse von 28×28 Pixeln. Der Global Stream (siehe 2.3.1 Doodle-SDQ) des Inputs in das neuronale Netz ändert sich bis auf die neue Grösse der Bilder nicht. Die Pixel der Bilder, wie auch die Zeichenfläche, nehmen den Wert von einem Bit an. Eine Null repräsentiert einen schwarzen (nicht gezeichneten) Pixel an dieser Stelle im Bild und eine Eins einen weissen (gezeichneten) Pixel. Die genaue Architektur des neuronalen Netzes ist in der Abbildung 3.1 angegeben.

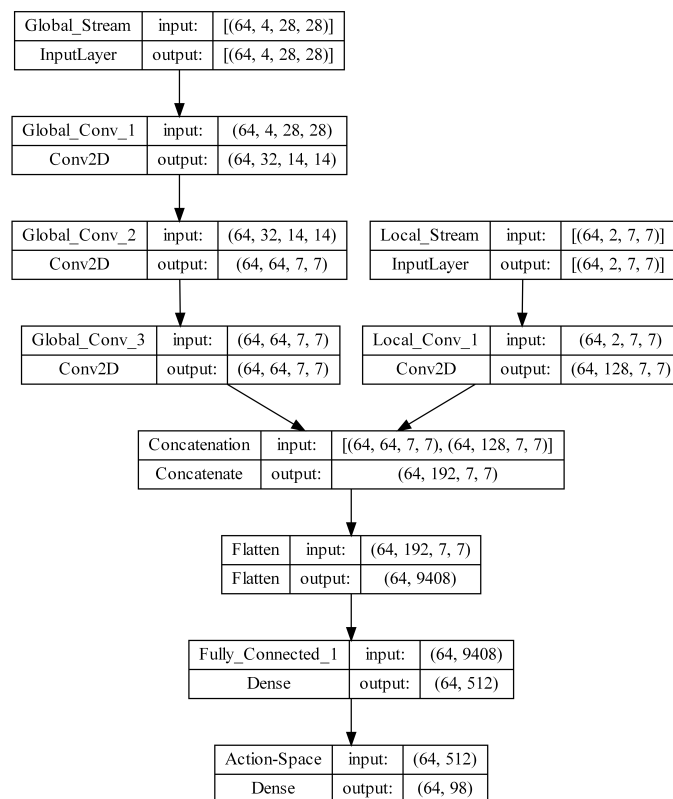


Abbildung 3.1: Architektur des neuronalen Netzes im Grundprogramm (eigene Abbildung, mit Keras erstellt). Jeder Block repräsentiert einen Layer. Die Form des Inputs und des Outputs ist von jedem Layer angegeben

Der Local Stream und damit auch der Local image Patch schrumpfen von

11×11 Pixel auf 7×7 Pixel. Somit schrumpft gleichzeitig der Action-Space (siehe 2.2.1 Funktionsweise von Reinforcement Learning) des Agenten von $2 \cdot 11 \cdot 11 = 242$ Actions auf $2 \cdot 7 \cdot 7 = 98$ Actions. Das bedeutet für den Agent, dass er sich pro Step um maximal drei Pixel von seiner Position wegbewegen kann. Diese Bewegung kann der Agent entweder zeichnend oder nicht zeichnend ausführen (siehe Abbildung 3.2).

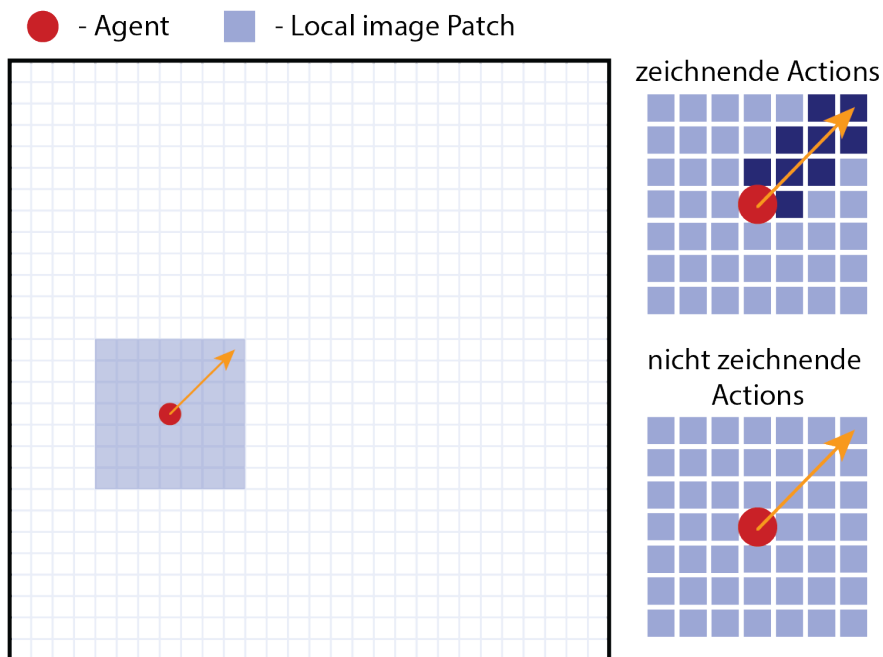


Abbildung 3.2: Action-Space im Grundprogramm

Falls der Agent die Action zeichnend ausführt, zieht das Programm einen Strich zwischen der alten und der neuen Position. Mit anderen Worten werden alle Pixel der Zeichenfläche zwischen den beiden Positionen weiss. Der Strich hat eine festgelegte Breite von 3 Pixeln. Am Anfang jeder Episode, also mit jeder neuen Ziffer, startet der Agent in einer zufälligen Position im nicht zeichnenden Zustand. Am Anfang jeder Episode ist die Zeichenfläche leer, also vollkommen Schwarz.

Actions des Agents, die ihn über die vorgegebene Zeichenfläche hinaus positionieren würden, sind nicht zulässig. Diese Actions können vom Agent nicht gewählt werden und ihr optimaler Q-Value (siehe 2.2.1 Funktionsweise von Reinforcement Learning) ist in jedem Fall 0. Das hat zur Folge, dass nach dem Training die allermeisten unzulässigen Actions einen Q-Value nahe oder gleich 0 haben. Das senkt die Wahrscheinlichkeit, dass der Agent versucht, eine unzulässige Action auszuführen.

3.1.2 Präparierung der Daten und Optimierung

Die Trainingsdaten bestehen aus 36'000 Bildern von handgeschriebenen Ziffern aus dem MNIST Datenset (siehe 2.1 Machine Learning). Die restlichen Bilder des MNIST Datensets machen die Testdaten aus. Die Bilder im Datenset sind als Bitmap dargestellt, wobei jedes Element (jeder Pixel) einen Wert zwischen 0 und 255 annimmt. Die Zahl repräsentiert eine Graustufe, wobei 0 Schwarz ist und 255 Weiss. Diese Graustufen werden entfernt. Jeder Pixel mit einem Wert über 0 übernimmt den Wert 1, wodurch die Bilder nur noch aus Einsen und Nullen bestehen. Dabei ist 0 Schwarz und 1 Weiss (siehe Abbildung 3.3). So stimmen die Bilder mit den Zeichnungen, die der Agent produzieren kann, überein.




Abbildung 3.3: Entfernung der Graustufen im MNIST Datenset. (eigene Abbildung)

Das Grundprogramm trainiert mit 3'000 Bildern, von denen jede Ziffer 300 Bilder ausmacht. Die restlichen Bilder in den Trainingsdaten sind für mögliche Erweiterungen aufgehoben. Der Agent zeichnet jedes der 3'000 Bilder ein Mal und trainiert somit für 3'000 Episoden. Der Agent zeichnet für 64 Steps pro Episode.

Die Hyperparameter des Grundprogramms, wie auch die der Variationen (siehe 3.3 Variationen) sind durch den Bayesian Optimization Algorithmus optimiert (siehe 2.1.3 Hyperparameter). Die Implementierung des Algorithmus in Python stammt von (Fernando Nogueira, 2014). Der Algorithmus ändert sich für verschiedene Variationen der KI nicht und ist somit Teil des Grundprogramms. Mit jeder Iteration des Bayesian Optimization Algorithmus trainiert das Reinforcement Learning Modell für eine vom Algorithmus selbst bestimmte Anzahl Episoden. Die Zielvariable, die durch den Bayesian Optimization Algorithmus maximiert werden soll, wird am Ende jeder Iteration des Trainings in der Testumgebung berechnet.

(siehe 3.4.1 Testumgebung). Auf welchem der drei Kriterien (siehe 3.2 Evaluation der Leistung) die Zielvariable basiert, ist frei wählbar.

3.2 Evaluation der Leistung

In diesem Unterkapitel sind die Kriterien definiert, welche die Leistung der künstlichen Intelligenz evaluieren. Mit anderen Worten beschreiben die Kriterien, wie gut die KI nachzeichnet. Für eine präzise und objektive Evaluation sind alle Kriterien durch einen Zahlenwert repräsentiert. Die Kriterien und ihre jeweilige Berechnung werden nachfolgend beschrieben.

3.2.1 Erkennbarkeit

Das Kriterium der Erkennbarkeit beschreibt, ob in der Vorlage das gleiche Motiv wie in der Zeichnung der künstlichen Intelligenz erkannt wird. Wenn Beispielsweise in beiden Fällen eine Fünf erkannt wird, hat das Kriterium den Wert 1. Wird in der Vorlage eine Fünf erkannt, aber in der Zeichnung eine Vier, hat das Kriterium den Wert 0

Das erkannte Motiv wird durch eine zweite KI beurteilt (siehe 2.1.1 Funktionsweise eines Machine Learning Modelles). Diese zweite KI beurteilt ein Motiv nur als erkannt, wenn das zugehörige Neuron im Output des neuronalen Netzes einen Wert von über 0.75 hat. Das entspricht laut dem neuronalen Netz mit einer hohen Wahrscheinlichkeit der korrekten Beurteilung.

Um die verschiedenen Arten von Strichbildern, die die KI zeichnen soll, zu erkennen, existieren vortrainierte Machine Learning Modelle. Die in dieser Arbeit implementierten vortrainierten Modelle sind in der Tabelle 3.1 ersichtlich. Diese Modelle sind mit denselben Daten trainiert, die in der Testumgebung (siehe 3.4.1 Testumgebung) als Vorlage zum Abzeichnen dienen.

Art	Entwickler	Trainiert mit
Ziffern	(Mazzia et al., 2022)	MNIST
Buchstaben	(Mor, 2022)	EMNIST Letters
Strichbilder von Objekten	(Lâm (Linus), 2022)	Auswahl aus QuickDraw

Tabelle 3.1: Vortrainierte Modelle

3.2.2 Prozentuale Übereinstimmung

Dieses Kriterium beschreibt die prozentuale Übereinstimmung der weissen (gezeichneten) Pixel zwischen der Vorlage und der Zeichnung der KI (siehe

3. METHODE

3.1 Grundprogramm). Der Wert K dieses Kriteriums zu dem Step t berechnet sich aus folgender Formel:

$$K(t) = \frac{G(t)}{G_{\max}}$$

G_{\max} entspricht der Anzahl aller weissen Pixeln in der Vorlage. $G(t)$ entspricht der Anzahl der weissen Pixel, die zwischen der Vorlage und der Zeichenfläche übereinstimmen. Die Pixel, die nicht übereinstimmen, zählen negativ für $G(t)$. $G(t)$ und somit auch $K(t)$ können dadurch auch negative Werte annehmen. Der maximale Wert von $K(t)$ ist 1, was einer prozentualen Übereinstimmung von 100% entspricht (siehe Abbildung 3.4).




Abbildung 3.4: Drei Beispiele für den Wert des Kriteriums der Übereinstimmung. (eigene Abbildung)

3.2.3 Geschwindigkeit

Dieses Kriterium beschreibt, wie schnell die Zeichnung der KI fertig ist. Der Wert dieses Kriteriums entspricht der Anzahl Steps bis zur Fertigstellung der Zeichnung. Eine kleinere Anzahl Steps entspricht einer schnelleren Fertigstellung der Zeichnung und somit einer besseren Leistung bezogen auf dieses Kriterium.

Eine Zeichnung gilt als fertig, wenn die prozentuale Übereinstimmung (siehe 3.2.2 Prozentuale Übereinstimmung) mindestens 70% beträgt und die Zahl der Definition entsprechend erkannt wird (siehe 3.2.1 Erkennbarkeit). Wenn die Zeichnung bis zum Ende der Episode die Bedingungen einer fertigen Zeichnung nicht erfüllt, hat dieses Kriterium den Wert 64. Das entspricht der Anzahl Steps, die von der KI pro Episode insgesamt begangen werden (siehe 3.1.2 Präparierung der Daten und Optimierung).

3.3 Variationen

Dieses Unterkapitel beschreibt verschiedene Variationen, ausgehend vom Grundprogramm (siehe 3.1 Grundprogramm). Bei einigen dieser Variationen

handelt es sich um konkrete Implementierungen der definierten Kriterien in die Reward-Function (siehe 2.2.1 Funktionsweise von Reinforcement Learning). Die Reward-Function kann dabei auf mehreren Kriterien gleichzeitig basieren. Der Unterschied zwischen den Variationen liegt im Fokus auf die Kriterien. Einige Variationen sind untereinander kombinierbar, andere Variationen führen strukturelle Veränderungen für die KI ein, die über die Reward-Function hinaus gehen.

3.3.1 Basis Reward-Function

Die Basis Reward-Function ist die einfachste Erweiterung des Grundprogrammes (siehe 3.1 Grundprogramm). Diese Reward-Function implementiert das Kriterium der prozentualen Übereinstimmung (siehe 3.2.2 Prozentuale Übereinstimmung). Der Reward für eine Action berechnet sich aus der Differenz zwischen der prozentualen Übereinstimmung vor dem Ausführen der Action, und der prozentualen Übereinstimmung nach dem Ausführen der Action (also $K(t - 1)$ und $K(t)$). Somit wird der Reward R zum Step t durch folgende Formel berechnet.

$$R(t) = K(t) - K(t - 1)$$

Der Reward eines Steps entspricht folglich nicht der gesamten prozentualen Übereinstimmung zu einem Step. Stattdessen entspricht der Reward der Veränderung der prozentualen Übereinstimmung, ausgelöst durch die Action in einem Step. Der akkumulierte Reward (siehe 2.2.1 Funktionsweise von Reinforcement Learning) entspricht dem absoluten Wert der prozentualen Übereinstimmung.

3.3.2 Training auf Geschwindigkeit

Das Kriterium der Geschwindigkeit (siehe 3.2.3 Geschwindigkeit) kann in die Reward-Function integriert werden. Dadurch trainiert die künstliche Intelligenz auf eine minimale Zeit bis zur Fertigstellung der Zeichnung. Die Variation verwendet grundsätzlich die Basis Reward-Function (siehe 3.3.1 Basis Reward-Function). Die vorgeschlagene Anpassung davon sieht folgendermassen aus: Am Ende jeder Episode wird der Reward jedes Steps in der Episode mit einem Faktor f multipliziert. Dieser Faktor berechnet sich aus folgender Formel:

$$f = 2 - \frac{S}{S_{\max}}$$

S_{\max} entspricht der Anzahl Steps, die der Agent in einer Episode begeht (siehe 3.1.2 Präparierung der Daten und Optimierung). S entspricht der Anzahl Steps bis zur Fertigstellung der Zeichnung. Der Faktor nimmt einen Wert zwischen 1 und 2 an. Ein grosser Faktor f entspricht einem hohen Reward und wird durch eine schnelle Fertigstellung der Zeichnung ausgelöst.

Wenn der Agent die Zeichnung bis zum Ende einer Episode nicht fertigstellt, ist $f = 1$. In diesem Fall unterscheidet sich die Reward-Function nicht von der Basis Reward-Function. Wenn die Zeichnung früher fertiggestellt wird, zeichnet der Agent trotzdem alle S_{\max} Steps. Das verhindert eine ungleichmässige Verteilung zwischen verschiedenen Episodes im Replay-Buffer (siehe 2.2.1 Funktionsweise von Reinforcement Learning). In diesem Fall wird S allerdings nur in dem Step gespeichert, in dem die Zeichnung zum ersten Mal die Bedingung einer Fertigstellung erfüllt.

Indem das Kriterium der Geschwindigkeit während dem Training angepasst wird, verstärkt sich der Fokus auf eine möglichst schnelle Fertigstellung. Die minimale prozentuale Übereinstimmung einer fertigen Zeichnung ist als 75% definiert. Zu Beginn des Trainings wird dieser Wert auf 25% herabgesetzt, und über das Training hinweg linear bis auf 75% erhöht. Dadurch löst die Reward-Function bei einer unfertigen Zeichnung bereits positive Rewards für die Geschwindigkeit aus. Für diese Anpassung wird die Bedingung der korrekten Erkennung (siehe 3.2.3 Geschwindigkeit) nicht beachtet.

3.3.3 Training auf Erkennbarkeit

Das Kriterium der Erkennbarkeit kann, anders als die anderen Kriterien, nur teilweise in die Reward-Function integriert werden. Das Kriterium strebt eine Erkennbarkeit, unabhängig von der Art der Strichbilder, an (siehe 3.2.1 Erkennbarkeit). Die künstliche Intelligenz trainiert allerdings nur auf das Nachzeichnen von Ziffern. Aus diesem Grund trainiert diese Variation nur auf die Erkennbarkeit von Ziffern, und lässt die anderen Arten von Strichbildern aussen vor.

Die Reward-Function (siehe 2.2.1 Funktionsweise von Reinforcement Learning) dieser Variation beinhaltet eine zweite KI, die handgeschriebene Ziffern erkennt (siehe Tabelle 3.1). Diese zweite KI beurteilt in jedem Step, welche Ziffern sie in der Vorlage und in der aktuellen Zeichnung erkennt.

Die einfachste Form der Reward-Function für diese Variation sähe folgendermassen aus: Wenn eine Zeichnung das Kriterium der Erkennbarkeit erfüllt, löst die Reward-Function einen Reward von 0.05 aus. In diesem Zustand funktioniert die Reward-Function allerdings nicht. Der Agent kann den akkumulierten Reward nicht maximieren. Zwei Ansätze gehen auf dieses Problem ein. Beide Ansätze sind Teil dieser Variation.

Der erste Ansatz schlägt vor, die zweite KI erst ab einer gewissen prozentualen Übereinstimmung (siehe 3.2.2 Prozentuale Übereinstimmung) einzusetzen. In diesem Fall löst die korrekte Erkennung erst ab einer prozentualen Übereinstimmung von 20% einen positiven Reward aus. Diese zusätzliche Bedingung ist notwendig, weil die Beurteilungen der zweiten KI teilweise für einen menschlichen Betrachter fragwürdig sind. Zum Beispiel

schätzt die zweite KI eine leere Zeichenfläche mit einer hohen Sicherheit als eine Eins ein (siehe Abbildung 3.5). Das ist ein Problem, weil dadurch der Agent einen positiven Reward für eine leere Zeichenfläche erhält. Das stört das weitere Lernverhalten, weil es die Wahrscheinlichkeit erhöht, dass die KI nicht mehr zeichnet.

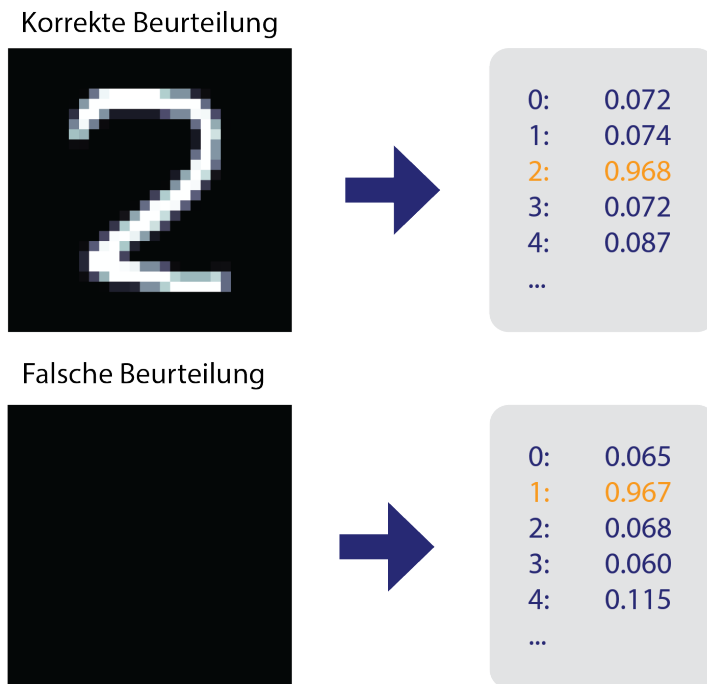


Abbildung 3.5: Beispiele einer richtigen und einer falschen Erkennung von handgeschriebenen Zahlen durch eine KI (eigene Abbildung). Die Werte sind durch einen Test der KI berechnet.

Der zweite Ansatz implementiert neben der Reward-Function der Erkennbarkeit erneut die Basis Reward-Function (siehe 3.3.1 Basis Reward-Function). Die Relevanz der beiden Reward-Functions ändert sich allerdings über das Training hinweg. Die Rewards werden in jedem Step mit einem bestimmten Faktor multipliziert. Zu Beginn des Trainings ist der Faktor für den Reward der Basis Reward-Function $f_b = 1$ und der Faktor für den Reward basierend auf der Erkennbarkeit $f_e = 0$. Vom Start ausgehend sinkt f_b linear und f_e steigt linear. Ab einem gewissen Punkt bleiben beide Faktoren stehen (siehe Abbildung 3.6). Blieben die Faktoren ab diesem Punkt nicht konstant, würde die Variation, gestützt auf Beobachtungen, an der Stabilität ihrer Leistung verlieren.




Abbildung 3.6: Veränderung der Faktoren der Basis Reward-Function und der Reward-Function der Erkennbarkeit über das Training hinweg. (eigene Abbildung)

Das Zusammenspiel der beiden Reward-Functions hat den Vorteil, dass die künstliche Intelligenz zu Beginn des Trainings durch die Basis Reward-Function für kleine Erfolge positive Rewards erzielt. Die Reward-Function der Erkennbarkeit ermöglicht das nicht, da sie erst für eine korrekte Erkennung einen Reward auslöst. Eine korrekte Erkennung ist allerdings für eine untrainierte KI schwer zu erreichen. Gewissermassen wird die KI durch die Basis Reward-Function vortrainiert, um schlussendlich mit der Reward-Function der Erkennbarkeit effizient trainieren zu können.

3.3.4 Physikalische Umgebung

Diese Variation spezialisiert sich auf kein Kriterium. Stattdessen verändert sich die Umgebung, in der sich der Agent bewegt (siehe 2.2.1 Funktionsweise von Reinforcement Learning). Auch der Input und der Output des neuronalen Netzes sind angepasst. Durch diese Veränderungen löst sich die Variation vom Grundprogramm. Sie bleibt allerdings mit den anderen Variationen kompatibel, da diese ausschliesslich die Reward-Function anpassen.

Die Variation ergänzt die Umgebung durch physikalische Simulationen. Diese physikalische Umgebung definiert die physischen Rahmenbedingungen des Zeichnens neu, mit dem Ziel, diese näher an die Realität zu bringen.

Der Agent hat neu eine Geschwindigkeit, die durch einen Vektor \vec{v} dargestellt

ist. Die Geschwindigkeit beschreibt, um wie viele Pixel und in welche Richtung sich der Agent pro Step bewegt. Die folgende Formel beschreibt, wie sich die Position des Agenten vom Step t bis zum nächsten Step $t + 1$ verändert:

$$\vec{p}(t+1) = \vec{p}(t) + \vec{v}(t)$$

$\vec{p}(t)$ beschreibt die Position des Agents als einen Ortsvektor auf der Zeichenfläche zum Step t und $\vec{v}(t)$ beschreibt die Geschwindigkeit des Agenten zum Step t . Die Position rundet in jedem Step auf ganze Zahlen. Das kommt daher, dass die Geschwindigkeit auch Dezimalzahlen annehmen kann, aber die Position nur durch ganze Zahlen dargestellt ist.

Zur Geschwindigkeit des Agents wird in jedem Step ein Beschleunigungsvektor addiert. Jede Action, die der Agent wählen kann, entspricht einem anderen Beschleunigungsvektor. Der Action-Space (siehe 2.2.1 Funktionsweise von Reinforcement Learning) besteht neu aus 42 Actions. 21 der 42 Actions beschreiben Beschleunigungsvektoren im zeichnenden Zustand. Die anderen 21 Actions beschreiben dieselben Vektoren im nicht zeichnenden Zustand. Die 21 verschiedenen Beschleunigungsvektoren im Action-Space sind in der folgenden Formation angeordnet: (siehe Abbildung 3.7).




Abbildung 3.7: Action-Space in der physikalischen Umgebung. (eigene Abbildung)

Mit dem gewählten Beschleunigungsvektor $\vec{a}(t)$ berechnet sich die Geschwindigkeit im nächsten Step $t + 1$ aus dem aktuellen Step t durch folgende Formel:

$$\vec{v}(t+1) = \vec{v}(t) + \vec{a}(t)$$

3. METHODE

Der Betrag der Geschwindigkeit $\vec{v}(t+1)$ des Agents wird in jedem Step, unabhängig von der gewählten Action, um 0.3 Pixel pro Step verringert. Das simuliert eine Reibungskraft, die auf den Agent einwirkt.

Die Veränderungen in der Umgebung erfordern Anpassungen im neuronalen Netz (siehe 2.1.2 Künstliche neuronale Netze). Ohne diese Anpassungen kann die KI den akkumulierten Reward nicht maximieren. Das Problem ist, dass die aktuelle Geschwindigkeit des Agents kein Teil der Observation ist (siehe 2.2.1 Funktionsweise von Reinforcement Learning). Der Agent berücksichtigt deswegen seine Geschwindigkeit nicht in seinen Entscheidungen. Die Lösung dieses Problems bietet eine Verschiebung des Local image Patches (siehe 2.3.1 Doodle-SDQ). Im Grundprogramm entspricht der Mittelpunkt des Local image Patches genau der Position des Agents. Neu befindet sich der Mittelpunkt dort, wo sich der Agent laut seiner aktuellen Geschwindigkeit im nächsten Step befinden wird. Durch diese Verschiebung des Local image Patches erhält der Agent Informationen über seine Geschwindigkeit, ohne dessen numerischen Wert zu kennen. Wie im Grundprogramm gibt der Local image Patch den gesamten Bereich an, in dem sich der Agent im nächsten Step befinden kann. Die tatsächliche neue Position des Agents wird durch die Action seiner Wahl bestimmt. Die Grösse des Local image Patches schrumpft von 7×7 Pixeln auf 5×5 Pixel, da alle möglichen Positionen des Agents nach einem Step auf einem 5×5 Feld Platz haben (siehe Abbildung 3.8).




Abbildung 3.8: Angabe der Geschwindigkeit durch eine Verschiebung des Local image Patches. (eigene Abbildung)

Ein weiteres Problem ist, dass der Agent sich durch seine Geschwindigkeit aus den vorgegebenen Grenzen der Zeichenfläche begeben kann. Im Grundprogramm (siehe 3.1.1 Doodle-SDQ als Basis) kann der Agent Actions, die ihn in eine unzulässige Position bewegen würden, nicht auswählen.

Wenn allerdings in der physikalischen Umgebung die Geschwindigkeit des Agents zu hoch ist, kann dieser keine Actions mehr wählen, die ihn innerhalb der Grenzen der Zeichenflächen halten würden. Als Lösung wird diesen Fällen die Geschwindigkeit des Agents auf den Nullvektor zurückgesetzt und die Reward-Function löst einen negativen Reward von -0.05 aus. Der negative Reward soll die Häufigkeit dieser Vorfälle vermindern.

3.4 Auswertung

Die Auswertung der Daten über die Leistung der künstlichen Intelligenz liefert das Resultat der Methode. Die Auswertung berechnet den Zahlenwert der definierten Kriterien (siehe 3.2 Evaluation der Leistung) für verschiedene Variationen der KI.

Die Variationen werden auf ihre Leistung für drei verschiedene Datensets geprüft. Die drei Datensets beinhalten verschiedene Arten von Strichbildern (siehe Tabelle 3.1). Im Falle des QuickDraw Datensets wird die KI allerdings nur auf das Nachzeichnen von zehn Motiven überprüft. Die zehn Motive sind: 'Amboss', 'Apfel', 'Besen', 'Eimer', 'Bulldozer', 'Uhr', 'Wolke', 'Computer', 'Auge' und 'Blume' (siehe Abbildung 3.9). Die Bilder in den drei Datensets sind gleich verarbeitet wie die Trainingsdaten (siehe 3.1.2 Präparierung der Daten und Optimierung).

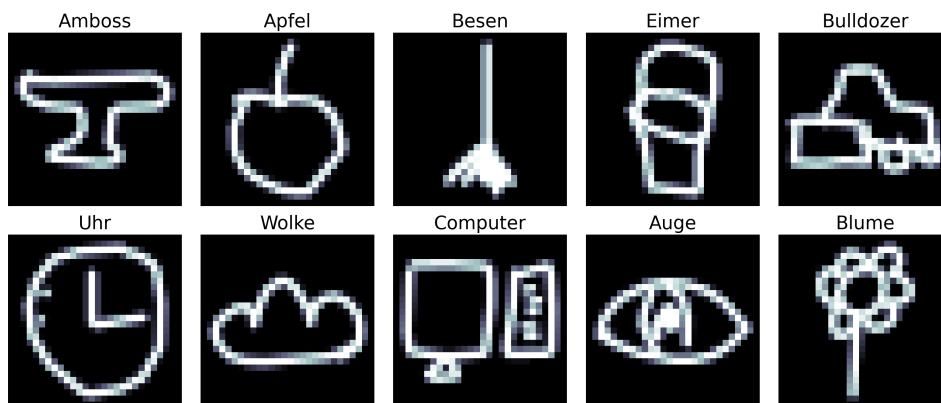


Abbildung 3.9: Beispiele der verwendeten Motive aus dem QuickDraw Datenset. (eigene Abbildung)

Die Variationen (siehe 3.3 Variationen) der KI umfassen zwei Umgebungen und drei Reward-Functions (siehe 2.2.1 Funktionsweise von Reinforcement Learning). Für jede Variation ist zur Vereinfachung eine Abkürzung definiert.

- 3.1 Grundprogramm Umgebung: Grund
- 3.3.4 Physikalische Umgebung: Physik
- 3.3.1 Basis Reward-Function: Basis
- 3.3.2 Training auf Geschwindigkeit: Speed
- 3.3.3 Training auf Erkennbarkeit (von MNIST Ziffern): MNIST

Die folgenden Kombinationen an Variationen der künstlichen Intelligenz werden ausgewertet. Diese Kombinationen stellen einzelne Versionen der KI dar

- Grund-Basis
- Grund-MNIST
- Grund-Speed
- Grund-MNIST-Speed
- Physik-Basis
- Physik-MNIST
- Physik-Speed
- Physik-MNIST-Speed

3.4.1 Testumgebung

Die Leistungen der verschiedenen Variationen der künstlichen Intelligenz werden in einer Testumgebung (siehe 2.1.1 Funktionsweise eines Machine Learning Modelles) ausgewertet. Zwischen der Trainingsumgebung und der Testumgebung sind drei relevante Unterschiede. Erstens trainiert die KI in der Testumgebung nicht. Die Testumgebung übernimmt eine trainierte Version der KI und verändert diese während dem Test nicht. Zweitens wählt der Agent in keinem Fall mehr eine zufällige Action. Stattdessen wählt er immer die Action mit dem höchsten Q-Value (gleichbedeutend mit $\epsilon = 0$) (siehe 2.2.1 Funktionsweise von Reinforcement Learning). Der Dritte Unterschied liegt in den Strichbildern, die für die künstliche Intelligenz als Vorlage dienen. Im Test zeichnet das Computerprogramm 2000 Bilder aus einem der drei zur Verfügung stehenden Datensets (siehe Tabelle 3.1).

Am Ende jeder Episode (das heisst jeder Zeichnung), wird der Zahlenwert für die verschiedenen Kriterien (siehe 3.2 Evaluation der Leistung) ihrer Definition entsprechend ausgewertet und gespeichert. Der Durchschnitt aller gespeicherten Werte eines Kriteriums entspricht der Leistung der getesteten Variation in diesem Kriterium. Das Kriterium der Erkennbarkeit verwendet zur Auswertung dasjenige vortrainierte Modell, das auf denselben Daten trainiert ist, die im Test verwendet werden (siehe 3.2.1 Erkennbarkeit). Da das Kriterium der Erkennbarkeit entweder den Wert 0 oder 1 hat, ergibt der Durchschnitt aus allen Werten dieses Kriteriums eine prozentuale Angabe (in Dezimalform) darüber, in wie vielen Fällen das richtige Motiv erkannt wird.

Kapitel 4

Resultate

Die Resultate bestehen aus drei Tabellen. Jede Tabelle beschreibt die Leistung der acht Versionen (siehe 3.3 Variationen), bezogen auf die drei definierten Kriterien (siehe 3.2 Evaluation der Leistung). Die Daten in den Tabellen stammen aus den Tests der KI (siehe 3.4 Auswertung). Der Unterschied in den Tabellen liegt im Datenset, mit denen die Versionen der KI jeweils getestet sind. Eine Sammlung von gezeichneten Strichbildern ergänzt die Resultate. Die Strichbilder sind dabei jeweils in Paaren angeordnet. Das linke Bild im Paar zeigt die Vorlage aus dem Datenset und das rechte Bild zeigt die nachgezeichnete Variante von der KI. Die Zeichnungen, die in der Sammlung vertreten sind, sind zufällig ausgewählt aus dem Test der jeweiligen Version der KI und stammen aus den Tests von allen drei Datensets. Die Bilder haben einen Farbverlauf, der den zeitliche Verlauf des Zeichnens darstellt. Die Helligkeit eines Striches ist proportional zu dem Step, in dem dieser gezeichnet wurde. Das bedeutet, dass dunklere Striche früher gezeichnet wurden als hellere Striche. Bewegungen des Agents, in denen dieser nicht zeichnet, sind in den Bildern nicht erkennbar.

4.1 Tabellen

Tabelle 4.1: Testen auf MNIST Datenset — 2000 Tests

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
Grund-Basis	86.5	86.6	24.5
Grund-MNIST	66.8	64.3	51.2
Grund-Speed	85.7	82.3	23.3
Grund-MNIST-Speed	61.4	55.1	56.8
Physik-Basis	56.4	46.4	62.5
Physik-MNIST	38.4	35.7	63.9
Physik-Speed	63.0	58.2	61.2
Physik-MNIST-Speed	29.2	27.3	63.7

Tabelle 4.2: Testen auf EMNIST Letters Datenset — 2000 Tests

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
Grund-Basis	86.8	74.5	38.2
Grund-MNIST	65.2	45.0	57.4
Grund-Speed	88.1	73.5	36.1
Grund-MNIST-Speed	62.2	40.0	60.9
Physik-Basis	57.6	32.4	63.5
Physik-MNIST	43.3	23.6	63.9
Physik-Speed	56.3	35.0	63.6
Physik-MNIST-Speed	30.2	13.9	64.0

Tabelle 4.3: Testen auf QuickDraw-Datenset — 2000 Tests

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
Grund-Basis	79.1	80.5	39.1
Grund-MNIST	57.3	62.5	59.9
Grund-Speed	80.0	80.3	35.0
Grund-MNIST-Speed	54.9	58.9	62.5
Physik-Basis	48.1	55.7	63.8
Physik-MNIST	30.5	38.9	64.0
Physik-Speed	50.0	58.3	63.6
Physik-MNIST-Speed	22.4	31.1	64.0

4.2 Bildersammlung



Abbildung 4.1: Grund-Basis Bildersammlung

4. RESULTATE



Abbildung 4.2: Grund-MNIST Bildersammlung




Abbildung 4.3: Physik-Basis Bildersammlung

4. RESULTATE



Abbildung 4.4: Physik-Speed Bildersammlung

Kapitel 5

Diskussion

Die Diskussion analysiert die Resultate der Methode (siehe 3 Methode), um daraus eine Antwort auf die Fragestellung zu bilden. Zu diesem Zweck werden einige allgemeine Feststellungen getroffen und die Unterfragen beantwortet (siehe 5.1 Fragestellung und Unterfragen). Im zweiten Teil der Diskussion folgt ein Fazit, ein Ausblick (siehe 5.2 Fazit und Ausblick), und eine Selbstreflexion (siehe 5.3 Selbstreflexion). Dabei verschiebt sich der Fokus von der Fragestellung weg und auf eine allgemeinere Betrachtung der Arbeit.

5.1 Fragestellung und Unterfragen

Die Fragestellung und die Unterfragen decken nicht alle Erkenntnisse aus den Resultaten ab (siehe 4 Resultate). Einige allgemeine Feststellungen geben Einblick, wie die Resultate zu verstehen sind.

Die Grund-Basis Version und die Grund-Speed Version (siehe 3.4 Auswertung) erreichen in allen Kriterien für alle Datensets die beste Leistung. Die Resultate zwischen den Versionen sind dabei bis auf den Wert des Kriteriums der Geschwindigkeit (siehe 3.2.3 Geschwindigkeit) fast ununterscheidbar. In diesem Kriterium erreicht die Grund-Speed Variation leicht bessere Werte als die Grund-Basis Version. Beispielsweise stellt die Grund-Speed Version Zeichnungen aus dem Quickdraw Datenset durchschnittlich vier Schritte früher als die Grund-Basis Version fertig. Insgesamt erreicht somit die Grund-Speed Version die beste Leistung. Unter den Versionen, die auf der physikalischen Umgebung basieren, erreichen ebenfalls die Physik-Basis und die Physik-Speed Versionen die beste Leistung. Die Werte sind allerdings deutlich tiefer als bei der Grund-Basis und der Grund-Speed Version.

Die Grund-MNIST Version und die Physik-MNIST Version sind in allen

Kriterien schlechter als die Basis und Speed Versionen. Auch im Kriterium der Erkennbarkeit (siehe 3.2.1 Erkennbarkeit) von MNIST Ziffern bringt die MNIST Variation keinen Vorteil. Die Physik-MNIST-Speed Version erbringt insgesamt die schlechteste Leistung. Eine Erklärung dafür ist, dass diese Version eine Kombination von allen Variationen (siehe 3.3 Variationen) ist und somit von der leistungsstarken Grund-Basis Version am stärksten abweicht.

5.1.1 Beantwortung der Unterfragen

Insgesamt sechs Unterfragen werden beantwortet (siehe 1 Einleitung). Diese Unterfragen weiten die Fragestellung aus und tragen zu der schlussendlichen Antwort auf die Fragestellung bei. Die Antworten beruhen auf den Resultaten, aber auch auf Erkenntnissen aus der Methode selbst (siehe 3 Methode).

Wie kann die Architektur einer KI aussehen, die das Nachzeichnen erlernt?

Unter der Annahme, dass die KI dieser Arbeit das Nachzeichnen erlernt, (siehe 5.1.2 Beantwortung der Fragestellung), kann die Architektur genau so aussehen, wie sie in dieser Arbeit beschrieben ist (siehe 3.1.1 Doodle-SDQ als Basis).

Wie lässt sich die Leistung der KI in ihrer Aufgabe beurteilen?

Die Leistung der KI lässt sich durch die definierten Kriterien (siehe 3.2 Evaluation der Leistung) beurteilen. Das Kriterium der Übereinstimmung ist durch einen objektiven und absoluten Wert repräsentiert, wodurch es das aussagekräftigste Kriterium ist. Ausserdem ist der maximale Wert des Kriteriums (100%) unabhängig vom gezeichneten Bild und dem Verhalten der KI. Dadurch ist das Kriterium geeignet für Vergleiche zwischen Versionen der KI.

Die Kriterien der Erkennbarkeit und der Geschwindigkeit sind an subjektive Annahmen gebunden. Zum Beispiel wird für das Kriterium der Geschwindigkeit ein subjektiver Punkt der Fertigstellung definiert (siehe 3.2.3 Geschwindigkeit). Dadurch sinkt ihre Aussagekraft. Allerdings verändern sich die Annahmen nicht und die Kriterien sind in jedem Fall durch einen Zahlenwert repräsentiert. Somit eignen sich auch diese Kriterien für Vergleiche zwischen Versionen der KI. Aus der Annahme heraus, dass für Menschen beim Nachzeichnen Erkennbarkeit wichtiger als absolute Genauigkeit ist, ergibt sich das Kriterium der Erkennbarkeit als besonders wichtig. Aus diesem Grund ist das Kriterium in der Fragestellung (siehe 1 Einleitung) festgehalten.

Wie lässt sich die Leistung der KI in ihrer Aufgabe verbessern?

Bezogen auf die definierten Kriterien erreicht die Grund-Basis Version Werte, die durch die implementierten Variationen nicht verbessert werden. Die Grund-Speed Version ist hierbei eine Ausnahme (siehe 5.1 Fragestellung und Unterfragen). Insgesamt sind die meisten Variationen der KI ein gescheiterter Versuch der Verbesserung der Leistung. Die Grund-Basis Version erfuhr allerdings während dessen Entwicklung signifikante Verbesserungen. Die grössten Verbesserungen stammen aus der Optimierung der Hyperparameter durch den Bayesian Optimization Algorithmus (siehe 3.1.2 Präparierung der Daten und Optimierung). Diese Optimierung steigerte die Leistung der Grund-Basis Version im Kriterium der prozentualen Übereinstimmung um 40 – 50%.

Welche Einflüsse haben physische Einschränkungen auf die Leistung der KI?

Die physischen Einschränkungen, die auf Physiksimulationen basieren (siehe 3.3.4 Physikalische Umgebung), verschlechtern die Leistung der KI bezogen auf die definierten Kriterien. Alle Versionen, die auf der Grundumgebung basieren, erzielen höhere Werte als die gleichen Versionen basierend auf der physikalischen Umgebung. Die physikalische Umgebung hat zum Ziel, die Bewegungen der KI realistischer zu gestalten als die Grundumgebung. In diesem Bereich kann der Einfluss nicht objektiv bestimmt werden. Aus Beobachtungen der Bilder, welche in der physikalischen Umgebung gezeichnet sind (siehe 4.2 Bildersammlung), gehen ebenfalls keine Erkenntnisse in diesem Bereich hervor. Die Bilder unterscheiden sich nicht bedeutend von denjenigen aus der Grundumgebung.

Wie ändert sich die Leistung der KI für Strichbilder, die im Training nicht enthalten sind?

In allen acht Versionen bleibt die Leistung der KI zwischen den drei Datensets (siehe Tabelle 3.1) vergleichbar. Die Tabellen (siehe Tabelle 5.1 und Tabelle 5.2) zeigen die Leistung der Grund-Basis Version und der Physik-Basis Version in den drei definierten Kriterien, getestet auf die drei Datensets. Der Wert der Übereinstimmung zwischen dem MNIST Datenset und dem EMNIST Datenset ist beinahe identisch. Für beide Versionen ist der Wert der Übereinstimmung für das QuickDraw Datenset niedriger. Insgesamt ist die KI in diesem Kriterium jedoch kaum beeinflusst durch die Wahl des Datensets. Die Analyse der anderen zwei Kriterien führt zu einer ähnlichen Schlussfolgerung. Interessant ist, dass vor allem die Grund-Basis Version eine viel höhere Geschwindigkeit im Zeichnen von MNIST Zahlen hat, als im Zeichnen von EMNIST Buchstaben. Obwohl die Formen zu einem

5. DISKUSSION

grossen Teil ähnlich sind, scheint die KI durch das spezifische Training auf MNIST Ziffern eine höhere Geschwindigkeit zu entwickeln.

Tabelle 5.1: Grund-Basis Leistung

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
MNIST	86.5	86.6	24.5
EMNIST	86.8	74.5	38.2
QuickDraw	79.1	80.5	39.1

Tabelle 5.2: Physik-Basis Leistung

	Übereinstimmung %	Erkennbarkeit %	Geschwindigkeit
MNIST	56.4	46.4	62.5
EMNIST	57.6	32.4	63.5
QuickDraw	48.1	55.7	63.8

Wie und inwiefern lässt sich das Verhalten der KI mit menschlichem Zeichnen vergleichen?

Die Antwort auf diese Frage leitet sich nicht aus den objektiven Resultaten ab, sondern basiert auf subjektiven Beobachtungen. Die Bewegungen in der Physik-Version der künstlichen Intelligenz basieren grundsätzlich auf denselben Gesetzen wie die Bewegungen in der echten Welt. Allerdings sind die Bewegungen stark vereinfacht im Vergleich zu menschlichen Bewegungen. Ausserdem ist für die künstliche Intelligenz der Druck des Stiftes nicht veränderbar. Zumindest konzeptuell nähert die künstliche Intelligenz menschliches Zeichnen, bezogen auf die physischen Einschränkungen, an. Einige menschliche Gewohnheiten sind bei der künstlichen Intelligenz allerdings nicht beobachtbar. Zum Beispiel beginnt die künstliche Intelligenz beim Zeichnen von Ziffern an zufälligen Orten, während Menschen in der Regel für jede Ziffer an derselben Stelle ansetzen.

5.1.2 Beantwortung der Fragestellung

Die Fragestellung lautet: Inwiefern kann eine künstliche Intelligenz lernen, Strichbilder auf eine physische Weise nachzuzeichnen, sodass diese durch ein automatisches System erkannt werden? (siehe 1 Einleitung) Diese Frage hat mehrere Aspekte, die teilweise bereits durch die Unterfragen (siehe 5.1.1 Beantwortung der Unterfragen) erfasst werden. Für die schlussendliche Antwort folgt eine genauere Ausführung der Aspekte.

Die KI zeichnet durch Physiksimulationen und durch allgemeine Einschränkungen der Bewegungsfreiheit auf eine annähernd physische

Weise. Das Zeichnen ist nur annähernd physisch, da alle Bewegungen simuliert sind und somit in keiner physischen Umgebung stattfinden. Ausserdem sind die Simulationen nicht vollkommen realistisch (siehe 5.1.1 Welche Einflüsse haben physische Einschränkungen auf die Leistung der KI?).

Die künstliche Intelligenz erlernt das Nachzeichnen bezogen auf die Kriterien, nach denen es definiert ist, erfolgreich. Dafür sprechen die Werte der besten Versionen für das Nachzeichnen von Ziffern (siehe 5.1 Fragestellung und Unterfragen). Die hohen Werte im Kriterium der Erkennbarkeit der besten Versionen bestätigen ausserdem, dass die Zeichnungen der KI in den meisten Fällen von einem automatischen System (einer zweiten KI) erkannt werden.

Laut der Fragestellung soll die KI das Nachzeichnen von Strichbildern erlernen. Damit ist implizit das Nachzeichnen von allen möglichen Arten von Strichbildern gemeint. Die Leistung der KI kann nicht auf alle möglichen Strichbilder überprüft werden, aber der Test mit drei verschiedenen Datensets ergibt vielversprechende Resultate (siehe 4.1 Tabellen). Die KI erlernt das Nachzeichnen von Ziffern, Kleinbuchstaben und zehn zufälligen Motiven aus dem QuickDraw Datenset erfolgreich. Durch die Vielfalt im QuickDraw Datenset kann die Annahme getroffen werden, dass die KI zumindest einen grossen Teil der denkbaren Strichbilder erfolgreich nachzeichnen kann.

Die zusammenfassende Antwort auf die Frage lautet somit: Eine künstliche Intelligenz kann das Nachzeichnen von Strichbildern auf annähernd physische Weise in dem Sinne lernen, dass die fertige Zeichnung von einem automatischen System grösstenteils erkannt wird, die Übereinstimmung zwischen der Vorlage und der Zeichnung gross ist und die Zeichnung nicht viel Zeit in Anspruch nimmt.

Diese Antwort bezieht sich auf die genaue Frage, wie sie in der Einleitung steht. Der nächste Abschnitt beurteilt die Frage durch die Erkenntnisse aus dieser Arbeit und geht auf mögliche Erweiterungen ein.

5.2 Fazit und Ausblick

Die Resultate erlauben eine positive Antwort auf die Fragestellung (siehe 5.1.2 Beantwortung der Fragestellung). Diese Antwort setzt allerdings einige Annahmen voraus, die weiter diskutiert werden können. Die grösste Annahme bezieht sich auf die Definition des Nachzeichnens. Diese Arbeit definiert Nachzeichnen durch drei Kriterien und durch physische Rahmenbedingungen. Die Kriterien sind für eine künstliche Intelligenz sinnvoll gewählt (siehe 5.1.1 Wie lässt sich die Leistung der KI in ihrer Aufgabe beurteilen?), allerdings wären auch andere Kriterien möglich. Nachzeichnen ist eine menschliche Tätigkeit. Dieser menschliche Aspekt ist in den definierten Kriterien wenig enthalten. Die zweite Annahme bezieht

sich auf die Definition eines Strichbildes. Die KI kann nur eine bestimmte Art von Strichbildern nachzeichnen. Mehrfarbige Bilder kann die KI beispielsweise nicht zeichnen.

Die physischen Rahmenbedingungen unterscheiden sich von denjenigen, die ein Mensch erfährt. Das kommt daher, dass die physischen Rahmenbedingungen für die KI lediglich simuliert sind. Das verunmöglicht eine umfassende Antwort auf die Frage, ob die künstliche Intelligenz auf eine physische Weise zeichnet. Dieses Problem könnte mit einem Roboter gelöst werden, der die künstliche Intelligenz in eine reale, physische Umgebung überführt. Der Roboter könnte verschiedenste Strichbilder auf einem echten Stück Papier, und somit zwangsläufig auf physische Weise nachzeichnen.

Aktuell sind die Bewegungen der künstlichen Intelligenz in gewissen Belangen eingeschränkt. So ist beispielsweise die Druckstärke nicht variierbar. Ausserdem zeichnet die künstliche Intelligenz vorwiegend kleine Strichbilder. Experimente mit grösseren Konstrukten, wie ganze Wörter, wären eine mögliche Erweiterung.

Alles in allem sind eine Vielzahl an denkbaren Fragen und Ideen möglich, die auf ReSketch, der künstlichen Intelligenz hinter dieser Arbeit, basieren.

5.3 Selbstreflexion

Die Selbstreflexion gibt genauere Einblicke in die Vorgehensweise hinter dieser Arbeit. Diese Dokumentation ist grundsätzlich eine Zusammenfassung der wichtigsten Ereignisse. Viele Aspekte bleiben verschwiegen. Die Selbstreflexion geht näher auf drei wichtige Aspekte ein, die in der zusammengefassten Dokumentation nicht genug betont sind.

Die Dokumentation ist mit LaTeX und spezifischer der ETH Thesis Formatvorlage („CADMO, Institute of Theoretical Computer Science, Department of Computer Science, ETH Zürich“, 2014) formatiert. Ein Grossteil der Abbildungen stammt von den Autoren und ist in Adobe Illustrator oder der Python Library Matplotlib erstellt.

5.3.1 Optimierung der KI

Insgesamt sind acht Versionen der KI präsentiert. Im Verlaufe des Projektes gab es viele weitere Versuche, die Leistung der künstlichen Intelligenz zu verbessern. Diese Versuche führten allerdings häufig dazu, dass die KI den akkumulierten Reward (siehe 2.2.1 Funktionsweise von Reinforcement Learning) nicht mehr maximieren konnte. In der Dokumentation sind deswegen nur diejenigen Versuche festgehalten, die tatsächlich funktionieren.

Häufig ist der Grund hinter dem Scheitern oder dem Erfolg einer KI schwer zu erkennen, was die Optimierung allgemein verkompliziert.

Die Strategie hinter der Optimierung der KI besteht in den meisten Fällen aus wiederholtem ausprobieren mit Anpassungen zwischen jedem Versuch. Hilfsmittel, wie der Bayesian Optimization Algorithmus, erleichtern diese Aufgabe massgeblich. Diese Strategie der Optimierung ist für einen Computer sehr ressourcenintensiv. In den längsten Optimierungsphasen liefen die beiden Computer, auf denen die Arbeit verrichtet wurde, zusammen länger als 48 Stunden.

5.3.2 Analyse der KI

Eine Analyse der künstlichen Intelligenz ist notwendig, um die Fragestellung und die Unterfragen zu beantworten. Aber auch während der Entwicklung ist eine stetige Analyse nötig, um die KI zu verstehen und zu verbessern.

Die Analyse besteht hauptsächlich darin, die Leistung der künstlichen Intelligenz zu beurteilen. Das geschieht mittels der Kriterien, die für diesen Zweck definiert sind (siehe 3.2 Evaluation der Leistung). Die Kriterien sind dabei so definiert, dass sie für jede mögliche Variation identisch bleiben. Der durchschnittliche akkumulierte Reward ist beispielsweise absichtlich kein Kriterium. Der akkumulierte Reward ist abhängig von der Reward-Function (siehe 2.2.1 Funktionsweise von Reinforcement Learning) und unterscheidet sich somit zwischen Variationen.

Eine weitere Form der Analyse stammt aus der Sammlung von Daten über das Lernverhalten der KI. So wird aus jedem Training ein Graph erstellt, der die durchschnittliche Leistung der KI in jeder Episode erfasst (siehe Abbildung 5.1). Die Leistung ist dabei durch den akkumulierten Reward in jeder Episode repräsentiert. Wie erwähnt, können Versionen der KI nicht anhand ihres akkumulierten Rewards verglichen werden. Der akkumulierte Reward zeigt allerdings für einzelne Versionen am präzisesten, inwiefern diese den akkumulierten Reward maximieren können.




Abbildung 5.1: Akkumulierter Reward zu jeder Episode (Lernverhalten) der Grund-Basis Version und der Physik-Basis Version. (eigene Abbildung)

5.3.3 Verwendung von Git und GitHub

Die Verwendung von Git und Github (siehe ?? ??) erleichtert die Arbeit an einem Projekt von dieser Grösse massgeblich. Die Programme ermöglichen einfache Zusammenarbeit am Programmcode und an der Dokumentation. GitHub dient dabei zusätzlich als Hilfsmittel zur Organisation durch die integrierte Funktion der Project Boards. Diese Funktion hätte allerdings zu grösserem Ausmass Verwendung finden können.

Die Funktion der Branches und Commits von Git wurden durch die Arbeit hindurch konsequent verwendet. Dabei wurde die Git Flow Arbeitsweise, abgesehen von den Release Branches und den Hotfix Branches, angewendet (siehe ?? ??). Neben den Feature Branches wurden ausserdem Dokumentation Branches eingeführt. In jedem Dokumentation Branch wurde ein Kapitel der Dokumentation verfasst. Für die Zusammenführungen der wichtigsten Branches wurde das Prinzip der Pull Request (siehe ?? ??) angewendet. Die Pull Request musste dabei für jeden Branch von demjenigen Autor akzeptiert werden, der die Pull Request nicht stellte.

Ein weiterer Vorteil von Git und Github ist die Zugänglichkeit des Projektes. Das gesamte Projekt ist unter folgendem Link einsehbar: <https://github.com/LarsZauberer/Nachzeichner-KI>. Im Projektordner sind vortrainierte Variationen der künstlichen Intelligenz enthalten. Das Projekt auf GitHub erfährt möglicherweise Erweiterungen, die in dieser Arbeit nicht mehr erfasst sind.

Kapitel 6

Zusammenfassung

Diese Untersuchung beantwortet die Frage, inwiefern eine künstliche Intelligenz Strichbilder auf eine physische Weise nachzeichnen kann, sodass diese durch ein automatisches System erkannt werden. Mit Strichbildern sind in diesem Fall Ziffern aus dem MNIST Datenset, Buchstaben aus dem EMNIST Letters Datenset und weitere Motive aus dem QuickDraw Datenset gemeint.

Zur Beantwortung der Fragestellung wird der Begriff des Nachzeichnens definiert. Zu der Definition gehören die Rahmenbedingungen, nach denen eine Tätigkeit als Nachzeichnen gilt, und die Kriterien, welche die Leistung im Nachzeichnen beurteilen. Zu den Rahmenbedingungen gehören unter anderem die physischen Einschränkungen und die ausführbaren Aktionen der KI. Um die Leistung der KI im Nachzeichnen zu bewerten, sind drei Kriterien definiert: Die Übereinstimmung der Pixel, die Erkennbarkeit der Zeichnung und die Geschwindigkeit des Zeichnens. Die Erkennbarkeit der Zeichnung wird durch eine zweite künstliche Intelligenz ermittelt.

Mit der Definition lautet das Ziel, eine künstliche Intelligenz zu entwickeln, welche die gesetzten Rahmenbedingungen erfüllt und eine möglichst gute Leistung nach den definierten Kriterien erzielt. Bei der grundsätzlichen Architektur der KI handelt es sich um ein Deep Q-Learning Modell, das auf der Arbeit hinter 'Doodle-SDQ' (Zhou et al., 2018) basiert.

Für die Rahmenbedingungen gibt es zwei Ansätze: Eine Grundumgebung und eine physikalische Umgebung. In der Grundumgebung kann sich die KI schrittweise um eine begrenzte Anzahl Pixel auf einer simulierten Zeichenfläche fortbewegen. Ausserdem startet die KI in einer zufälligen Position auf der Zeichenfläche. Die physikalische Umgebung ist von simulierter Physik begleitet. So kann die KI durch Beschleunigungen ihre aktuelle Geschwindigkeit anpassen und sich dadurch fortbewegen. Dabei wird die KI durch simulierte Reibung kontinuierlich abgebremst.

Für die KI existieren weitere Variationen, die dessen Leistung nach einem bestimmten Kriterium verbessern sollen. So existiert ein spezifisches Training auf eine verbesserte Erkennbarkeit und Geschwindigkeit der KI. Durch Kombinationen der Variationen und der Rahmenbedingungen existieren schlussendlich acht Versionen der künstlichen Intelligenz.

Die acht Versionen der künstlichen Intelligenz sind alle auf das Nachzeichnen von Ziffern trainiert. Ein Experiment bestimmt, ob diese Versionen das Nachzeichnen allgemein erlernen. Die Leistung der Versionen wird auf das Nachzeichnen von Strichbildern aus dem Quickdraw und dem EMNIST Letters Datenset gemessen. Wenn die Leistung für diese Strichbilder vergleichbar bleibt mit der Leistung für die Trainingsdaten, ermöglicht das eine positive Antwort für die Fragestellung.

Einige Versionen der künstlichen Intelligenz zeigen hierbei vielversprechende Ergebnisse. Die Grundversion, ohne weitere Variationen, zeichnet in 87% der Fälle eine erkennbare Ziffer, in 75% der Fälle einen erkennbaren Buchstaben, und in 80% der Fälle ein erkennbares Motiv aus dem QuickDraw Datenset.

Literatur

- Aaron Hertzmann. (2002, 15. April). *Stroke-Based Rendering*. Verfügbar 16. September 2022 unter https://www.cs.ucdavis.edu/~ma/SIGGRAPH02/course23/notes/S02c23_3.pdf
- Agnihotri, A., & Batra, N. (2020). Exploring bayesian optimization. *Distill*, 5(5), e26. <https://doi.org/10.23915/distill.00026>
- Arora, S. (2020, 29. Januar). *Supervised vs unsupervised vs reinforcement* [AITUDE]. Verfügbar 25. Juni 2022 unter <https://www.aitude.com/supervised-vs-unsupervised-vs-reinforcement/>
- Artificial neural network tutorial - javatpoint* [Www.javatpoint.com]. (n. d.). Verfügbar 16. September 2022 unter <https://www.javatpoint.com/artificial-neural-network>
- Black Box (Systemtheorie) [Page Version ID: 215860839]. (2021, 24. September). In *Wikipedia*. Verfügbar 2. Oktober 2022 unter [https://de.wikipedia.org/w/index.php?title=Black.Box_\(Systemtheorie\)&oldid=215860839](https://de.wikipedia.org/w/index.php?title=Black.Box_(Systemtheorie)&oldid=215860839)
- CADMO, Institute of Theoretical Computer Science, Department of Computer Science, ETH Zürich. (2014, 8. April). Verfügbar 7. Oktober 2022 unter <https://cadmo.ethz.ch/education/thesis/template.html>
- David E. Rumelhart, Geoffrey E. Hinton & Ronald J. Williams. (n. d.). *Learning representations by back-propagating errors*. Verfügbar 16. September 2022 unter https://www.iro.umontreal.ca/~vincentp/ift3395/lectures/backprop_old.pdf
- Deshpande, A. (n. d.). *A Beginner's Guide To Understanding Convolutional Neural Networks Part 2*. Verfügbar 28. April 2022 unter <https://adeshpande3.github.io/A-Beginner's-Guide-To-Understanding-Convolutional-Neural-Networks-Part-2/>
- Fernando Nogueira. (2014). *Bayesian Optimization: Open source constrained global optimization tool for Python* [original-date: 2014-06-06T08:18:56Z].

- Verfügbar 25. Juli 2022 unter <https://github.com/fmfn/BayesianOptimization>
- Garnett, R. (n. d.). *Bayesian optimization book* [Bayesian optimization book]. Verfügbar 2. Oktober 2022 unter <https://bayesoptbook.com/>
- Huang, Z., Zhou, S., & Heng, W. (2019). Learning to paint with model-based deep reinforcement learning. *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, 8708–8717. <https://doi.org/10.1109/ICCV.2019.00880>
- Jan-Dirk Kranz. (2019, 3. April). *Deep Learning vs Machine Learning - Was ist der Unterschied?* [IT-Talents.de]. Verfügbar 18. Juni 2022 unter <https://it-talents.de/it-wissen/programmieren/deep-learning-vs-machine-learning-was-ist-der-unterschied/>
- Jayawardana, K. (2021, 3. Januar). *Concatenating multiple activation functions and multiple pooling layers for deep neural networks* [Medium]. Verfügbar 16. September 2022 unter <https://towardsdatascience.com/concatenating-multiple-activation-functions-and-multiple-pooling-layers-for-deep-neural-networks-d48a4b273d30>
- Keras: the Python deep learning API. (2015). Verfügbar 9. Oktober 2022 unter <https://keras.io/>
- Kumar, N. (2019, 18. Dezember). *Sigmoid neuron — deep neural networks* [Medium]. Verfügbar 16. September 2022 unter <https://towardsdatascience.com/sigmoid-neuron-deep-neural-networks-a4cd35b629d7>
- Lâm (Linus), H. T. (2022, 12. August). *Keras DenseNet 121 for Quick, Draw! Doodle Recognition Challenge* [original-date: 2018-12-09T03:16:32Z]. Verfügbar 28. August 2022 unter <https://github.com/lamhoangtung/densenet121-quickdraw-doodle-recognition-challenge>
- Laurenz Wuttke. (2021, 13. Oktober). *Was ist Supervised Learning (Überwachtes Lernen)?* [datasolut GmbH]. Verfügbar 16. September 2022 unter <https://datasolut.com/wiki/supervised-learning/>
- Luis G. Serrano. (2021, 14. Dezember). *2.1 what is the difference between labelled and unlabelled data? · grokking machine learning*. Verfügbar 16. September 2022 unter <https://livebook.manning.com/book/grokking-machine-learning/2-1-what-is-the-difference-between-labelled-and-unlabelled-data-v-4/>
- Malik, F. (2019, 20. Mai). *What are hidden layers?* [FinTechExplained]. Verfügbar 16. September 2022 unter <https://medium.com/fintechexplained/what-are-hidden-layers-4f54f7328263>
- Mazzia, Vittorio, Salvetti, Francesco, Chiaberge & Marcello. (2022, 29. Juli). *~ Efficient-CapsNet ~* [original-date: 2020-12-29T18:13:43Z]. Verfügbar 3. August 2022 unter <https://github.com/EscVM/Efficient-CapsNet>

- Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., & Riedmiller, M. (2013, 19. Dezember). Playing Atari with Deep Reinforcement Learning. <https://doi.org/10.48550/arXiv.1312.5602>
- Mor, S. (2022, 1. Juni). *EMNIST* [original-date: 2018-07-17T12:21:46Z]. Verfügbar 7. Oktober 2022 unter <https://github.com/shubhammor0403/EMNIST>
- Moriconi, R., Deisenroth, M. P., & Kumar, K. S. S. (2020, 25. September). High-dimensional Bayesian optimization using low-dimensional feature spaces. <https://doi.org/10.48550/arXiv.1902.10675>
- Neuronales Netz [Page Version ID: 210963657]. (2021, 15. April). In *Wikipedia*. Verfügbar 16. September 2022 unter https://de.wikipedia.org/w/index.php?title=Neuronales_Netz&oldid=210963657
- Nielsen, M. A. (2015). *Neural networks and deep learning* [Publisher: Determination Press]. Verfügbar 22. April 2022 unter <http://neuralnetworksanddeeplearning.com>
- Nyuytiymbiy, K. (2022, 28. März). *Parameters and hyperparameters in machine learning and deep learning* [Medium]. Verfügbar 16. September 2022 unter <https://towardsdatascience.com/parameters-and-hyperparameters-aa609601a9ac>
- Ognjanovski, G. (2020, 7. Juni). *Everything you need to know about neural networks and backpropagation — machine learning made easy...* [Medium]. Verfügbar 16. September 2022 unter <https://towardsdatascience.com/everything-you-need-to-know-about-neural-networks-and-backpropagation-machine-learning-made-easy-e5285bc2be3a>
- Osiński, B., & Budek, K. (2018, 5. Juli). *What is reinforcement learning? the complete guide* [Deepsense.ai] [Section: Deep learning]. Verfügbar 16. September 2022 unter <https://deepsense.ai/what-is-reinforcement-learning-the-complete-guide/>
- paretos. (2021, 25. Januar). *Bayesian Optimization (Bayes Opt): Easy explanation of popular hyperparameter tuning method*. Verfügbar 22. September 2022 unter <https://www.youtube.com/watch?v=M-NTkxfd7-8>
- Piyush Verma & Stelios Diamantidis. (2021, 27. April). *What is Reinforcement Learning? – Overview of How it Works — Synopsys*. Verfügbar 16. September 2022 unter <https://www.synopsys.com/ai/what-is-reinforcement-learning.html>
- Pragati Baheti. (2022, 19. Juli). *Activation functions in neural networks [12 types & use cases]*. Verfügbar 16. September 2022 unter <https://www.v7labs.com/blog/neural-networks-activation-functions,%20https://www.v7labs.com/blog/neural-networks-activation-functions>
- Pramoditha, R. (2021, 29. Dezember). *The concept of artificial neurons (perceptrons) in neural networks* [Medium]. Verfügbar 1. Oktober 2022 unter <https://towardsdatascience.com/the-concept-of-artificial-neurons-perceptrons-in-neural-networks-fab22249cbfc>

- Quick, Draw! Image Recognition [original-date: 2019-04-30T10:10:02Z]. (2022, 28. August). Verfügbar 28. August 2022 unter <https://github.com/Lexie88rus/quick-draw-image-recognition>
- Rajendra Koppula. (n. d.). *Exploration vs. exploitation in reinforcement learning*. Verfügbar 2. Oktober 2022 unter <https://www.manifold.ai/exploration-vs-exploitation-in-reinforcement-learning>
- Robbins, B. (2017, 14. Juli). *MACHINE LEARNING: How black is this beautiful black box* [Medium]. Verfügbar 2. Oktober 2022 unter <https://towardsdatascience.com/machine-learning-how-black-is-this-black-box-f11e4031fdf>
- Sadie Bennett. (2019, 10. Juni). *Why machine learning is primarily written in Python* [IBM Developer]. Verfügbar 2. Oktober 2022 unter <https://developer.ibm.com/blogs/why-machine-learning-is-primarily-written-in-python/>
- Simplilearn. (2021, 26. Mai). *What is perceptron: A beginners guide for perceptron [updated]* [Simplilearn.com]. Verfügbar 16. September 2022 unter <https://www.simplilearn.com/tutorials/deep-learning-tutorial/perceptron>
- Spaulding, N. W. (2020, 9. Juli). Is Human Judgment Necessary? Artificial Intelligence, Algorithmic Governance, and the Law. In M. D. Dubber, F. Pasquale & S. Das (Hrsg.), *The Oxford Handbook of Ethics of AI*. Oxford University Press. <https://doi.org/10.1093/oxfordhb/9780190067397.013.25>
- Sutton, R. S., & Barto, A. G. (2014). *Reinforcement learning: An introduction*. MIT Press, 352.
- TensorFlow. (2015). Verfügbar 2. Oktober 2022 unter <https://www.tensorflow.org/>
- Trahasch, Tobias Hagen, Tobias Lauer, Volker Sänger, Stephan & Klaus Dorer. (2020, 8. August). *3.1 Einführung — Menschen Lernen Maschinelles Lernen - ML2*. Verfügbar 16. September 2022 unter <https://imla.gitlab.io/ml-buch/ml2-buch/3-1-lr-einfuehrung.html>
- Training and test sets: Splitting data — machine learning* [Google developers]. (n. d.). Verfügbar 16. September 2022 unter <https://developers.google.com/machine-learning/crash-course/training-and-test-sets/splitting-data>
- Unzueta, D. (2022, 15. März). *Convolutional layers vs fully connected layers* [Medium]. Verfügbar 16. September 2022 unter <https://towardsdatascience.com/convolutional-layers-vs-fully-connected-layers-364f05ab460b>
- van Heeswijk, W. (2021, 30. August). *How to model experience replay, batch learning and target networks* [Medium]. Verfügbar 16. September 2022 unter <https://towardsdatascience.com/how-to-model-experience-replay-batch-learning-and-target-networks-c1350db93172>

- Wang, M. (2021, 3. Oktober). *Deep q-learning tutorial: minDQN* [Medium]. Verfügbar 15. April 2022 unter <https://towardsdatascience.com/deep-q-learning-tutorial-mindqn-2a4c855abffc>
- What is Artificial Intelligence (AI)? — Glossary. (n. d.). Verfügbar 21. Juni 2022 unter <https://www.hpe.com/ch/de/what-is/artificial-intelligence.html>
- What is Machine Learning? — Glossary. (n. d.). Verfügbar 21. Juni 2022 unter <https://www.hpe.com/ch/de/what-is/machine-learning.html>
- Yann LeCun. (n. d.). *Papers with code - MNIST dataset*. Verfügbar 9. Oktober 2022 unter <https://paperswithcode.com/dataset/mnist>
- Yann LeCun, Corinna Cortes & Christopher J.C. Burges. (n. d.). *MNIST handwritten digit database, Yann LeCun, Corinna Cortes and Chris Burges*. Verfügbar 16. September 2022 unter <http://yann.lecun.com/exdb/mnist/>
- Zheng, N., Jiang, Y., & Huang, D. (2018). StrokeNet: A neural painting environment. Verfügbar 31. März 2022 unter <https://openreview.net/forum?id=HJxwDiActX>
- Zhou, T., Fang, C., Wang, Z., Yang, J., Kim, B., Chen, Z., Brandt, J., & Terzopoulos, D. (2018). Learning to Doodle with Deep Q Networks and Demonstrated Strokes. *arXiv:1810.05977 [cs]*. Verfügbar 31. März 2022 unter <http://arxiv.org/abs/1810.05977>

Abbildungsverzeichnis

2.1	Erkennung von handgeschriebenen Zahlen durch ein Machine Learning Modell. (eigene Abbildung)	4
2.2	Beispiele aus dem MNIST Datenset. (Eigene Abbildung)	5
2.3	Perzeptron Neuron. (eigene Abbildung)	6
2.4	Vergleich des Outputs eines Perzeptron Neurons und eines Sigmoid Neurons. (eigene Abbildung)	8
2.5	Neuronales Netz mit beschrifteten Layers. (eigene Abbildung) . .	9
2.6	Vergleich zwischen Convolutional Layers (links) und Fully Connected Layers (rechts). (Unzueta, 2022)	10

2.7	Prinzip einer Black Box Funktion. („Black Box (Systemtheorie)“, 2021)	10
2.8	Funktionsweise eines Reinforcement Learning Modells. (eigene Abbildung)	12
2.9	Funktionsweise einer Reward-Function. (eigene Abbildung) . . .	14
2.10	Vergleich zwischen Stroke-Based Rendering und dem Führen eines Stiftes. (eigene Abbildung)	15
3.1	Architektur des neuronalen Netzes im Grundprogramm (eigene Abbildung, mit Keras erstellt). Jeder Block repräsentiert einen Layer. Die Form des Inputs und des Outputs ist von jedem Layer angegeben	18
3.2	Action-Space im Grundprogramm	19
3.3	Entfernung der Graustufen im MNIST Datenset. (eigene Abbildung)	20
3.4	Drei Beispiele für den Wert des Kriteriums der Übereinstimmung. (eigene Abbildung)	22
3.5	Beispiele einer richtigen und einer falschen Erkennung von handgeschriebenen Zahlen durch eine KI (eigene Abbildung). Die Werte sind durch einen Test der KI berechnet.	25
3.6	Veränderung der Faktoren der Basis Reward-Function und der Reward-Function der Erkennbarkeit über das Training hinweg. (eigene Abbildung)	26
3.7	Action-Space in der physikalischen Umgebung. (eigene Abbildung)	27
3.8	Angabe der Geschwindigkeit durch eine Verschiebung des Local image Patches. (eigene Abbildung)	28
3.9	Beispiele der verwendeten Motive aus dem QuickDraw Datenset. (eigene Abbildung)	29
4.1	Grund-Basis Bildersammlung	33
4.2	Grund-MNIST Bildersammlung	34
4.3	Physik-Basis Bildersammlung	35
4.4	Physik-Speed Bildersammlung	36
5.1	Akkumulierter Reward zu jeder Episode (Lernverhalten) der Grund-Basis Version und der Physik-Basis Version. (eigene Abbildung)	44

Tabellenverzeichnis

3.1	Vortrainierte Modelle	21
4.1	Testen auf MNIST Datenset — 2000 Tests	32
4.2	Testen auf EMNIST Letters Datenset — 2000 Tests	32
4.3	Testen auf QuickDraw-Datenset — 2000 Tests	32
5.1	Grund-Basis Leistung	40
5.2	Physik-Basis Leistung	40